UNIVERSIDAD MARIANO GÁLVEZ DE GUATEMALA
FACULTAD DE INGENIERÍA EN SISTEMAS DE INFORMACIÓN

SISTEMA PREDICTIVO BASADO EN INTELIGENCIA ARTIFICIAL PARA LA GESTIÓN DE VENTAS DE ZORROS REVOLUTION BIKER

CURSO: SEMINARIO DE TECNOLOGÍA DE INFORMACIÓN
CATEDRÁTICO: ING. DICSOR HERNÁNDEZ

GABRIEL ENRIQUE PÉREZ MEZA
CARNÉ: 0900-23-14509
LUIS PEDRO ORDOÑEZ CHUTAN
CARNÉ: 0900-19-9883
ELDER ESTUARDO GARCIA PACHECO
CARNÉ: 0900-24-9106

GUATEMALA, OCTUBRE 2026

UNIVERSIDAD MARIANO GÁLVEZ DE GUATEMALA
FACULTAD DE INGENIERÍA EN SISTEMAS DE INFORMACIÓN

SISTEMA PREDICTIVO BASADO EN INTELIGENCIA ARTIFICIAL PARA LA GESTIÓN DE VENTAS DE ZORROS REVOLUTION BIKER

TRABAJO DE GRADUACIÓN

PRESENTADO POR:
GABRIEL ENRIQUE PÉREZ MEZA
LUIS PEDRO ORDOÑEZ CHUTAN
ELDER ESTUARDO GARCIA PACHECO

PREVIO A OPTAR AL GRADO ACADÉMICO DE
LICENCIADO EN INGENIERÍA EN SISTEMAS DE INFORMACIÓN Y CIENCIAS DE LA COMPUTACIÓN
Y
TÍTULO PROFESIONAL DE
INGENIERO EN SISTEMAS DE INFORMACIÓN
Y
CIENCIAS DE LA COMPUTACIÓN.

GUATEMALA, OCTUBRE 2026

Índice

Índice i

Índice de Tablas vii

Índice de Figuras ix

Introducción 1

Capítulo I – Marco Conceptual 3

1.1 Antecedentes 3

1.1.1 Contexto de Zorros Revolution Biker 3

1.1.2 Evolución de los sistemas predictivos de ventas 4

1.1.3 Brecha identificada 5

1.2 Planteamiento del Problema 5

1.3 Justificación 6

1.4 Objetivos 7

1.4.1 Objetivo General 7

1.4.2 Objetivos Específicos 7

1.5 Alcances y Límites 7

1.5.1 Ámbito Geográfico 7

1.5.2 Ámbito Tecnológico 8

1.5.3 Ámbito Personal 8

1.5.4 Ámbito Temporal 8

1.5.5 Ámbito Temático 8

1.5.6 Límites 8

1.6 Hipótesis 9

Capítulo II – Marco Teórico 11

2.1 Estado del Arte 11

2.1.1 Posicionamiento de la propuesta 11
2.2 Bases Teóricas 12
2.2.1 Gestión de Ventas en el Sector Retail 12
2.2.2 Fundamentos del Pronóstico de Series de Tiempo 14
2.2.3 Inteligencia Artificial Aplicada al Pronóstico de Ventas 15
2.2.4 Preparación de Datos y Construcción de Características 16
2.2.5 Evaluación de Pronósticos 17
2.2.6 Explicabilidad, Incertidumbre y Confianza 18
2.2.7 Arquitectura de Sistemas Predictivos 19
2.3 Definición de Términos 19
Capítulo III – Marco Metodológico 23
3.1 Tipo y Diseño de Investigación 23
3.1.1 Unidad de Análisis 23
3.2 Población y Muestra 24
3.2.1 Población 24
3.2.2 Muestra 24
3.3 Técnicas e Instrumentos de Recolección de Datos 24
3.3.1 Entrevista Semiestructurada 24
3.3.2 Cuestionario de Usabilidad 24
3.3.3 Observación Directa 25
3.3.4 Revisión Documental 25
3.3.5 Ficha de Perfilamiento de Datos 25
3.3.6 Procedimiento de Recolección de Datos 25
3.4 Validación del Instrumento 26
3.4.1 Juicio de expertos 26

3.4.2 Prueba piloto y confiabilidad 27
3.4.3 Validación de los instrumentos técnicos 27
3.4.4 Registro de resultados y ajustes 28
3.5 Metodología de Desarrollo del Proyecto 28
3.5.1 Selección del marco de trabajo 28
3.5.2 Roles del equipo 28
3.5.3 Eventos, artefactos y definición de terminado 29
3.5.4 Sprints y vinculación con los objetivos 29
3.5.5 Herramientas de gestión y seguimiento 30
Capítulo IV – Presentación y Análisis de Resultados 31
4.1 Presentación de resultados 31
4.1.1 Estado de aplicación de los instrumentos 31
4.1.2 Naturaleza de los datos utilizados 32
4.1.3 Resultados del perfilamiento de series 33
4.1.4 Serie agregada de ventas 35
4.1.5 Resultados de la evaluación de modelos 36
4.1.6 Resultado del criterio de publicación 38
4.1.7 Efecto del generador de datos sobre la evaluación 39
4.1.8 Resultados de las pruebas del sistema y del despliegue 39
4.2 Análisis e interpretación de resultados 40
4.2.1 La intermitencia del catálogo determina la estrategia de modelado 40
4.2.2 El modelo de aprendizaje automático supera a las referencias, pero por un margen estrecho 40
4.2.3 El sesgo negativo y la ventana de doce meses 41
4.2.4 La circularidad del generador anterior explica la diferencia entre 35 % y 22 % 41

4.2.5 Relación entre resultados: demanda censurada, sesgo y perfil 42
4.2.6 Cierre parcial por objetivo específico 42
4.3 Comprobación de hipótesis 43
4.3.1 Formulación 43
4.3.2 Prueba seleccionada y nivel de significancia 43
4.3.3 Resultados 44
4.3.4 Conclusión de la prueba 44
Capítulo V – Estudio de Factibilidad 46
5.1 Modelo de negocio 46
5.2 Transformación digital 47
5.3 Factibilidad legal 48
5.3.1 Normativa aplicable 48
5.3.2 Datos personales tratados 50
5.3.3 Licenciamiento del software 50
5.3.4 Confidencialidad 51
5.4 Factibilidad ambiental 51
5.5 Factibilidad operativa 52
5.6 Factibilidad técnica 53
5.6.1 Infraestructura 53
5.6.2 Herramientas y madurez tecnológica 53
5.6.3 Competencias del equipo 54
5.6.4 Riesgos técnicos identificados 54
5.7 Factibilidad económica 54
5.7.1 Costos 54
5.7.2 Beneficios y supuestos 55

5.7.3 Retorno de la inversión y relación beneficio-costo 55
5.7.4 Interpretación y punto de equilibrio 56
Capítulo VI – Desarrollo de la Solución Tecnológica 58
6.1 Tipo de sistema propuesto 58
6.2 Análisis de requerimientos 59
6.2.1 Fuentes y método 59
6.2.2 Levantamiento Preliminar de Requerimientos 59
6.2.3 Requerimientos funcionales 63
6.2.4 Requerimientos no funcionales 65
6.2.5 Casos de uso 66
6.3 Diseño de la solución 69
6.3.1 Diseño Arquitectónico Preliminar 69
6.3.2 Arquitectura 72
6.3.3 Modelo de datos 75
6.3.4 Diseño de la API 77
6.3.5 Diseño del motor de pronóstico 78
6.3.6 Prototipado de Baja Fidelidad 82
6.3.7 Diseño de la interfaz 84
6.3.8 Diseño de seguridad 85
6.4 Desarrollo o implementación 85
6.4.1 Tecnologías y justificación 85
6.4.2 Proceso de construcción 86
6.4.3 Entorno de desarrollo y despliegue 87
6.4.4 Evidencia del sistema en funcionamiento 87
6.5 Plan de pruebas 93

6.5.1 Estrategia 93
6.5.2 Matriz de casos de prueba 94
6.5.3 Defectos detectados y corregidos 96
6.5.4 Pruebas pendientes 97
Referencias 98

Índice de Tablas

Tabla 1. *Síntesis del estado del arte en pronóstico de ventas minoristas* 11
Tabla 2. *Características candidatas para el modelo predictivo* 17
Tabla 3. *Métricas propuestas para evaluar los pronósticos* 18
Tabla 4. *Procedimiento de validación previsto para cada instrumento de recolección de datos* 26
Tabla 5. *Sprints del proyecto, entregable principal y objetivo específico que atiende cada uno* 30
Tabla 6. *Estado de aplicación de los instrumentos de recolección de datos* 32
Tabla 7. *Características del conjunto de datos simulado utilizado en la validación técnica* 33
Tabla 8. *Perfil de intermitencia de las 25 series de demanda (n = 25)* 33
Tabla 9. *Perfil de los cinco productos de mayor y de menor volumen* 34
Tabla 10. *Ventas simuladas por mes* 35
Tabla 11. *Métricas promedio de los siete candidatos en cinco ventanas de origen móvil (horizonte de 30 días)* 37
Tabla 12. *MASE por ventana de validación* 37
Tabla 13. *Sesgo y WAPE del modelo por ventana de validación* 38
Tabla 14. *Resultado del criterio de publicación aplicado por el sistema* 39
Tabla 15. *Comparación de la evaluación del modelo según el procedimiento de generación de datos* 39
Tabla 16. *Pruebas automatizadas del sistema por módulo* 40
Tabla 17. *Diferencias de MASE por ventana entre el modelo y la referencia naïve estacional* 44
Tabla 18. *Resultados de la comprobación de hipótesis* 44
Tabla 19. *Business Model Canvas de Zorros Revolution Biker con los bloques en que interviene la solución* 47
Tabla 20. *Normativa guatemalteca aplicable y su atención en el proyecto* 49
Tabla 21. *Inventario de datos personales tratados por el sistema y medidas de protección* 50
Tabla 22. *Licencias de los componentes del sistema* 51
Tabla 23. *Infraestructura del despliegue y mediciones obtenidas* 53
Tabla 24. *Costos del proyecto* 55
Tabla 25. *Supuestos del análisis económico* 55
Tabla 26. *Escenarios de retorno de la inversión según los supuestos de la Tabla 25* 56
Tabla 27. *Clasificación del sistema según su tipo* 58

Tabla 28. *Requerimientos funcionales preliminares* 60
Tabla 29. *Requerimientos no funcionales preliminares* 61
Tabla 30. *Historias de usuario del backlog inicial* 62
Tabla 31. *Caso de uso CU-01: importar histórico de ventas* 62
Tabla 32. *Caso de uso CU-02: entrenar y evaluar modelos* 63
Tabla 33. *Caso de uso CU-03: consultar pronóstico* 63
Tabla 34. *Requerimientos funcionales con su estado en el MVP* 64
Tabla 35. *Requerimientos no funcionales, característica de calidad asociada y estado en el MVP* 66
Tabla 36. *Casos de uso del sistema* 67
Tabla 37. *Componentes propuestos para la arquitectura* 70
Tabla 38. *Entidades principales del sistema* 71
Tabla 39. *Endpoints preliminares de la API* 72
Tabla 40. *Componentes de la arquitectura y diferencias respecto del diseño preliminar* 75
Tabla 41. *Estado de las entidades del modelo de datos respecto del diseño preliminar* 77
Tabla 42. *Endpoints de la API implementados* 78
Tabla 43. *Componentes del motor de pronóstico y su fundamento teórico* 80
Tabla 44. *Tecnologías utilizadas y su justificación* 86
Tabla 45. *Iteraciones del desarrollo durante la fase* 87
Tabla 46. *Matriz de casos de prueba trazada a los requerimientos* 96
Tabla 47. *Defectos detectados durante las pruebas y su corrección* 97

Índice de Figuras

Figura 1. *Distribución de la proporción de días sin venta por producto (n = 25)* 34
Figura 2. *Serie diaria simulada de ventas con los periodos de temporada alta señalados* 35
Figura 3. *Ingreso mensual simulado* 36
Figura 4. *MASE por ventana de validación: modelo frente a la referencia naïve estacional* 38
Figura 5. *Diagrama de casos de uso del sistema* 68
Figura 6. *Arquitectura lógica de la solución web predictiva* 69
Figura 7. *Modelo entidad-relación preliminar* 71
Figura 8. *Arquitectura desplegada de la solución* 73
Figura 9. *Modelo entidad-relación implementado* 76
Figura 10. *Flujo de una recalibración del modelo* 81
Figura 11. *Wireframe del panel ejecutivo* 82
Figura 12. *Wireframe de importación y validación de ventas* 83
Figura 13. *Wireframe del análisis de pronósticos* 84
Figura 14. *Pantalla de acceso* 88
Figura 15. *Centro de control con indicadores, proyección del próximo mes y ventas reales frente a proyectadas* 89
Figura 16. *Registro de ventas con el formulario de nueva venta* 90
Figura 17. *Productos e inventario con el filtro de existencia baja* 91
Figura 18. *Pronóstico de ventas con señales por producto, recomendaciones de reabastecimiento y resultado de la recalibración* 92
Figura 19. *Administración de usuarios y roles* 93

Introducción

La gestión de ventas en el comercio minorista exige decisiones frecuentes sobre abastecimiento, rotación de inventario, promociones, metas comerciales y distribución de productos entre canales. Estas decisiones se vuelven más complejas cuando el catálogo contiene artículos con precios, estacionalidades y velocidades de rotación distintas. En ese contexto, la experiencia del personal continúa siendo valiosa, pero resulta insuficiente cuando los registros históricos crecen y los patrones cambian entre sucursales, temporadas y categorías.

Zorros Revolution Biker comercializa accesorios para motociclistas. Su sitio oficial presenta categorías como cascos, chumpas, guantes y accesorios, además de diferentes ubicaciones y un canal en línea (Zorros Revolution Biker, s. f.). Esta combinación genera un escenario pertinente para aplicar analítica predictiva: la demanda puede variar por producto, talla, diseño, precio, promoción, punto de venta, fecha y canal. Transformar dichos registros en pronósticos comprensibles puede apoyar la planificación comercial y reducir la dependencia de estimaciones exclusivamente manuales.

El presente trabajo propone el diseño de un sistema web basado en inteligencia artificial capaz de integrar históricos de ventas, validar su calidad, construir series temporales y comparar modelos estadísticos y de aprendizaje automático. La propuesta no asume que un algoritmo complejo será siempre superior. En cambio, establece una evaluación contra líneas base, validación temporal con origen móvil y selección del modelo con mejor desempeño para cada nivel de agregación que posea datos suficientes.

El documento desarrolla los entregables de las fases de ideación, análisis y diseño, y el avance de validación técnica y construcción del sistema. El Capítulo I presenta el planteamiento del problema, la justificación, los objetivos, los alcances y límites, y la hipótesis del proyecto. El Capítulo II integra el estado del arte, las bases teóricas sobre pronóstico de ventas minoristas, series de tiempo, aprendizaje automático, demanda intermitente, métricas y explicabilidad, y la definición de términos. El Capítulo III define el tipo y diseño de la investigación, la población y la muestra, las técnicas e instrumentos de recolección de datos y su validación, y la metodología de desarrollo del proyecto.

El Capítulo IV presenta los resultados de la validación técnica del prototipo y la comprobación de la hipótesis; el Capítulo V, el estudio de factibilidad; y el Capítulo VI, el

desarrollo de la solución: tipo de sistema, requerimientos —desde el levantamiento preliminar mediante historias de usuario y casos de uso hasta los del producto mínimo viable—, diseño —incluidos la arquitectura preliminar y tres wireframes de baja fidelidad—, implementación y plan de pruebas.

Capítulo I – Marco Conceptual

1.1 Antecedentes

La planificación de ventas ha evolucionado desde registros manuales y promedios simples hacia sistemas que integran datos transaccionales, variables de calendario, inventario, precio, promociones y comportamiento por canal. Este cambio responde a una necesidad operativa: las empresas deben anticipar la demanda con suficiente oportunidad para comprar, redistribuir y promover productos sin inmovilizar capital innecesario ni provocar faltantes.

En el sector retail, un mismo catálogo puede contener productos de alta rotación, referencias estacionales y artículos con demanda intermitente. Fildes, Ma y Kolassa (2022) señalan que la práctica del pronóstico minorista presenta retos particulares por la cantidad de series, la granularidad de producto y tienda, las promociones y la necesidad de conectar el pronóstico con las decisiones. Por ello, la calidad de un sistema no depende solo de su algoritmo, sino también de la preparación de datos, la selección del nivel de agregación y la forma en que comunica incertidumbre.

La competencia M5 utilizó 42,840 series jerárquicas de ventas minoristas y evidenció la relevancia de los métodos de aprendizaje automático, las variables explicativas y el aprendizaje compartido entre series (Makridakis, Spiliotis y Assimakopoulos, 2022). Sus resultados también muestran que la evaluación debe realizarse fuera de muestra y en varios niveles, ya que el mejor comportamiento agregado no garantiza la misma precisión para cada producto.

En Guatemala, el comercio constituye una actividad empresarial de alta presencia. El Instituto Nacional de Estadística reportó que el comercio al por mayor y menor concentraba 27.7 % de las empresas consideradas en el informe del empleador y que las microempresas predominaban según ingresos y número de trabajadores (INE, 2023). Este contexto hace pertinente el desarrollo de soluciones analíticas que puedan operar con recursos limitados y sin exigir infraestructura de gran escala.

1.1.1 Contexto de Zorros Revolution Biker

Zorros Revolution Biker se presenta públicamente como una tienda de accesorios para motociclistas en Guatemala. Su catálogo web incluye cascos, chumpas, guantes y accesorios, con productos de precios y características diversas. El sitio también muestra ofertas, productos

populares y ubicaciones como Antigua Guatemala, Bosques de San Nicolás, C. C. Metronorte, Cobán, Kiosko Metronorte, canal en línea y San Juan zona 4 (Zorros Revolution Biker, s. f.).

La coexistencia de productos, sucursales y canal digital implica múltiples niveles posibles de análisis: venta total, venta por ubicación, categoría, producto y combinación producto-sucursal. Un sistema predictivo debe reconocer que no todos esos niveles poseen igual densidad de datos. Para productos con pocas transacciones puede ser preferible pronosticar por categoría y distribuir el resultado; para referencias de alta rotación puede ser viable un pronóstico específico por SKU.

El antecedente empresarial concreto debe completarse mediante entrevista con gerencia y revisión del sistema de ventas. Es necesario identificar la fuente real de los datos, periodicidad, existencia de devoluciones, descuentos, transferencias, faltantes de inventario y cambios de catálogo. Estas condiciones determinan qué parte de la demanda observada representa ventas efectivas y qué parte pudo quedar censurada por falta de existencia.

1.1.2 Evolución de los sistemas predictivos de ventas

Los primeros enfoques empresariales se apoyaron en medias móviles, suavizamiento exponencial y modelos ARIMA. Estos métodos continúan siendo líneas base importantes por su bajo costo computacional, interpretabilidad y capacidad para representar tendencia y estacionalidad. Taylor y Letham (2018) propusieron Prophet como un enfoque configurable que combina componentes de tendencia, estacionalidad y eventos, con intervención del analista.

El aprendizaje automático amplió el conjunto de variables utilizables. Los árboles potenciados pueden aprender relaciones no lineales entre rezagos, medias móviles, día de la semana, promociones, precios y atributos de producto. XGBoost incorpora mecanismos eficientes para datos dispersos y regularización, por lo que se ha convertido en una alternativa frecuente para problemas tabulares (Chen y Guestrin, 2016).

Las redes LSTM y los transformadores pueden representar dependencias temporales complejas, pero su utilidad depende del volumen, continuidad y representatividad de los datos. En una empresa con series cortas o intermitentes, un modelo profundo puede sobreajustarse. Por esa razón, el sistema propuesto compara modelos simples y de inteligencia artificial bajo la misma validación temporal, y conserva el modelo más parsimonioso cuando su rendimiento es equivalente.

1.1.3 Brecha identificada

La literatura ofrece métodos avanzados, pero una micro o pequeña empresa necesita algo más que un cuaderno de experimentos. Requiere un flujo reproducible que reciba datos, detecte errores, genere pronósticos, explique los factores principales, registre la versión del modelo y permita comparar lo estimado con lo realmente vendido.

La brecha que orienta este proyecto es la falta de una solución contextualizada para Zorros Revolution Biker que traduzca sus registros históricos en información prospectiva para la gestión comercial. La propuesta busca cubrir esa brecha mediante una aplicación web ligera, un motor de pronóstico evaluable y mecanismos de trazabilidad que no dependan de un científico de datos para cada consulta cotidiana.

1.2 Planteamiento del Problema

La gestión de ventas de una empresa con múltiples productos, ubicaciones y canal digital requiere analizar señales que cambian en el tiempo. Los totales mensuales pueden ocultar que una categoría crece mientras otra disminuye; del mismo modo, una venta baja puede reflejar poca demanda, falta de inventario o un producto recientemente incorporado. Cuando el análisis se realiza únicamente mediante revisión manual, existe riesgo de decisiones tardías o inconsistentes.

El problema central se define como la insuficiente capacidad para transformar de manera sistemática los históricos de ventas de Zorros Revolution Biker en pronósticos verificables, comparables y útiles para la planificación comercial. Esta insuficiencia limita la anticipación de variaciones por fecha, categoría, producto, sucursal o canal, y dificulta medir si una estimación mejora realmente frente a un método sencillo.

La raíz del problema no es solamente algorítmica. Antes de modelar deben resolverse identificadores duplicados, fechas incompletas, cambios de nombre, devoluciones, descuentos, productos sin movimiento y posibles períodos sin inventario. Si esas situaciones se ignoran, el modelo puede aprender patrones que no representan la demanda real y producir una falsa sensación de precisión.

La solución propuesta consiste en un sistema web que reciba datos históricos, aplique reglas de calidad, construya variables temporales y comerciales, compare líneas base con modelos de inteligencia artificial y publique pronósticos acompañados de métricas e información

explicativa. La predicción se plantea como apoyo a la decisión y no como sustitución automática del criterio gerencial.

La formulación deberá ser confirmada mediante entrevista y revisión documental con la empresa. En particular, se validará el proceso actual de planificación, el horizonte que resulta más útil, la granularidad mínima aceptable y las decisiones que se tomarán con el pronóstico.

De este planteamiento se desprende la pregunta de investigación que orienta el resto del documento: ¿en qué medida un sistema web predictivo basado en inteligencia artificial, entrenado y evaluado con los datos históricos de Zorros Revolution Biker, puede mejorar la precisión y oportunidad de la información utilizada para la gestión de ventas frente a los métodos de estimación actualmente empleados?

1.3 Justificación

La investigación se justifica por la necesidad de convertir datos transaccionales en apoyo oportuno para la gestión de ventas. Un pronóstico no elimina la incertidumbre, pero permite hacerla explícita y comparar escenarios. Si la empresa conoce con anticipación qué categorías pueden aumentar o disminuir su demanda, puede priorizar compras, distribución, promociones y seguimiento comercial con mayor fundamento.

Desde la perspectiva académica, el proyecto integra ingeniería de software, inteligencia artificial, bases de datos y gestión empresarial. El valor investigativo reside en evaluar modelos bajo condiciones reales de una empresa guatemalteca, con las restricciones propias de un catálogo minorista, posibles ventas intermitentes y datos históricos que pueden contener inconsistencias.

Desde la perspectiva tecnológica, la solución propone una arquitectura modular y trazable. El sistema separa la carga y validación de datos, la generación de características, el entrenamiento, la evaluación, el almacenamiento de pronósticos y la visualización. Esta separación permite cambiar el algoritmo sin rehacer toda la aplicación y facilita auditar qué datos produjeron una predicción.

Desde la perspectiva empresarial, el sistema puede reducir el tiempo dedicado a consolidar reportes y mejorar la coherencia de las estimaciones entre responsables. También puede advertir sobre alta demanda prevista, baja rotación y divergencias relevantes entre venta real y pronóstico. Estos beneficios deberán medirse durante la prueba piloto; no se asumen como resultados alcanzados en esta fase.

Desde la perspectiva económica, el enfoque utiliza tecnologías de código abierto y puede desplegarse en infraestructura de costo moderado. El mayor esfuerzo se concentra en depurar e integrar los datos, no en licencias. La solución será viable si el beneficio esperado en calidad de decisión y tiempo de análisis justifica el costo total de construcción, operación y mantenimiento.

1.4 Objetivos

1.4.1 Objetivo General

Diseñar y desarrollar un sistema web predictivo basado en inteligencia artificial que procese los datos históricos de Zorros Revolution Biker y genere pronósticos trazables para apoyar la gestión de ventas por período, categoría, producto, sucursal y canal, de acuerdo con la calidad y suficiencia de la información disponible.

1.4.2 Objetivos Específicos

1. Diagnosticar el proceso actual de registro, consolidación y planificación de ventas de Zorros Revolution Biker, incluido el método con que hoy se estiman las ventas, así como las necesidades de información de los usuarios responsables.
2. Desarrollar un sistema web de arquitectura modular que integre los datos históricos con trazabilidad, compare modelos de referencia y de inteligencia artificial mediante validación temporal con origen móvil, publique solo los que superen la línea base acordada y permita consultar pronósticos, métricas y alertas sin exponer datos sensibles innecesarios.
3. Evaluar la mejora en la precisión del pronóstico que aporta el sistema frente al método de estimación vigente en la empresa, mediante la comparación del error escalado en las mismas ventanas de validación y una prueba estadística para muestras relacionadas.

1.5 Alcances y Límites

1.5.1 Ámbito Geográfico

El análisis abarcará las ubicaciones y canales que la empresa autorice y para los cuales existan registros comparables. El sistema web será accesible mediante internet bajo controles de autenticación.

1.5.2 Ámbito Tecnológico

El prototipo incluirá carga de archivos, validación, catálogo mínimo, entrenamiento, comparación de modelos, generación de pronósticos, métricas, explicaciones, alertas y exportación. La integración directa con POS o comercio electrónico quedará preparada como extensión si se dispone de una API.

1.5.3 Ámbito Personal

Los usuarios previstos son gerencia, responsables de ventas, administración, inventario y el administrador técnico. Los datos de clientes no serán necesarios para el pronóstico básico y deberán excluirse o anonimizarse.

1.5.4 Ámbito Temporal

La ventana histórica ideal será de veinticuatro meses o más para observar ciclos anuales; con doce meses se ejecutará un piloto limitado. Los horizontes iniciales serán 7, 14 y 30 días, además de una vista mensual cuando la granularidad lo permita.

1.5.5 Ámbito Temático

El estudio se concentra en pronóstico de ventas, demanda intermitente, calidad de datos, explicación de modelos y soporte a decisiones. Las exclusiones se declaran de forma explícita en la sección 1.5.6.

1.5.6 Límites

Para delimitar con precisión el compromiso del proyecto, se declaran expresamente las exclusiones siguientes:

- No se desarrollan recomendadores de productos, segmentación individual de clientes ni optimización automática de precios.
- No se integra el sistema de forma directa con el punto de venta ni con la tienda en línea de la empresa; la integración queda preparada como extensión mediante la API, sujeta a que la empresa disponga de una interfaz para sus sistemas.
- El sistema no emite facturas ni documentos tributarios: su registro de ventas es interno y no sustituye la factura electrónica en línea de la Superintendencia de Administración Tributaria ni la contabilidad de la empresa.

- Las recomendaciones de reabastecimiento son un insumo para la decisión de compra; el sistema no genera ni envía pedidos a proveedores de forma automática.
- No se tratan datos personales de clientes. Los únicos datos personales que el sistema almacena son el nombre y el correo de los empleados con cuenta de acceso.
- No se construyen modelos de aprendizaje profundo, como LSTM o transformadores, en esta fase; quedan como experimento posterior si los datos demuestran que aportan una mejora estable (sección 2.2.3.2).
- No se desarrollan aplicaciones móviles nativas; el acceso al sistema es mediante navegador web.
- Durante esta fase, la validación técnica del motor de pronóstico se realiza con datos simulados. La evaluación sobre los registros reales de la empresa y la aplicación de los instrumentos dirigidos a personas quedan sujetas al acceso que la empresa autorice en la prueba piloto.

1.6 Hipótesis

El proyecto incorpora un componente investigativo verificable, por lo que la formulación de una hipótesis sí aplica. La pregunta de investigación de la sección 1.2 indaga si el sistema mejora la precisión de la información frente a los métodos de estimación vigentes, y la sección 2.2.5.1 fija un criterio cuantificable para juzgarlo: una reducción de al menos 10 % del error escalado respecto del método de referencia. Ambos elementos conforman una afirmación comprobable, que puede contrastarse con mediciones repetidas del error en varios periodos de prueba (sección 3.1).

Variable independiente: el método de pronóstico, con dos niveles: el modelo de aprendizaje automático que el sistema selecciona y publica, y el método de estimación de referencia.

Variable dependiente: la precisión del pronóstico de ventas, medida mediante el error escalado absoluto medio (MASE) en cada ventana de validación de origen móvil de 30 días (sección 2.3).

Mientras los instrumentos de la sección 3.3 no documenten el procedimiento con que la empresa estima hoy sus ventas, el método vigente se representa con el naïve estacional, que formaliza la regla de estimación más elemental —esperar para cada día lo vendido el mismo día de la semana anterior— y que la sección 2.2.5.1 adopta como referencia del criterio de publicación.

Si la entrevista y la revisión documental identifican un procedimiento distinto, este se incorporará como referencia adicional y se evaluará con el mismo protocolo.

- **Hipótesis de trabajo** (H_1): el modelo de aprendizaje automático publicado por el sistema reduce en más de 10 % el error escalado del pronóstico de ventas respecto del método de referencia, evaluados ambos en las mismas ventanas de validación de origen móvil; es decir, $MASE_{modelo} < 0.90 \times MASE_{referencia}$.
- **Hipótesis nula** (H_0): el modelo no reduce el error escalado en más de 10 % respecto del método de referencia; es decir, $MASE_{modelo} \geq 0.90 \times MASE_{referencia}$.

La hipótesis se contrasta con la prueba t de Student para muestras relacionadas, unilateral y con un nivel de significancia $\alpha = 0.05$, sobre la diferencia entre el error del modelo y el 90 % del error de la referencia en cada ventana; se complementa con la prueba de rangos con signo de Wilcoxon y con el tamaño del efecto (sección 4.3). Se vincula directamente con el objetivo específico 3, que evalúa la mejora frente al método vigente, y con el objetivo específico 2, que incluye el protocolo de comparación y el criterio de aceptación. En esta fase se contrasta sobre datos simulados para validar el procedimiento; su comprobación con los registros de la empresa corresponde a la prueba piloto.

Capítulo II – Marco Teórico

2.1 Estado del Arte

El estado del arte muestra una transición desde un modelo único hacia selección por serie, agrupación de productos, ensambles, aprendizaje global e integración de inventario y comportamiento. También evidencia que los resultados dependen del contexto y no deben transferirse sin validación local.

Estudio	Enfoque	Aporte relevante	Implicación para el proyecto
Makridakis et al. (2022)	Competencia M5; 42,840 series jerárquicas	Comparación a gran escala con variables externas	Evaluar jerarquías, líneas base y modelos globales
Swami et al. (2020)	XGBoost y LSTM para ventas mensuales	XGBoost superó LSTM en un conjunto disperso	No asumir que mayor complejidad produce menor error
Ganzevoort y Van Vuuren (2023)	Selección de modelos basada en clústeres	Reduce opciones mediante características de series	Agrupar productos antes de seleccionar modelos
Zhang et al. (2024)	Transformers para demanda intermitente	Modela ocurrencia y cantidad en series dispersas	Tratar ceros e intermitencia como condición específica
Mejía y Aguilar (2024)	Clústeres, ingeniería de características y ensambles	Mejora frente a una estrategia única	Construir estrategia por tipo de producto
Ganguly y Mukherjee (2024)	Comparación de RF, GB, SVR y XGBoost	Resalta ajuste e ingeniería de variables	Comparar varios modelos bajo el mismo protocolo
Suresh et al. (2026)	Meta-LLSTM con inventario y segmentación	Integra señales operativas y comportamiento	Considerar inventario y adaptación como evolución futura

Tabla 1. *Síntesis del estado del arte en pronóstico de ventas minoristas*

Nota. Elaboración propia.

2.1.1 Posicionamiento de la propuesta

La propuesta no busca crear un algoritmo académico nuevo, sino integrar prácticas probadas en un sistema usable y gobernado para una empresa específica. Su diferenciación se encuentra en el flujo completo: validación de datos, segmentación por comportamiento, comparación con baselines, explicabilidad, control de versiones y visualización orientada a decisiones.

Para el primer ciclo se prioriza un modelo global de árboles potenciados con variables de calendario, rezagos y atributos comerciales, comparado con naïve estacional, suavizamiento y Prophet. Si la densidad lo justifica, se explorarán modelos por clúster y LSTM. La selección final será empírica y no anticipada por preferencia tecnológica.

La revisión del estado del arte confirma que la principal contribución práctica consistirá en conectar la predicción con la gestión de ventas sin perder trazabilidad. El sistema deberá explicar qué datos utilizó, cuánto error ha tenido y cuándo necesita reentrenamiento.

2.2 Bases Teóricas

Las bases teóricas que sustentan la solución se organizan de lo general a lo particular. Primero se aborda la gestión de ventas en el comercio minorista, que define el problema de negocio (sección 2.2.1); luego, los fundamentos del pronóstico de series de tiempo (sección 2.2.2) y los métodos de inteligencia artificial aplicados a él (sección 2.2.3); después, la preparación de datos (sección 2.2.4), la evaluación de pronósticos (sección 2.2.5) y la explicabilidad (sección 2.2.6); y, por último, la arquitectura de los sistemas predictivos (sección 2.2.7), que traslada esos fundamentos a un sistema de información. Cada apartado indica cómo se aplica la teoría en el proyecto.

2.2.1 Gestión de Ventas en el Sector Retail

La gestión de ventas comprende la planificación, ejecución, seguimiento y control de las actividades que convierten la oferta de una empresa en ingresos. En retail, esta gestión se relaciona directamente con el surtido, la disponibilidad, la asignación de inventario, las promociones, la experiencia del cliente y el desempeño por tienda o canal. El pronóstico constituye una entrada para esas decisiones, no un fin aislado.

Una venta observada es el resultado de varios factores: demanda del cliente, existencia disponible, precio, visibilidad del producto, promoción, calendario y capacidad operativa. Por ello, la serie histórica no representa siempre la demanda potencial. Si un artículo se agotó, las unidades vendidas pueden disminuir aunque el interés permanezca alto; este fenómeno se conoce como demanda censurada por inventario.

La gestión basada en datos requiere una definición común de indicadores. Ingreso, unidades, ticket y margen responden preguntas diferentes. Para un sistema predictivo inicial, las unidades vendidas ofrecen una señal más cercana a la demanda física, mientras que el ingreso

incorpora el efecto del precio. Ambos objetivos pueden modelarse, pero deben evaluarse por separado.

2.2.1.1 Jerarquías de venta

Las ventas minoristas se organizan en jerarquías: empresa, canal, sucursal, categoría, subcategoría, producto y variante. Las series superiores suelen ser densas y estables; las inferiores pueden contener numerosos ceros. Un sistema útil debe conservar coherencia entre niveles, de modo que los pronósticos de productos puedan agregarse y compararse con el total de la categoría.

La competencia M5 mostró la complejidad de pronosticar miles de series relacionadas y la importancia del aprendizaje global, donde un modelo utiliza patrones compartidos entre productos y tiendas (Makridakis et al., 2022). Para Zorros Revolution Biker se propone comenzar con los niveles que posean mayor calidad y bajar a SKU-sucursal solo cuando exista suficiente densidad.

2.2.1.2 Estacionalidad, promociones y eventos

La estacionalidad es la repetición de patrones asociados con el calendario. En ventas diarias pueden aparecer efectos de día de la semana, quincena, fin de mes y temporada anual. En Guatemala también pueden influir feriados, Semana Santa, fin de año y actividades vinculadas con la comunidad motociclista. Estos eventos deben representarse mediante variables explícitas y no inferirse únicamente por fecha.

Las promociones modifican temporalmente precio y visibilidad. Si el sistema no conoce su vigencia, puede interpretar el incremento como crecimiento permanente. El diseño de datos debe registrar tipo de promoción, descuento y período. Cuando la información histórica no exista, el modelo debe marcar la limitación y evitar proyecciones excesivamente confiadas.

2.2.1.3 Rotación, sobreinventario y faltantes

Una previsión superior a la demanda real puede contribuir al sobreinventario, inmovilización de capital y obsolescencia; una previsión inferior puede relacionarse con faltantes y pérdida de ventas. Mejía y Aguilar (2024) resaltan que la diversidad de comportamiento entre productos exige modelos adaptados a categorías o grupos de series y no una única fórmula aplicada indiscriminadamente.

El pronóstico no determina por sí mismo cuánto comprar. La decisión requiere tiempo de reposición, inventario disponible, pedidos en tránsito, nivel de servicio y riesgo aceptado. En esta

fase, el sistema mostrará señales de demanda y permitirá exportarlas; una futura extensión podría calcular sugerencias de reposición bajo reglas aprobadas por la empresa.

2.2.1.4 Contexto de micro y pequeñas empresas guatemaltecas

El INE (2023) indica que las microempresas representan la mayor proporción de unidades productivas en el conjunto analizado y que el comercio es la principal rama de actividad. Esta estructura justifica soluciones con bajo costo operativo, despliegue sencillo y capacidad de trabajar con volúmenes moderados de información.

La limitación de recursos no elimina la necesidad de rigor. Al contrario, hace indispensable priorizar datos mínimos, modelos comparables y automatización gradual. Un sistema sobredimensionado puede ser difícil de mantener; uno demasiado simple puede producir conclusiones engañosas. La arquitectura propuesta busca equilibrio entre ambos extremos.

2.2.2 Fundamentos del Pronóstico de Series de Tiempo

Una serie de tiempo es una secuencia ordenada de observaciones. A diferencia de un conjunto tabular independiente, el orden temporal contiene información y restringe la evaluación: el futuro no debe utilizarse para construir variables del pasado. La separación aleatoria de registros produciría fuga de información y una estimación optimista del desempeño.

El objetivo del pronóstico es estimar valores futuros a partir de patrones históricos y variables conocidas o planificadas. Para cada fecha objetivo debe definirse el horizonte, la granularidad, la fecha de corte y la información disponible al momento de emitir la predicción. Sin esta disciplina, dos métricas aparentemente iguales pueden corresponder a escenarios operativos distintos.

2.2.2.1 Componentes de una serie

La tendencia representa un movimiento persistente; la estacionalidad, un patrón que se repite con período conocido; el ciclo, oscilaciones de duración variable; y el componente irregular, variaciones no explicadas. En retail, estos componentes se combinan con promociones, precios, aperturas, productos nuevos y restricciones de inventario.

La descomposición ayuda a diagnosticar si una serie admite un modelo específico o necesita agregación. Una alta proporción de ceros, intervalos largos entre ventas y gran variabilidad de cantidades sugiere demanda intermitente. En ese caso, métricas porcentuales como MAPE pueden ser indefinidas o inestables.

2.2.2.2 Métodos de referencia

El pronóstico naïve utiliza el último valor observado; el naïve estacional repite el valor del ciclo anterior. Las medias móviles reducen ruido y el suavizamiento exponencial asigna mayor peso a observaciones recientes. ARIMA modela dependencias autoregresivas y diferencias. Estos métodos son esenciales como referencia porque un modelo de inteligencia artificial solo agrega valor si los supera de forma consistente.

Prophet representa la serie mediante tendencia, estacionalidades y eventos configurables, con un proceso orientado al analista (Taylor y Letham, 2018). Puede ser útil para series agregadas con ciclos claros, pero no debe asumirse como mejor opción sin comparación fuera de muestra.

2.2.2.3 Demanda intermitente

La demanda intermitente presenta períodos sin venta separados por ocurrencias positivas. En catálogos con múltiples tallas, colores o diseños, esta condición puede ser frecuente. Zhang, Xia y Xie (2024) muestran que incluso modelos profundos requieren enfoques específicos para representar la ocurrencia y magnitud de este tipo de demanda.

Antes de entrenar se calcularán proporción de ceros, intervalo promedio entre demandas y variabilidad de cantidades. Dependiendo del resultado, la serie podrá tratarse con métodos especializados, agregarse temporalmente o integrarse en un modelo global por categoría. Esta decisión será registrada para evitar comparar series incompatibles sin contexto.

2.2.3 Inteligencia Artificial Aplicada al Pronóstico de Ventas

En este proyecto, inteligencia artificial se utiliza como término amplio para métodos capaces de aprender relaciones a partir de datos y producir estimaciones. El componente principal será aprendizaje supervisado: cada observación contiene variables disponibles en una fecha de corte y un valor objetivo futuro. La calidad del resultado depende tanto de las características como del algoritmo.

El aprendizaje automático permite incorporar rezagos, estadísticas móviles, calendario, producto, sucursal, canal, precio y promociones. Sin embargo, también puede amplificar sesgos, memorizar anomalías o depender de variables que no estarán disponibles en producción. Por ello, el sistema debe controlar fuga de información y almacenar el conjunto exacto de características utilizado por cada versión.

2.2.3.1 Árboles de decisión y ensambles

Los árboles dividen el espacio de variables mediante reglas. Random Forest combina múltiples árboles entrenados con muestras y subconjuntos de variables; Gradient Boosting construye árboles secuenciales que corrigen errores previos. Estos modelos trabajan bien con datos tabulares, interacciones no lineales y variables de distinta naturaleza.

XGBoost es un sistema de potenciación de árboles escalable con regularización y tratamiento eficiente de datos dispersos (Chen y Guestrin, 2016). Para ventas, puede aprender que el efecto de una promoción depende de la categoría, el día y los rezagos. Su principal riesgo es sobreajustar si se usan demasiadas variables o si la validación temporal es insuficiente.

2.2.3.2 Redes neuronales recurrentes y LSTM

Las redes recurrentes procesan secuencias manteniendo un estado; LSTM incorpora compuertas para conservar información relevante durante intervalos más largos. Suresh, Suresh y Kang (2026) proponen una variante meta-LLSTM para pronóstico minorista que integra ventas, segmentación e inventario, lo que evidencia la tendencia hacia modelos adaptativos y multifuente.

No obstante, los modelos profundos requieren más datos, ajuste y monitoreo. Para una empresa con histórico limitado se considerarán como experimento posterior o para series globales suficientemente densas. La primera versión priorizará modelos interpretables y ensambles de árboles, sin excluir LSTM si los datos demuestran que aporta mejora estable.

2.2.3.3 Modelos globales, segmentación y ensambles

Un modelo local se entrena para una sola serie; uno global aprende de muchas series e incluye identificadores o atributos. En catálogos amplios, el modelo global puede transferir patrones de productos con mayor historia a referencias con menos observaciones. La competencia M5 impulsó este enfoque para grandes jerarquías minoristas (Makridakis et al., 2022).

Mejía y Aguilar (2024) proponen agrupar productos según características de sus series y evaluar modelos por grupo. Esta idea es pertinente para Zorros Revolution Biker: cascos populares pueden comportarse distinto de accesorios ocasionales. El sistema podrá clasificar series por densidad, tendencia, estacionalidad y variabilidad antes de seleccionar la estrategia de pronóstico.

2.2.4 Preparación de Datos y Construcción de Características

La preparación comienza con un contrato de datos que define campos, tipos, reglas y claves. Cada carga debe conservar el archivo original, un identificador, fecha, usuario y reporte de

errores. Las filas rechazadas no deben desaparecer silenciosamente; deben quedar disponibles para corrección.

Las reglas mínimas incluyen fecha válida, SKU no vacío, cantidad numérica, precio no negativo, sucursal reconocida y ausencia de duplicados según la clave acordada. Devoluciones y anulaciones se representarán con un tipo de movimiento o cantidades negativas, no se eliminarán sin criterio empresarial.

Las características temporales incluirán día de semana, semana, mes, quincena, fin de mes, feriados, rezagos y medias móviles calculadas únicamente con fechas anteriores. Las características comerciales incluirán categoría, sucursal, canal, precio, descuento, antigüedad del producto e inventario cuando esté disponible.

Grupo	Ejemplos	Propósito
Calendario	día, semana, mes, quincena, feriado	Representar ciclos y eventos
Rezagos	t−1, t−7, t−14, t−28	Capturar dependencia temporal
Ventanas	media, mediana y desviación móvil	Resumir nivel y volatilidad reciente
Comerciales	precio, descuento, promoción, canal	Explicar cambios gestionables
Producto	categoría, marca, talla, antigüedad	Compartir información entre artículos
Inventario	existencia, días sin stock	Distinguir demanda de disponibilidad

Tabla 2. *Características candidatas para el modelo predictivo*

Nota. Elaboración propia.

2.2.5 Evaluación de Pronósticos

La evaluación se realizará con ventanas temporales ordenadas. En cada corte, el modelo se entrena con el pasado y predice el horizonte siguiente. El origen avanza y el proceso se repite. Esta validación de origen móvil aproxima el uso real y permite observar estabilidad en varios períodos.

Hyndman y Koehler (2006) advierten limitaciones de varias métricas porcentuales y proponen errores escalados. Por ello, MASE será una métrica principal junto con WAPE para interpretación empresarial. MAE y RMSE se reportarán como complementarias; MAPE solo se mostrará en series donde el denominador no produzca distorsiones.

Métrica	Uso	Precaución
MAE	Error absoluto promedio en unidades o quetzales	Depende de la escala

Métrica	Uso	Precaución
RMSE	Penaliza errores grandes	Puede ser dominada por atípicos
WAPE	Error absoluto total relativo al volumen	Debe segmentarse para no ocultar series pequeñas
MASE	Compara el error con una línea base naïve	Requiere escala histórica válida
sMAPE	Comparación porcentual simétrica	Inestable cerca de cero
Sesgo	Indica sobre o subestimación sistemática	No mide magnitud total del error

Tabla 3. *Métricas propuestas para evaluar los pronósticos*

Nota. Elaboración propia.

2.2.5.1 Criterio de selección

Un modelo candidato será publicable si supera la línea base acordada en la métrica primaria, no presenta sesgo inaceptable y mantiene desempeño consistente en la mayoría de las ventanas. La mejora mínima se definirá con la empresa; como criterio técnico inicial se propone una reducción de al menos 10 % del error escalado respecto al naïve estacional, sujeta a revisión según el tamaño de la muestra.

Si ningún modelo supera la referencia, el sistema publicará el baseline y documentará el resultado. Esta decisión evita presentar complejidad como sinónimo de valor y conserva una ruta segura para iterar sobre datos y características.

2.2.6 Explicabilidad, Incertidumbre y Confianza

La predicción debe acompañarse de intervalo, fecha de generación, horizonte, modelo, versión y métricas recientes. Un valor puntual sin contexto puede interpretarse como certeza. El sistema mostrará rangos cuando el método los produzca y advertirá sobre series con poco historial o alta volatilidad.

SHAP asigna contribuciones a las variables de una predicción y permite explicar modelos complejos con un marco aditivo (Lundberg y Lee, 2017). En la interfaz se mostrarán factores de alto nivel, por ejemplo tendencia reciente, fin de semana o promoción, evitando exponer detalles técnicos innecesarios. La explicación no implica causalidad; indica cómo el modelo utilizó la información.

La confianza operacional también depende de la frescura de datos. Si la última carga está incompleta o atrasada, el sistema debe impedir o etiquetar el pronóstico. La gobernanza de datos es, por tanto, parte del sistema predictivo y no una actividad separada.

2.2.7 Arquitectura de Sistemas Predictivos

Un sistema predictivo en producción combina almacenamiento, procesamiento, servicios, interfaz y monitoreo. El modelo entrenado debe estar versionado junto con sus variables, métricas, fecha de corte y conjunto de datos. La API no debe cargar un archivo arbitrario sin validar que su contrato coincide con el esperado.

La arquitectura propuesta para este proyecto, que desarrolla la sección 6.3, separa el servicio de datos y el servicio predictivo de la interfaz web. PostgreSQL almacena ventas normalizadas, ejecuciones y pronósticos; un repositorio de artefactos conserva modelos; la API autentica y orquesta; y el frontend presenta resultados. Esta separación facilita pruebas, mantenimiento y reemplazo gradual de componentes.

2.3 Definición de Términos

Los términos siguientes se emplean a lo largo del documento con el significado que aquí se precisa. Se presentan en orden alfabético; para cada uno se da su definición conceptual y, cuando el término se mide o se concreta en el sistema, su definición operacional.

ADI (intervalo promedio entre demandas). Promedio de periodos que transcurren entre dos ocurrencias de demanda positiva; junto con el CV^2, permite clasificar el patrón de demanda de una serie (Syntetos, Boylan y Croston, 2005). Operacionalmente, es el número de días observados de un producto, contados desde su primera venta, dividido entre el número de días en que registró ventas: un ADI de 5 indica, en promedio, un día con venta de cada cinco.

Árboles potenciados por gradiente. Técnica de aprendizaje automático que construye árboles de decisión de forma secuencial, de modo que cada árbol corrige el error residual de los anteriores (Friedman, 2001). Operacionalmente, es el modelo candidato del sistema: el regresor de árboles potenciados de scikit-learn, con hiperparámetros fijos y registrados en cada ejecución, que pronostica el total diario de ventas a partir de variables de calendario, rezagos y medias móviles.

Criterio de publicación. Regla de aceptación que determina si un modelo candidato reemplaza al modelo vigente (sección 2.2.5.1). Operacionalmente, el sistema publica el modelo de aprendizaje automático solo si cumple tres condiciones en la validación de origen móvil: su MASE medio es al menos 10 % menor que el del naïve estacional, su sesgo relativo no excede el 20 % y obtiene un MASE menor que el de la referencia en más de la mitad de las ventanas.

CV^2 (coeficiente de variación al cuadrado). Medida de la variabilidad del tamaño de la demanda, igual al cuadrado del cociente entre la desviación estándar y la media (Syntetos, Boylan y Croston, 2005). Operacionalmente, se calcula solo sobre las cantidades vendidas en los días con venta, de modo que mide la dispersión del tamaño de cada venta y no la de la serie con sus días en cero.

Datos simulados. Registros generados artificialmente para reproducir propiedades conocidas de un fenómeno cuando los datos reales no están disponibles. Operacionalmente, son las transacciones de doce meses producidas por el simulador del sistema (sección 4.1.2), que no comparte funciones con las variables del modelo; sirven exclusivamente para validar el procedimiento técnico, y ninguna cifra obtenida con ellos describe la operación de la empresa.

Demanda censurada. Parte de la demanda que no se convierte en venta porque la falta de existencia impide atender al cliente, de modo que las ventas registradas subestiman la demanda potencial (sección 2.2.1). Operacionalmente, en el simulador son las unidades demandadas que no se vendieron por falta de existencia; en los registros reales no es observable de forma directa, por lo que el modelo de datos conserva la existencia y sus movimientos para identificar los periodos sin inventario.

Demanda intermitente. Patrón de demanda con periodos frecuentes sin venta, separados por ocurrencias positivas de tamaño variable (Croston, 1972; Syntetos, Boylan y Croston, 2005). Operacionalmente, la serie diaria de un producto se clasifica como intermitente cuando su ADI es mayor o igual que 1.32 y su CV^2 menor que 0.49; con ADI mayor o igual que 1.32 y CV^2 mayor o igual que 0.49 se clasifica como grumosa, y con ADI menor que 1.32, como regular o errática según el mismo corte del CV^2.

Fuga de información. Uso, al construir o evaluar un modelo, de información que no estaría disponible en el momento de emitir el pronóstico, lo que produce una estimación optimista de su desempeño (Bergmeir y Benítez, 2012). Operacionalmente, el sistema la evita desplazando un periodo todos los rezagos y medias móviles, de modo que ninguna característica del día t utiliza datos de t o posteriores, y reentrenando cada candidato solo con el pasado de cada ventana de validación.

Horizonte de pronóstico. Número de periodos futuros para los que se emite una predicción a partir de una fecha de corte (Hyndman y Athanasopoulos, 2021). Operacionalmente,

la evaluación de modelos utiliza un horizonte de 30 días, el mismo que consume el centro de control; la consulta de pronósticos admite horizontes de 7, 30, 90 y 180 días.

Línea base. Método de pronóstico simple contra el cual se mide si un modelo más complejo agrega valor; también se denomina método de referencia (Hyndman y Athanasopoulos, 2021). Operacionalmente, el sistema evalúa seis líneas base: naïve, naïve estacional de periodo 7, media móvil, suavizamiento exponencial simple, Holt-Winters aditivo y ARIMA(1,1,1).

MASE (error escalado absoluto medio). Métrica que divide el error absoluto medio de un pronóstico entre el error absoluto medio de un método naïve dentro de la muestra de entrenamiento, lo que la hace comparable entre series de distinta escala (Hyndman y Koehler, 2006). Operacionalmente, es el error absoluto medio del pronóstico en cada ventana de 30 días dividido entre el del naïve estacional de periodo 7 calculado sobre el conjunto de entrenamiento de esa ventana; un valor menor que 1 indica un error inferior al de esa referencia. Es la métrica primaria del sistema y la variable dependiente de la hipótesis (sección 1.6).

MVP (producto mínimo viable). Versión de un producto con la funcionalidad mínima necesaria para que sus usuarios lo utilicen y lo evalúen. Operacionalmente, es la versión del sistema desplegada en esta fase, cuyas funciones se identifican con el estado «Implementado» en la Tabla 34.

Naïve estacional. Método que pronostica cada periodo con el valor observado en el mismo punto del ciclo anterior (Hyndman y Athanasopoulos, 2021). Operacionalmente, con un ciclo semanal, el pronóstico de cada día es la venta del mismo día de la semana anterior. Es la referencia del criterio de publicación y, mientras no se documente el método vigente de la empresa, la del contraste de la hipótesis.

Punto de reorden. Nivel de existencia en el que debe emitirse un pedido para que la mercadería llegue antes de agotarse. Operacionalmente, es la demanda diaria media de los últimos 60 días —incrementada en 40 % cuando un evento de temporada cae dentro del tiempo de importación— multiplicada por la suma del tiempo de importación del producto y diez días de seguridad.

Recalibración. Proceso mediante el cual el sistema reentrena, evalúa y, si corresponde, publica una nueva versión del modelo. Operacionalmente, comprende la evaluación de los siete candidatos en cinco ventanas de origen móvil, la aplicación del criterio de publicación y el registro de la ejecución con sus métricas y su decisión (Figura 10).

Sesgo del pronóstico. Error medio con signo, que indica si un método tiende a sobreestimar o a subestimar. Operacionalmente, es el promedio del pronóstico menos la venta real, en quetzales por día: un valor negativo indica subestimación. El sesgo relativo, que utiliza el criterio de publicación, es su valor absoluto dividido entre la venta diaria media del periodo evaluado.

SHAP (explicaciones aditivas de Shapley). Método que asigna a cada variable de entrada una contribución al valor de una predicción, de modo que la suma de las contribuciones explica la diferencia respecto del valor medio (Lundberg y Lee, 2017). Operacionalmente, es el mecanismo previsto para mostrar los factores principales de cada pronóstico (requerimiento RF-12); el MVP aún no lo implementa, de modo que el sistema muestra la versión del modelo y sus métricas, pero no factores explicativos.

Validación de origen móvil. Procedimiento de evaluación de series de tiempo en el que el origen del pronóstico avanza de forma sucesiva: en cada corte, el modelo se entrena con el pasado y se evalúa sobre el periodo siguiente (Tashman, 2000). Operacionalmente, el sistema utiliza cinco ventanas consecutivas de 30 días con un mínimo de 60 días de entrenamiento; en cada ventana, todos los candidatos se reentrenan con el historial anterior al corte y pronostican los 30 días siguientes.

WAPE (error porcentual absoluto ponderado). Suma de los errores absolutos dividida entre la suma de los valores reales, expresada en porcentaje; a diferencia del error porcentual medio, no se indefine en los días sin venta y pondera el error según el volumen. Operacionalmente, se calcula sobre cada ventana de 30 días y se reporta como indefinido, no como cero, cuando el periodo no tuvo ventas.

Capítulo III – Marco Metodológico

3.1 Tipo y Diseño de Investigación

La investigación tendrá enfoque mixto con predominio cuantitativo. La parte cuantitativa comprende perfilamiento de datos, construcción de series, entrenamiento, validación temporal y comparación de métricas. La parte cualitativa comprende entrevistas, observación del proceso y pruebas de uso para entender decisiones y utilidad percibida.

Por su finalidad, la investigación es aplicada, porque busca resolver una necesidad concreta mediante un artefacto de software. Su alcance inicial es descriptivo y correlacional: describe el proceso y los datos, y examina relaciones predictivas sin manipular deliberadamente las condiciones comerciales.

El diseño es no experimental y longitudinal retrospectivo para el componente histórico, dado que se observan ventas registradas a lo largo del tiempo. La validación piloto tendrá un componente pre y post limitado para medir tiempo de preparación y experiencia de uso, sin afirmar causalidad más allá del contexto observado.

Para contrastar la hipótesis de la sección 1.6, el diseño incorpora un componente comparativo: el modelo de aprendizaje automático y el método de referencia se evalúan sobre las mismas ventanas de validación de origen móvil, de modo que sus errores forman observaciones emparejadas que se comparan mediante una prueba estadística para muestras relacionadas (sección 4.3). Esta comparación no requiere intervenir en la operación de la empresa, porque se realiza sobre los registros históricos y con el mismo protocolo para ambos métodos.

3.1.1 Unidad de Análisis

La unidad cuantitativa será una observación de venta agregada por fecha y nivel comercial autorizado. El nivel base preferente es producto-sucursal-día; si los datos no permiten estimación estable, la unidad se elevará a producto-total, categoría-sucursal o categoría-total.

La unidad cualitativa será el participante relacionado con gestión de ventas, administración, inventario o tecnología. No se investigará a clientes individuales ni se utilizarán datos personales para el modelo inicial.

3.2 Población y Muestra

3.2.1 Población

La población cuantitativa estará constituida por todas las transacciones de venta incluidas en el período autorizado, junto con catálogo, sucursales, canales, promociones e inventario cuando existan. La población cualitativa estará constituida por personas que participan en planificación, venta, administración, inventario y soporte técnico.

El marco poblacional se documentará después de la extracción inicial. Se reportarán fechas mínima y máxima, número de transacciones, productos, sucursales, canales y campos disponibles, sin divulgar información confidencial.

3.2.2 Muestra

Para el componente cuantitativo se propone un censo de registros válidos dentro de la ventana histórica, porque excluir observaciones temporales puede alterar estacionalidad. Los períodos finales se reservarán para validación y prueba mediante cortes ordenados.

Para el componente cualitativo se utilizará muestra intencional de entre cinco y ocho participantes con roles distintos, sujeta al tamaño real del equipo. Se buscará representación de gerencia, ventas, inventario, administración y tecnología. Los resultados se presentarán por rol y sin atribuciones personales innecesarias.

3.3 Técnicas e Instrumentos de Recolección de Datos

3.3.1 Entrevista Semiestructurada

Se aplicará una guía a responsables de negocio para conocer el proceso actual, las decisiones apoyadas por los reportes, los horizontes requeridos, las excepciones, los criterios de confianza y las expectativas de la interfaz.

3.3.2 Cuestionario de Usabilidad

Después de presentar los wireframes se utilizará un cuestionario breve con escala Likert de cinco puntos sobre facilidad, claridad, utilidad, confianza y disposición de uso. Se complementará con tareas observables para evitar depender solo de percepción.

3.3.3 Observación Directa

Se observará una sesión real de preparación o revisión de ventas, registrando fuentes consultadas, pasos, duración, retrabajo y puntos de decisión. No se registrarán datos personales de clientes.

3.3.4 Revisión Documental

Se revisarán reportes de ventas, diccionario de campos, catálogo, políticas de promociones y documentación del sistema transaccional. La revisión confirmará definiciones y evitará interpretar nombres de columnas sin contexto.

3.3.5 Ficha de Perfilamiento de Datos

La ficha registrará tipo, rango, nulos, duplicados, valores inválidos, cardinalidad, cobertura y reglas de corrección por campo. A partir de esta ficha se elaborará el diccionario mínimo de datos autorizado por la empresa.

3.3.6 Procedimiento de Recolección de Datos

La recolección se ejecutará con autorización de la empresa y sin incorporar información personal innecesaria. Cada instrumento producirá una evidencia identificable —acta, guía respondida, ficha de observación o reporte de perfilamiento— para conservar trazabilidad entre la necesidad expresada y el requerimiento resultante.

1. Acordar con gerencia el período, las fuentes, los responsables y los campos autorizados para la muestra de ventas.
2. Aplicar entrevistas semiestructuradas y observar una sesión de preparación o análisis de ventas, registrando decisiones, tiempos y excepciones.
3. Recibir una exportación controlada en CSV o XLSX, crear el diccionario de datos y verificar tipos, nulos, duplicados, claves, devoluciones y cobertura temporal.
4. Contrastar los hallazgos con los usuarios responsables y documentar correcciones, reglas de negocio y niveles de agregación aprobados.
5. Almacenar la muestra en un entorno restringido, conservar la trazabilidad de sus transformaciones y presentar los resultados sin revelar información confidencial.

3.4 Validación del Instrumento

Antes de su aplicación definitiva, cada instrumento de la sección 3.3 se somete a un procedimiento de validación acorde con su tipo, con el fin de comprobar que mide lo que pretende medir (validez) y que lo hace de manera consistente en aplicaciones repetidas (confiabilidad). La Tabla 4 resume el procedimiento previsto para cada instrumento.

Instrumento	Validez	Confiabilidad	Criterio de aceptación
Guía de entrevista semiestructurada (3.3.1)	Juicio de tres expertos sobre claridad, pertinencia y coherencia de cada pregunta	Prueba piloto con personas de perfil similar, no incluidas en la muestra	V de Aiken ≥ 0.80 en cada pregunta
Cuestionario de usabilidad con escala Likert (3.3.2)	Juicio de tres expertos	Prueba piloto y alfa de Cronbach	V de Aiken ≥ 0.80 en cada ítem; $\alpha \geq 0.70$
Guía de observación directa (3.3.3)	Juicio de tres expertos	Registro simultáneo por dos observadores y contraste de sus anotaciones	V de Aiken ≥ 0.80 en cada aspecto observado
Lista de cotejo para la revisión documental (3.3.4)	Juicio de tres expertos	Verificación de la lista con la gerencia antes de aplicarla	V de Aiken ≥ 0.80 en cada elemento
Ficha de perfilamiento de datos (3.3.5)	Pruebas automatizadas contra valores calculados a mano	Repetibilidad del cálculo con los mismos datos	Todas las pruebas aprobadas

Tabla 4. *Procedimiento de validación previsto para cada instrumento de recolección de datos*

Nota. Elaboración propia a partir de Hernández Sampieri, Fernández Collado y Baptista Lucio (2014).

3.4.1 Juicio de expertos

La validez de contenido de la guía de entrevista, el cuestionario de usabilidad, la guía de observación y la lista de cotejo documental se verifica mediante el juicio de tres expertos con perfiles complementarios: un ingeniero en sistemas con experiencia en desarrollo de software o en analítica de datos, un profesional del área comercial o de inventarios del comercio minorista y un docente de metodología de la investigación. Cada experto recibe un formato de validación en el que califica cada ítem de 1 a 4 en claridad, pertinencia y coherencia con el objetivo o la variable

que mide, y anota sus observaciones (Hernández Sampieri, Fernández Collado y Baptista Lucio, 2014).

El grado de acuerdo entre los expertos se cuantifica con el coeficiente V de Aiken (1985), que varía entre 0 y 1 y se calcula como $V = S / [n (c - 1)]$, donde S es la suma, sobre los jueces, de la diferencia entre la calificación asignada y el valor mínimo de la escala; n, el número de jueces, y c, el número de valores de la escala. Con tres jueces y una escala de 1 a 4, un ítem calificado con 4, 4 y 3 obtiene $V = (3 + 3 + 2) / (3 \times 3) = 0.89$. Se conservan los ítems con $V \geq 0.80$ en los tres criterios; los demás se reformulan según las observaciones y se someten a una segunda ronda, o se eliminan si no alcanzan el umbral.

3.4.2 Prueba piloto y confiabilidad

Una vez incorporados los ajustes del juicio de expertos, la guía de entrevista y el cuestionario de usabilidad se aplican a un grupo piloto con características similares a las de la muestra, pero no incluido en ella: personal de ventas o de administración de otro comercio minorista. Como la muestra cualitativa es de cinco a ocho participantes (sección 3.2.2), el 10 % a 15 % que suele recomendarse equivaldría a menos de una persona; por ello, el grupo piloto se fija en un mínimo de tres personas. En la prueba se registran el tiempo de aplicación, las preguntas que generan dudas o respuestas ambiguas y las tareas del cuestionario que no se comprenden, y cada problema detectado da lugar a un ajuste documentado del instrumento.

La confiabilidad del cuestionario de usabilidad se estima con el alfa de Cronbach (1951) sobre sus ítems Likert y se considera aceptable a partir de 0.70. Con un grupo piloto tan reducido, el valor obtenido en el piloto se interpreta solo como un indicador preliminar; el coeficiente se recalcula con las respuestas de la aplicación definitiva y se reporta junto con su interpretación.

3.4.3 Validación de los instrumentos técnicos

La ficha de perfilamiento de datos y los registros de evaluación de modelos no dependen del juicio de un informante, sino de cálculos que realiza el sistema, por lo que su validación es técnica. Su validez se verifica con pruebas automatizadas que comparan cada estadístico y cada métrica con valores calculados a mano fuera del código que se prueba (casos CP-07 a CP-11 de la Tabla 46), y su confiabilidad, con la repetibilidad: el mismo conjunto de datos y la misma semilla producen siempre el mismo perfil y las mismas métricas.

3.4.4 Registro de resultados y ajustes

Los formatos de validación completados, la V de Aiken de cada ítem, el alfa de Cronbach y la lista de ajustes realizados a cada instrumento se documentarán y se incluirán como anexos del documento final, junto con la versión definitiva de cada instrumento. A la fecha de este informe, los instrumentos técnicos están validados y los instrumentos dirigidos a personas están diseñados; su validación es requisito previo para aplicarlos en la prueba piloto (Tabla 6).

3.5 Metodología de Desarrollo del Proyecto

La metodología de desarrollo define cómo se construye el producto de software y es independiente de la metodología de investigación de la sección 3.1: aquella determina cómo se obtienen y analizan los datos; esta, cómo se organiza el trabajo técnico del equipo.

3.5.1 Selección del marco de trabajo

Se contrastaron dos enfoques. El modelo en cascada organiza el desarrollo en fases secuenciales —requerimientos, diseño, construcción, pruebas e implantación— y conviene cuando los requerimientos son estables y están definidos desde el inicio (Sommerville, 2016). Scrum organiza el trabajo en iteraciones de duración fija, llamadas sprints, que producen incrementos utilizables y permiten ajustar el backlog con la retroalimentación del cliente (Schwaber y Sutherland, 2020).

Las condiciones del proyecto favorecen el enfoque ágil. Los requerimientos no podían fijarse al inicio: el levantamiento preliminar debía validarse con la empresa (sección 6.2.2), y durante la construcción surgieron requerimientos que no figuraban en el backlog, como la administración de cuentas y el registro de ventas en el propio sistema (sección 6.2.3). El motor de pronóstico exige, además, experimentar y medir antes de comprometer un diseño, lo que se ajusta a ciclos cortos con un resultado verificable. Por estas razones se adoptó Scrum, adaptado a un equipo de tres integrantes con dedicación parcial.

3.5.2 Roles del equipo

- **Product Owner:** la gerencia de Zorros Revolution Biker, que representa al negocio, valida el backlog y acepta los incrementos. Mientras no se dispone de acceso a la empresa, un integrante del equipo actúa como Product Owner delegado: prioriza el backlog a partir del

planteamiento del problema y de los objetivos, y deja las decisiones de negocio sujetas a la validación de la gerencia en la prueba piloto.

- **Scrum Master:** Elder Estuardo Garcia Pacheco, quien facilita los eventos del sprint, da seguimiento a los impedimentos y vela por que cada cambio cumpla la definición de terminado.
- **Equipo de desarrollo:** Gabriel Enrique Pérez Meza y Luis Pedro Ordoñez Chutan, junto con el Scrum Master. El equipo es multifuncional y comparte el análisis, la construcción del sistema y del motor de pronóstico, las pruebas y la documentación.

3.5.3 Eventos, artefactos y definición de terminado

Cada sprint dura dos semanas, de modo que el semestre de dieciséis semanas comprende ocho sprints. Cada uno inicia con una planificación en la que el equipo selecciona los elementos del backlog y fija la meta del sprint, y cierra con una revisión del incremento y una retrospectiva. Por la dedicación parcial del equipo, la reunión diaria se sustituye por una sincronización breve por mensajería y por reuniones virtuales cuando un impedimento lo requiere.

El backlog del producto parte de las historias de usuario del levantamiento preliminar (sección 6.2.2) y se gestiona como incidencias del repositorio. Un elemento se considera terminado cuando su código está en una rama propia, cuenta con pruebas automatizadas que se aprueban, fue revisado e integrado mediante un pull request y puede desplegarse con un comando reproducible; en el caso de los entregables documentales, cuando quedan integrados en el documento del proyecto.

3.5.4 Sprints y vinculación con los objetivos

La Tabla 5 presenta los sprints, su entregable principal y el objetivo específico que atiende cada uno. Los sprints 3 a 6 agrupan las iteraciones de construcción descritas en la sección 6.4.2 (Tabla 45); los sprints 7 y 8 corresponden a la prueba piloto con la empresa.

Sprint (semanas)	Entregable principal	Objetivo específico	Estado
1 (1 y 2)	Antecedentes, planteamiento del problema, objetivos y diseño de los instrumentos de recolección	1	Completado
2 (3 y 4)	Backlog inicial con historias de usuario, requerimientos preliminares, arquitectura, modelo	2	Completado

Sprint (semanas)	Entregable principal	Objetivo específico	Estado
	de datos y prototipos de baja fidelidad		
3 (5 y 6)	Auditoría de alineación, corrección de defectos críticos y despliegue en contenedores con PostgreSQL (iteraciones 1 a 4)	2	Completado
4 (7 y 8)	Perfilamiento de series, líneas base, validación de origen móvil, métricas y criterio de publicación (iteraciones 5 y 6)	2	Completado
5 (9 y 10)	Administración de usuarios y roles, y rediseño de la interfaz (iteraciones 7 y 8)	2	Completado
6 (11 y 12)	Simulador de ventas, validación técnica, comprobación de la hipótesis sobre datos simulados y manual de usuario (iteraciones 9 y 10)	2 y 3	Completado
7 (13 y 14)	Importador de históricos con validación y trazabilidad de cargas; validación de los instrumentos y diagnóstico del proceso actual en la empresa	1 y 2	Planificado
8 (15 y 16)	Prueba piloto con los registros reales: evaluación frente al método vigente, cuestionario de usabilidad y ajustes	3	Planificado

Tabla 5. *Sprints del proyecto, entregable principal y objetivo específico que atiende cada uno*

Nota. Elaboración propia.

3.5.5 Herramientas de gestión y seguimiento

La gestión y el seguimiento del proyecto se apoyan en GitHub: el backlog se registra como incidencias del repositorio, cada cambio se desarrolla en una rama propia y se integra mediante un pull request revisado, y el historial de cambios sirve de evidencia verificable de cada incremento. La comunicación del equipo se realiza por WhatsApp para la sincronización diaria y por Google Meet o Microsoft Teams para la planificación, la revisión y la retrospectiva de cada sprint. Las herramientas de construcción del sistema —Python, FastAPI, pytest y Docker Compose, entre otras— se describen en la sección 6.4.1 (Tabla 44).

Capítulo IV – Presentación y Análisis de Resultados

Este capítulo presenta los datos obtenidos durante la fase de validación técnica del sistema y los interpreta en relación con el problema, los objetivos específicos y las bases teóricas del Capítulo II. Conviene delimitar desde el inicio su alcance: durante esta fase no se dispuso de acceso a los registros históricos de Zorros Revolution Biker, por lo que los instrumentos de recolección de carácter cualitativo definidos en el Capítulo III —entrevista semiestructurada, cuestionario de usabilidad y observación directa— quedan en estado de diseño, listos para su aplicación en la fase de prueba piloto. Los resultados que aquí se reportan provienen del componente cuantitativo: la ficha de perfilamiento de datos y los registros de evaluación que el propio sistema genera al comparar los modelos de pronóstico.

Los datos sobre los que operó el sistema son **simulados**. No representan ventas de la empresa y ninguna cifra de este capítulo debe leerse como un hallazgo sobre su operación. Lo que la simulación permite validar es el procedimiento: que el motor de pronóstico calcula las métricas correctas, compara los candidatos bajo el protocolo exigido por el marco teórico y aplica el criterio de publicación tal como fue diseñado. En cada tabla se indica explícitamente esta procedencia.

4.1 Presentación de resultados

4.1.1 Estado de aplicación de los instrumentos

La Tabla 6 resume qué instrumentos del Capítulo III se aplicaron en esta fase y cuáles quedan pendientes, con el motivo.

Instrumento (Cap. III)	Estado	Observación
3.3.1 Entrevista semiestructurada	Diseñado, no aplicado	Requiere acceso a la gerencia de la empresa; programado para la prueba piloto
3.3.2 Cuestionario de usabilidad (Likert)	Diseñado, no aplicado	Se aplicará sobre el MVP desplegado, con las tareas observables del RNF-05
3.3.3 Observación directa	No aplicado	Requiere una sesión de preparación de ventas en la empresa
3.3.4 Revisión documental	Parcial	Se revisó la información pública de la empresa; no se accedió a reportes internos
3.3.5 Ficha de perfilamiento de datos	Aplicada sobre datos simulados	El sistema calcula el perfil de cada serie de forma automática (sección 4.1.3)
Registros del sistema (evaluación de modelos)	Aplicados sobre datos simulados	Métricas, ventanas de validación y decisión de publicación (secciones 4.1.5 a 4.1.7)

Tabla 6. *Estado de aplicación de los instrumentos de recolección de datos*

Nota. Elaboración propia.

4.1.2 Naturaleza de los datos utilizados

Para validar el sistema se construyó un simulador de ventas que genera doce meses de transacciones sobre el catálogo de 25 productos del prototipo. El simulador se diseñó para reproducir las propiedades que el marco teórico identifica como determinantes en el comercio minorista de accesorios: demanda intermitente por producto (Syntetos, Boylan y Croston, 2005), estacionalidad ligada al calendario guatemalteco (quincenas, Bono 14, aguinaldo, Caravana del Zorro y feriados), promociones de corta duración y, de manera central, la demanda censurada por inventario descrita en la sección 2.2.1: cuando un producto se agota, la venta se pierde y no queda registrada.

Un requisito de diseño del simulador fue no compartir ninguna función con las variables que el modelo recibe como entrada. Un generador que use las mismas funciones de calendario que las características del modelo le entrega la respuesta por construcción, y cualquier métrica obtenida resulta circular. La sección 4.1.7 presenta el efecto medido de esta decisión. El conjunto resultante se resume en la Tabla 7.

Característica	Valor
Periodo	18 de septiembre de 2025 al 18 de septiembre de 2026 (366 días)
Productos con ventas	25

Característica	Valor
Tickets registrados	1,607
Unidades vendidas	2,492
Unidades demandadas no atendidas por falta de existencia	424 (14.5 % de la demanda simulada)
Días con al menos una venta	359 de 366
Ingreso total simulado	Q 1,610,560
Ticket promedio simulado	Q 1,002.22

Tabla 7. *Características del conjunto de datos simulado utilizado en la validación técnica*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

4.1.3 Resultados del perfilamiento de series

El sistema calcula para cada producto, a partir de sus unidades vendidas por día, los tres estadísticos que la sección 2.2.2.3 exige antes de entrenar: la proporción de días sin venta, el intervalo promedio entre demandas (ADI, por sus siglas en inglés) y el coeficiente de variación al cuadrado de las cantidades positivas (CV^2). Con ellos clasifica cada serie según el esquema de Syntetos, Boylan y Croston (2005), con los cortes ADI = 1.32 y $CV^2 = 0.49$. La Tabla 8 presenta los estadísticos del catálogo completo y la Figura 1 la distribución de la proporción de días sin venta.

Estadístico	Mínimo	Mediana	Media	Máximo
Proporción de días sin venta	59.1 %	79.1 %	77.3 %	88.6 %
Intervalo promedio entre demandas (ADI, días)	2.45	—	5.15	8.73
CV^2 de las cantidades positivas	0.023	—	0.130	0.291
Clasificación resultante	Intermitente: 25 de 25 productos (100 %)			

Tabla 8. *Perfil de intermitencia de las 25 series de demanda (n = 25)*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

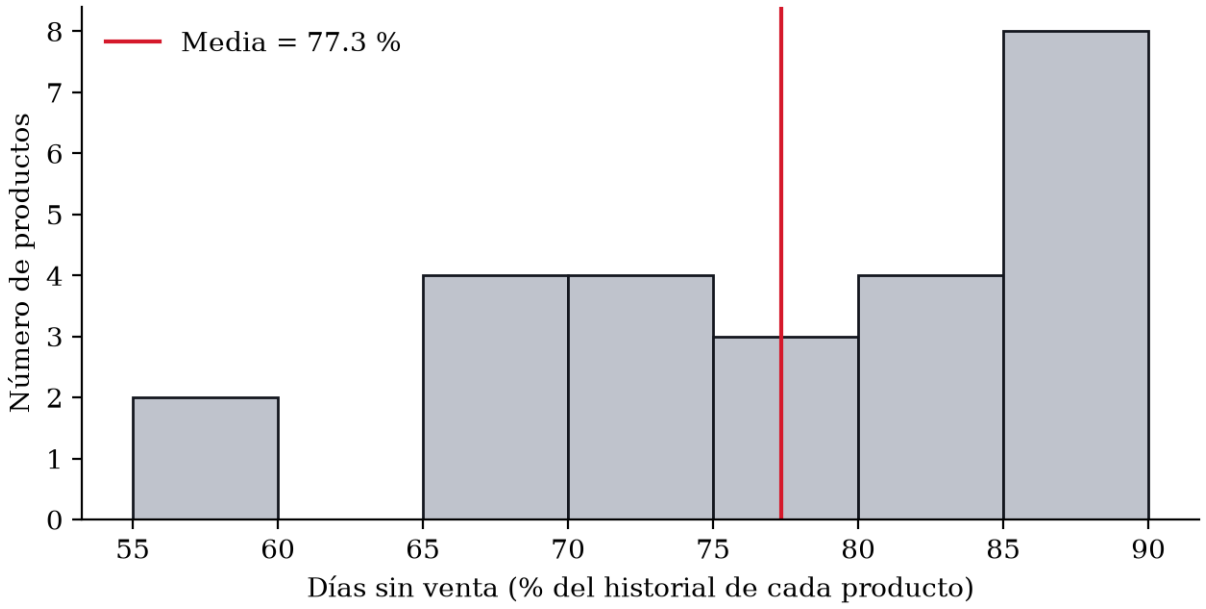


Figura 1. *Distribución de la proporción de días sin venta por producto (n = 25)*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

Ningún producto alcanzó el umbral de ADI < 1.32 que caracteriza a una serie regular. El producto con mayor rotación (espejos retrovisores, 189 unidades en el periodo) registró ventas en el 40.2 % de los días; el de menor rotación (botas urbanas, 42 unidades), en el 11.5 %. La Tabla 9 muestra los cinco productos de mayor y los cinco de menor volumen.

Producto (SKU)	Unidades	Días sin venta	ADI (días)	CV²	Clasificación
ACC-ESPEJOS	189	59.8 %	2.49	0.20	Intermitente
CAS-VISOR	186	59.1 %	2.45	0.18	Intermitente
GTE-VERANO	165	66.4 %	2.98	0.23	Intermitente
ACC-CANDADO	162	65.5 %	2.90	0.24	Intermitente
CHQ-VMAX-PRO	150	68.4 %	3.17	0.19	Intermitente
…					
CAS-XR700	56	85.4 %	6.85	0.06	Intermitente
ACC-PORTA	52	87.0 %	7.67	0.09	Intermitente
ACC-COVER	47	87.5 %	7.98	0.04	Intermitente
CHQ-LLUVIA	46	88.1 %	8.43	0.07	Intermitente
BOT-URBANA	42	88.5 %	8.73	0.02	Intermitente

Tabla 9. *Perfil de los cinco productos de mayor y de menor volumen*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

4.1.4 Serie agregada de ventas

El modelo de pronóstico de esta fase opera sobre el total diario de ventas en quetzales. La Figura 2 presenta la serie de 366 días con su media móvil de siete días y los periodos de temporada alta señalados, y la Tabla 10 los totales mensuales.

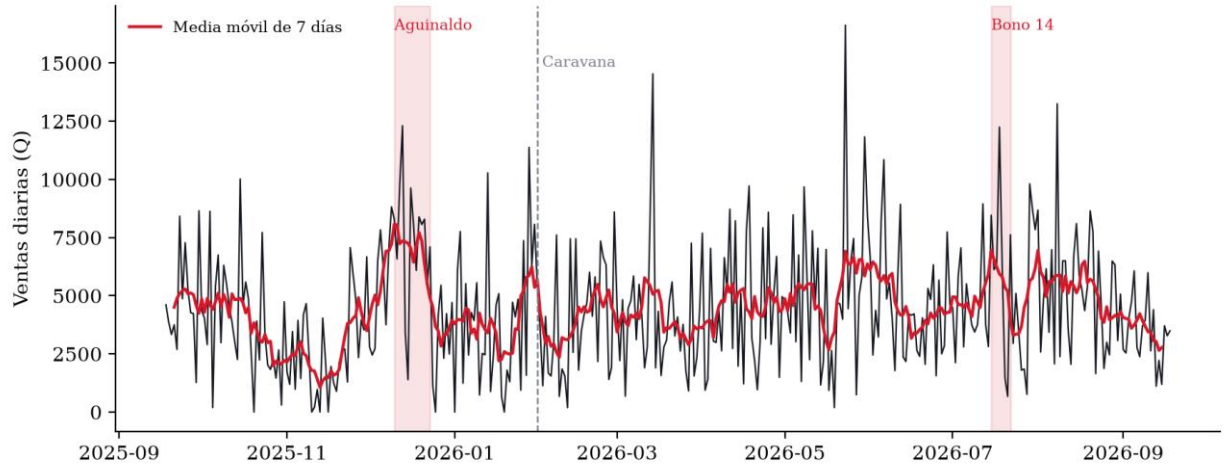


Figura 2. *Serie diaria simulada de ventas con los periodos de temporada alta señalados*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

Mes	Tickets	Ingreso (Q)	Mes	Tickets	Ingreso (Q)
Sep. 2025 (13 días)	59	62,490	Abr. 2026	130	137,520
Oct. 2025	130	120,870	May. 2026	148	163,660
Nov. 2025	72	78,780	Jun. 2026	140	136,250
Dic. 2025	168	175,590	Jul. 2026	171	155,180
Ene. 2026	111	124,280	Ago. 2026	156	162,480
Feb. 2026	118	108,970	Sep. 2026 (18 días)	68	60,860
Mar. 2026	136	123,630	**Total**	**1,607**	**1,610,560**

Tabla 10. *Ventas simuladas por mes*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

Diciembre concentró el mayor ingreso mensual (Q 175,590) y julio el mayor número de tickets (171). Noviembre presentó el menor volumen de un mes completo (72 tickets).

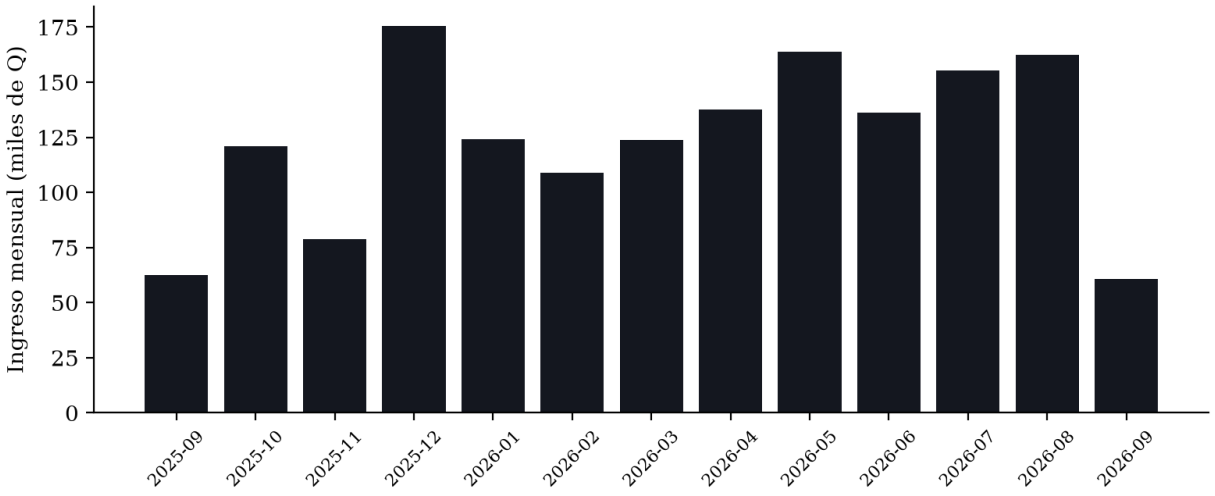


Figura 3. *Ingreso mensual simulado*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

4.1.5 Resultados de la evaluación de modelos

El sistema evaluó siete candidatos bajo el protocolo de la sección 2.2.5: validación temporal con origen móvil, cinco ventanas sucesivas de 30 días y reentrenamiento en cada corte con únicamente el pasado disponible. Los seis primeros son los métodos de referencia exigidos por la sección 2.2.2.2; el séptimo es el modelo de aprendizaje automático (árboles potenciados por gradiente) con variables de calendario, rezagos y medias móviles. Las ventanas de validación tuvieron cortes en los días 216, 246, 276, 306 y 336 de la serie, de modo que el entrenamiento más corto contó con 216 observaciones y el más largo con 336. La Tabla 11 reporta el promedio de las seis métricas de la Tabla 3 en las cinco ventanas.

Candidato	MAE (Q)	RMSE (Q)	WAPE (%)	sMAPE (%)	Sesgo (Q/día)	MASE
Gradient boosting (modelo)	2,126.3	2,738.1	43.99	47.88	−754.3	**0.8030**
Suavizamiento exponencial	2,198.3	2,796.6	46.06	47.99	−130.1	0.8305
ARIMA (1,1,1)	2,226.1	2,823.4	46.57	48.61	−178.4	0.8410
Holt-Winters aditivo	2,253.7	2,792.4	46.55	52.45	−707.1	0.8505
Media móvil (7 días)	2,346.2	2,979.2	48.85	51.28	−310.6	0.8861
Naïve estacional (referencia)	2,736.0	3,354.4	56.95	64.53	−331.9	1.0341
Naïve	2,773.6	3,492.4	57.97	70.08	−1,505.2	1.0499

Tabla 11. *Métricas promedio de los siete candidatos en cinco ventanas de origen móvil (horizonte de 30 días)*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

El modelo de aprendizaje automático obtuvo el menor error en las seis métricas, con un MASE promedio de 0.8030 frente a 1.0341 del naïve estacional. La distancia respecto del segundo candidato, el suavizamiento exponencial simple, fue de 0.0275 unidades de MASE. La Tabla 12 desagrega el MASE por ventana y la Figura 4 compara el modelo con la referencia.

Candidato	Ventana 1	Ventana 2	Ventana 3	Ventana 4	Ventana 5	Media
Gradient boosting (modelo)	0.817	0.976	0.804	0.826	0.592	0.803
Suavizamiento exponencial	0.828	0.909	0.693	0.915	0.808	0.831
ARIMA (1,1,1)	0.826	0.948	0.704	0.920	0.807	0.841
Holt-Winters aditivo	0.760	1.056	0.934	0.860	0.642	0.851
Media móvil (7 días)	0.819	1.056	0.791	0.965	0.799	0.886
Naïve estacional (referencia)	1.056	1.297	0.777	1.121	0.918	1.034
Naïve	1.396	0.888	0.718	1.444	0.804	1.050

Tabla 12. *MASE por ventana de validación*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

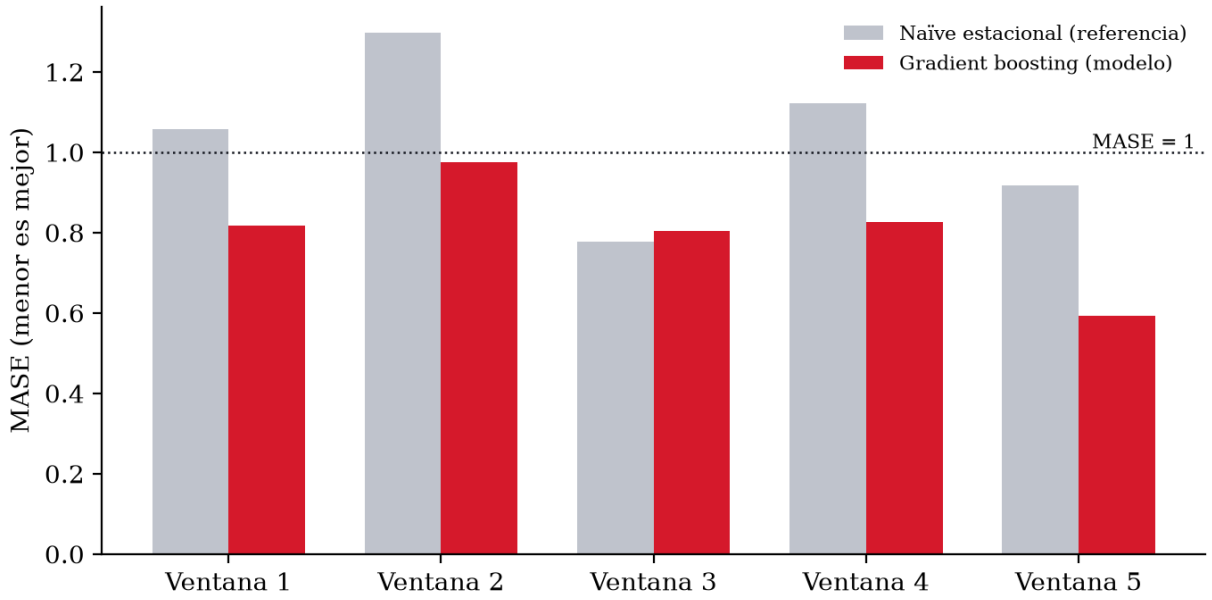


Figura 4. *MASE por ventana de validación: modelo frente a la referencia naïve estacional*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

El modelo superó a la referencia en cuatro de las cinco ventanas. En la ventana 3 el naïve estacional obtuvo un MASE de 0.777 frente a 0.804 del modelo. La Tabla 13 presenta el sesgo y el WAPE del modelo en cada ventana.

Ventana	Corte (día)	Observaciones de entrenamiento	Sesgo (Q/día)	WAPE (%)
1	216	216	−662.0	46.89
2	246	246	−1,654.6	47.27
3	276	276	−1,300.4	43.94
4	306	306	−668.4	41.97
5	336	336	+513.7	39.86

Tabla 13. *Sesgo y WAPE del modelo por ventana de validación*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

El sesgo fue negativo en cuatro ventanas, es decir, el modelo subestimó las ventas, y el WAPE disminuyó de forma sostenida desde 46.89 % en la primera ventana hasta 39.86 % en la quinta, a medida que el conjunto de entrenamiento creció.

4.1.6 Resultado del criterio de publicación

Tras la evaluación, el sistema aplicó el criterio de aceptación de la sección 2.2.5.1. La Tabla 14 muestra el resultado de cada condición.

Condición (sección 2.2.5.1)	Umbral	Valor obtenido	Resultado
Mejora del error escalado sobre el naïve estacional	≥ 10 %	22.35 %	Cumple
Sesgo relativo al volumen medio del periodo	≤ 20 %	19.06 %	Cumple
Consistencia (ventanas en que supera la referencia)	> 50 %	80 % (4 de 5)	Cumple
Decisión		Modelo publicado	

Tabla 14. *Resultado del criterio de publicación aplicado por el sistema*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

4.1.7 Efecto del generador de datos sobre la evaluación

Antes de construir el simulador descrito en 4.1.2, el sistema se evaluó sobre un conjunto generado por un procedimiento anterior que utilizaba las mismas tres funciones de calendario que el modelo recibe como características. La Tabla 15 compara ambas evaluaciones bajo el mismo protocolo.

Indicador	Generador anterior (comparte funciones con el modelo)	Simulador actual (sin funciones compartidas)
MASE del modelo	0.6992	0.8030
MASE del naïve estacional	1.0762	1.0341
Mejora sobre la referencia	35.0 %	22.4 %
Distancia al mejor método simple (MASE)	0.119	0.028
Sesgo relativo	8.9 %	19.1 %
Demanda censurada por inventario	No simulada	14.5 % de la demanda

Tabla 15. *Comparación de la evaluación del modelo según el procedimiento de generación de datos*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

4.1.8 Resultados de las pruebas del sistema y del despliegue

Además de la evaluación del modelo, el sistema cuenta con 128 pruebas automatizadas que verifican las fórmulas de las métricas contra valores calculados a mano, la ausencia de fuga de información temporal en la validación, el perfilamiento de series, la simulación y la gestión de usuarios (Tabla 16). El despliegue en producción se midió en un servidor de un núcleo: el proceso de la API consume entre 331 y 355 MB de memoria, la base de datos 47 MB, y el ciclo completo de evaluación de los siete candidatos en cinco ventanas tarda entre 3 y 5 segundos.

Módulo verificado	Pruebas	Resultado
Métricas de evaluación (MASE, WAPE, MAE, RMSE, sMAPE, sesgo)	19	19 aprobadas
Líneas base y validación de origen móvil	32	32 aprobadas
Perfilamiento de series	20	20 aprobadas
Simulador de ventas	30	30 aprobadas
Usuarios, roles y contraseñas	27	27 aprobadas
Total	**128**	**128 aprobadas**

Tabla 16. *Pruebas automatizadas del sistema por módulo*

Nota. Elaboración propia a partir de los registros del sistema.

4.2 Análisis e interpretación de resultados

4.2.1 La intermitencia del catálogo determina la estrategia de modelado

El resultado de la sección 4.1.3 —25 de 25 series clasificadas como intermitentes, con un 77 % de días sin venta en promedio y un intervalo medio de 5.2 días entre demandas— responde al primer paso que el marco teórico exige antes de entrenar (sección 2.2.2.3) y tiene una consecuencia directa de diseño. Una serie con más de tres de cada cuatro días en cero no admite un regresor diario por producto: el modelo aprendería que la mejor predicción es cero y las métricas porcentuales quedarían indefinidas, tal como advierten Hyndman y Koehler (2006). Esta es la razón por la que el motor de esta fase pronostica el total diario del negocio y no cada producto, y por la que el paso siguiente del proyecto es la agregación temporal por producto o un método específico de demanda intermitente (Croston, 1972; Syntetos y Boylan, 2005). El hallazgo coincide con lo anticipado en la sección 2.2.3.3 a partir de Mejía y Aguilar (2024): los productos de un catálogo de accesorios no comparten un único comportamiento y requieren una estrategia por tipo de serie. Aunque el dato proviene de la simulación, su implicación metodológica es independiente del origen: un catálogo real con tallas, colores y diseños será, con toda probabilidad, todavía más disperso.

4.2.2 El modelo de aprendizaje automático supera a las referencias, pero por un margen estrecho

El marco teórico establece que un modelo de inteligencia artificial solo agrega valor si supera de forma consistente a los métodos de referencia (sección 2.2.2.2). Los resultados de la Tabla 11 lo confirman en el sentido literal: el modelo obtuvo el menor error en las seis métricas y le ganó al naïve estacional en cuatro de cinco ventanas, con una reducción media del MASE de

22.4 %. Sin embargo, la Tabla 12 obliga a matizar la lectura. El suavizamiento exponencial simple, un método con un único parámetro, quedó a 0.028 unidades de MASE del modelo, y en las ventanas 2 y 3 lo superó. La diferencia entre el modelo y el conjunto de métodos simples (suavizamiento, ARIMA, Holt-Winters) es mucho menor que la diferencia entre ese conjunto y el naïve. Esto es coherente con la evidencia de la competencia M5 (Makridakis, Spiliotis y Assimakopoulos, 2022) y con la advertencia de Swami, Shah y Ray (2020): la complejidad del modelo no garantiza por sí sola una mejora, y el valor de los métodos de aprendizaje automático depende de la calidad de las variables y de la cantidad de historia disponible. En términos del objetivo específico 2, el sistema cumple con comparar los modelos bajo un mismo protocolo verificable, y el criterio de aceptación que forma parte de ese objetivo operó como se diseñó.

4.2.3 El sesgo negativo y la ventana de doce meses

El modelo subestimó las ventas en cuatro de las cinco ventanas (Tabla 13), con un sesgo relativo del 19.1 % que quedó a menos de un punto del límite del 20 % fijado en el criterio de publicación. La interpretación más plausible no está en el algoritmo sino en la longitud del historial. Con doce meses de datos, cada evento anual aparece una sola vez en la serie, y las ventanas de validación cubren de finales de abril a septiembre de 2026; la tercera ventana (21 de junio a 20 de julio) contiene el Bono 14. Para el modelo, ese pico ocurre por primera vez en el conjunto de prueba: no existe en su entrenamiento ningún julio anterior del cual aprender la magnitud del efecto. La ventana 5, la única con sesgo positivo, es también la única cuyo entrenamiento ya incluye el pico de julio completo. El resultado ilustra de forma concreta la afirmación de la sección 1.5.4 de que una ventana de veinticuatro meses es la ideal para observar ciclos anuales: con doce meses, el sistema puede modelar la estacionalidad semanal y la tendencia, pero no puede anticipar un evento anual que no ha visto.

4.2.4 La circularidad del generador anterior explica la diferencia entre 35 % y 22 %

La Tabla 15 documenta un hallazgo metodológico que el equipo considera el más importante de la fase. Bajo el generador anterior, el modelo reportaba una mejora del 35 % sobre la referencia y una distancia de 0.119 unidades de MASE respecto del mejor método simple. Al reemplazarlo por un simulador que no comparte ninguna función con las variables del modelo, la mejora descendió a 22 % y la distancia a 0.028. La explicación es directa: si el proceso que genera los datos utiliza las mismas funciones que el modelo recibe como entrada, el modelo recupera por

construcción la señal que se le inyectó, y la evaluación mide la coincidencia entre generador y modelo, no la capacidad de pronóstico. Este tipo de fuga de información es una de las advertencias centrales de la sección 2.2.3 y de la literatura sobre evaluación de series temporales (Bergmeir y Benítez, 2012; Tashman, 2000). La consecuencia práctica es que el 22 % es la cifra defendible del sistema en su estado actual y el 35 % no lo era. Se incluyen ambas precisamente porque el contraste demuestra que el protocolo de evaluación es sensible a la fuga y la detecta.

4.2.5 Relación entre resultados: demanda censurada, sesgo y perfil

Los resultados no son independientes entre sí. El simulador perdió el 14.5 % de la demanda por falta de existencia (Tabla 7), un fenómeno que la sección 2.2.1 describe como demanda censurada por inventario: las unidades vendidas subestiman la demanda potencial cuando el producto se agota. Un modelo entrenado sobre ventas observadas aprende, por tanto, una demanda menor a la real, lo que contribuye al sesgo negativo de la Tabla 13 junto con el efecto de la ventana de doce meses. A su vez, el perfil intermitente de la Tabla 8 es en parte producto de esos quiebres: los días sin existencia son también días sin venta. La cadena perfil → agregación → sesgo muestra por qué la sección 2.2.4 (Tabla 2) incluye la existencia y los días sin stock entre las características candidatas del modelo, y por qué su incorporación es una de las mejoras previstas.

4.2.6 Cierre parcial por objetivo específico

En conjunto, los datos permiten afirmar lo siguiente respecto de los objetivos específicos de la sección 1.4.2, con la salvedad de que provienen de una validación técnica sobre datos simulados:

- **Objetivo 1** (diagnóstico del proceso actual y del método de estimación vigente): pendiente; requiere aplicar en la empresa la entrevista, la observación y la revisión documental (Tabla 6).
- **Objetivo 2** (sistema web que integra los datos, compara modelos y presenta pronósticos): cumplido parcialmente. La comparación de modelos se cumple en cuanto al procedimiento: seis referencias y un modelo de aprendizaje automático se evaluaron en cinco ventanas con MASE, WAPE, MAE, RMSE, sMAPE y sesgo, y el criterio de aceptación operó automáticamente y dejó registrada su decisión. Se consultan pronósticos, métricas y alertas, pero no intervalos derivados del modelo ni explicaciones; la integración de históricos no

es evaluable porque el sistema aún no dispone del importador, y los prototipos aún no se han validado con la empresa.

- **Objetivo 3** (evaluar la mejora frente al método de estimación vigente): cumplido en cuanto al procedimiento sobre datos simulados. Frente al naïve estacional, que representa el método vigente mientras este no se documente, el modelo redujo el MASE en 22.35 % en promedio; la sección 4.3 contrasta esa mejora con la hipótesis de la sección 1.6. La evaluación con los registros de la empresa corresponde a la prueba piloto.

4.3 Comprobación de hipótesis

4.3.1 Formulación

La sección 1.6 formula la hipótesis de trabajo a partir del criterio técnico de la sección 2.2.5.1: que el modelo de aprendizaje automático reduce en más de 10 % el error escalado respecto del naïve estacional, que representa el método de estimación de referencia. Sea $d'_i = MASE_{modelo} - 0.90 \times MASE_{referencia}$ la diferencia ajustada por el umbral en la ventana i y $\mu_{d'}$ su media. Los enunciados son:

- H_0: $\mu_{d'} \geq 0$ (la reducción del error escalado no supera el 10 %).
- H_1: $\mu_{d'} < 0$ (el modelo reduce el error escalado en más de 10 %).

De manera complementaria, se contrasta una hipótesis menos exigente, sin umbral: que el modelo reduce en alguna medida el error respecto de la referencia. Con $d_i = MASE_{modelo} - MASE_{referencia}$ en la ventana i y μ_d su media:

- H_0': $\mu_d \geq 0$ (el modelo no reduce el error escalado respecto del naïve estacional).
- H_1': $\mu_d < 0$ (el modelo reduce el error escalado respecto del naïve estacional).

4.3.2 Prueba seleccionada y nivel de significancia

Las cinco ventanas de validación son las mismas para el modelo y para la referencia, de modo que las observaciones están emparejadas. La prueba adecuada es la t de Student para muestras relacionadas, unilateral, con $\alpha = 0.05$ (Hernández Sampieri, Fernández Collado y Baptista Lucio, 2014). Dado que con n = 5 no es posible verificar de forma robusta el supuesto de normalidad de las diferencias, se reporta además la prueba no paramétrica de rangos con signo de Wilcoxon (1945) y el tamaño del efecto d de Cohen (1988). Con más ventanas disponibles, la prueba de referencia en la literatura para comparar la precisión de dos pronósticos es la de Diebold y Mariano (1995), que se propone para la fase con datos reales.

4.3.3 Resultados

La Tabla 17 resume las diferencias por ventana y los estadísticos obtenidos.

Ventana	MASE modelo	MASE referencia	Diferencia d_i	Diferencia ajustada d'_i
1	0.8174	1.0564	−0.2391	−0.1334
2	0.9757	1.2971	−0.3214	−0.1917
3	0.8041	0.7775	+0.0267	+0.1044
4	0.8258	1.1214	−0.2956	−0.1835
5	0.5921	0.9183	−0.3263	−0.2344
Media de las diferencias			−0.2311	−0.1277
Desviación estándar de las diferencias			0.1482	0.1346

Tabla 17. *Diferencias de MASE por ventana entre el modelo y la referencia naïve estacional*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

Prueba	Estadístico	Valor p (unilateral)	Decisión (α = 0.05)
t de Student pareada contra el umbral del 10 % (H_0: $\mu_{d'} \geq 0$)	$t(4) = -2.121$	0.051	No se rechaza H_0
t de Student pareada sin umbral (H_0': $\mu_d \geq 0$)	$t(4) = -3.487$	0.013	Se rechaza H_0'
Wilcoxon de rangos con signo (H_0': $\mu_d \geq 0$)	$W = 1$	0.063	No se rechaza H_0'
Tamaño del efecto (diferencias sin umbral)	d de Cohen = −1.56	—	Efecto grande

Tabla 18. *Resultados de la comprobación de hipótesis*

Nota. Elaboración propia a partir de los registros del sistema (datos simulados).

4.3.4 Conclusión de la prueba

Para la hipótesis de trabajo, la prueba t pareada contra el umbral del 10 % arroja un valor p de 0.051, que no permite rechazar H_0 al nivel $\alpha = 0.05$, por un margen de una milésima. La mejora media observada, 22.35 %, supera con holgura el umbral de la sección 2.2.5.1, pero la variabilidad entre ventanas —en la tercera, el modelo no superó a la referencia— impide afirmar con la confianza exigida que la mejora supere el 10 % de forma sistemática. Los datos son, por tanto, compatibles con H_1, pero cinco ventanas no bastan para sostenerla estadísticamente. Esta conclusión es coherente con las secciones 4.2.3 y 4.2.4: el sistema aplica el criterio del 10 % sobre el promedio de las ventanas, tal como se diseñó, pero la certeza estadística sobre ese umbral

requiere más historia —y, por tanto, más ventanas de validación— que la disponible en doce meses.

La hipótesis complementaria, menos exigente, sí encuentra respaldo. Con la prueba t pareada sin umbral, el valor p de 0.013 es menor que $\alpha = 0.05$, por lo que se rechaza H_0': existe evidencia estadística de que el modelo de aprendizaje automático reduce el error escalado respecto del naïve estacional en el conjunto evaluado, con un tamaño del efecto grande ($d = -1.56$). La prueba de Wilcoxon no alcanza la significancia al 5 % ($p = 0.063$), lo que se explica por el tamaño de la muestra: con cinco pares, el menor valor p unilateral posible es 0.031 y solo se obtiene cuando las cinco diferencias tienen el mismo signo; con cuatro de cinco, el resultado es exactamente 0.0625. La discrepancia entre ambas pruebas no refleja un desacuerdo sobre la dirección del efecto, sino la escasa potencia que cinco observaciones otorgan a la prueba no paramétrica.

Corresponde reiterar el alcance de estas pruebas. Los datos son simulados, de modo que lo comprobado es que el procedimiento del sistema —su protocolo de validación, sus métricas y su criterio de publicación— distingue correctamente entre un modelo que mejora la referencia y uno que no. La respuesta a la pregunta de investigación de la sección 1.2 y la comprobación de la hipótesis de la sección 1.6 con los registros reales de Zorros Revolution Biker quedan condicionadas a la aplicación del mismo protocolo en la fase de prueba piloto, con más ventanas de validación y, si la entrevista lo documenta, con el método de estimación vigente de la empresa como referencia adicional.

Capítulo V – Estudio de Factibilidad

El estudio de factibilidad examina si el sistema propuesto puede desarrollarse, implantarse y sostenerse en las condiciones reales de Zorros Revolution Biker. Se analizan siete dimensiones —modelo de negocio, transformación digital, legal, ambiental, operativa, técnica y económica— con la evidencia disponible en esta fase: la información pública de la empresa, el estado del prototipo desplegado y las mediciones obtenidas en su infraestructura. Donde una dimensión depende de datos que solo la empresa posee, se declara el supuesto utilizado en lugar de presentarlo como un hecho.

5.1 Modelo de negocio

Para situar el sistema en la lógica de valor de la empresa se utiliza el Business Model Canvas de Osterwalder y Pigneur (2010), completado a partir de la información pública descrita en la sección 1.1.1 y del problema planteado en la sección 1.2. La Tabla 19 presenta los nueve bloques y señala en cuáles interviene la solución.

Bloque	Descripción para Zorros Revolution Biker	Intervención del sistema
Segmentos de clientes	Motociclistas de Guatemala que adquieren equipo de protección, indumentaria, consumibles y accesorios; atendidos en sucursales físicas y en línea	Indirecta: mayor disponibilidad de producto en temporada
Propuesta de valor	Catálogo especializado de accesorios para motocicleta, con presencia en varias ubicaciones del país y canal en línea	Directa: reduce faltantes en los periodos de mayor demanda (diciembre, Bono 14, Caravana del Zorro)
Canales	Sucursales en Antigua Guatemala, Bosques de San Nicolás, C. C. Metronorte, Cobán, Kiosko Metronorte y San Juan zona 4; tienda en línea	Ninguna en esta fase; el pronóstico por sucursal es una extensión prevista
Relación con clientes	Atención en mostrador y en línea	Ninguna directa
Fuentes de ingreso	Venta de productos al detalle	Indirecta: ventas que hoy se pierden por quiebre de existencia
Recursos clave	Inventario importado, sucursales, personal de ventas, catálogo	Directa: el inventario pasa a gestionarse con información prospectiva

Bloque	Descripción para Zorros Revolution Biker	Intervención del sistema
Actividades clave	Compra e importación desde China (lead time de aproximadamente 60 días), almacenamiento, venta, reabastecimiento	Directa: la decisión de cuánto y cuándo pedir se apoya en el pronóstico y el punto de reorden
Socios clave	Proveedores en China, operadores logísticos de importación, plataforma de venta en línea	Ninguna directa
Estructura de costos	Compra de mercadería, transporte e importación, arrendamiento de locales, personal, capital inmovilizado en inventario	Directa: menor capital inmovilizado por sobrepedido y menores ventas perdidas por faltante

Tabla 19. *Business Model Canvas de Zorros Revolution Biker con los bloques en que interviene la solución*

Nota. Elaboración propia a partir de Osterwalder y Pigneur (2010) y de la información pública de la empresa.

El sistema no modifica el negocio: incide sobre la actividad clave de reabastecimiento y, a través de ella, sobre dos rubros de la estructura de costos que el planteamiento del problema identifica como la consecuencia de decidir por experiencia. Un pedido excesivo inmoviliza capital durante un ciclo de importación de dos meses; un pedido escaso produce faltantes justamente cuando la demanda es mayor. El valor de la solución reside en acercar ambas decisiones a la demanda esperada, no en sustituir el criterio comercial de la gerencia, como se establece en la sección 1.2.

5.2 Transformación digital

Estado de partida. Según el planteamiento de la sección 1.2, la planificación de compras de la empresa se apoya en la experiencia del personal y en la revisión manual de registros. No se dispone, en esta fase, de una descripción verificada del sistema transaccional que la empresa utiliza; la sección 1.1.1 deja explícito que ese antecedente debe completarse mediante entrevista. Por tanto, el estado de partida se caracteriza con lo que sí se conoce: las decisiones de reabastecimiento no cuentan con un pronóstico sistemático ni con una medición del error de las estimaciones.

Estado deseado. Una operación en la que las ventas se registran de forma estructurada, cada producto tiene un perfil de demanda conocido, el pronóstico se genera y evalúa con un protocolo reproducible, y las alertas de reabastecimiento consideran el tiempo de importación

desde China. La sección 2.1.1 lo formula como conectar la predicción con la gestión de ventas sin perder trazabilidad.

Capacidades que habilita el MVP. El prototipo desplegado aporta cuatro capacidades que no existían: registro transaccional con descuento automático de inventario; perfilamiento de cada serie de demanda; comparación de modelos de pronóstico con criterio de publicación; y alertas de reabastecimiento que anticipan los eventos de temporada dentro de la ventana de envío. Todas son accesibles desde cualquier navegador con control de acceso por roles.

Impacto en procesos, personas y cultura. El cambio más profundo no es tecnológico sino de criterio: la decisión de compra pasa de basarse en la memoria de temporadas anteriores a apoyarse en una estimación con error conocido. Ello exige dos cosas del personal: disciplina en el registro de cada venta y cada recepción de mercadería, porque la calidad del pronóstico depende de ella, y disposición a contrastar la recomendación del sistema con su propio juicio, en lugar de aceptarla o descartarla en bloque. La sección 5.5 aborda cómo gestionar esa transición. Es importante no sobredimensionar el alcance: el sistema no transforma la relación con el cliente ni los canales de venta; transforma una decisión interna de abastecimiento.

5.3 Factibilidad legal

5.3.1 Normativa aplicable

Guatemala no cuenta con una ley general de protección de datos personales. Ello no significa ausencia de obligaciones: la Tabla 20 identifica las normas que inciden en el proyecto y la forma en que se atienden.

Norma	Contenido relevante	Atención en el proyecto
Constitución Política de la República de Guatemala, artículos 24 y 31 (Asamblea Nacional Constituyente, 1985)	Inviolabilidad de la correspondencia, documentos y libros; derecho de acceso a los archivos y registros que contengan datos de la persona	Los datos de las cuentas de usuario se tratan como información confidencial de la empresa; cada usuario puede consultar sus propios datos
Código Penal, Decreto 17-73, artículos 274 "A" a 274 "G", adicionados por el Decreto 33-96 (Congreso de la República de Guatemala, 1996)	Tipifica la destrucción y alteración de registros informáticos, la reproducción no autorizada de programas, los registros prohibidos, la manipulación de información y los programas destructivos	Control de acceso por roles, contraseñas cifradas, registro de quién realiza cada operación y respaldos de la base de datos
Ley de Derecho de Autor y Derechos Conexos, Decreto 33-98 (Congreso de la República de Guatemala, 1998)	Protege los programas de ordenador como obras literarias; regula la titularidad del software desarrollado	El código es obra del equipo; se propone acordar por escrito con la empresa las condiciones de uso y titularidad antes de la implantación
Ley de Acceso a la Información Pública, Decreto 57-2008 (Congreso de la República de Guatemala, 2008)	Define los datos personales y los datos sensibles y establece el principio de que solo pueden tratarse con consentimiento; aplica a sujetos obligados del sector público, pero constituye la referencia normativa nacional de esas categorías	Se adoptan sus definiciones: el sistema no recolecta datos sensibles y minimiza los personales al nombre y correo de los empleados usuarios
Código de Comercio, Decreto 2-70 (Congreso de la República de Guatemala, 1970)	Obligación del comerciante de llevar contabilidad y conservar sus registros	El sistema es una herramienta de gestión y no sustituye los libros contables ni la facturación
Régimen de Factura Electrónica en Línea, Acuerdo de Directorio 13-2018 (Superintendencia de Administración Tributaria, 2018)	Obliga a emitir facturas electrónicas a través de la plataforma FEL	El sistema no emite facturas ni documentos tributarios; su registro de ventas es interno y no reemplaza la FEL

Tabla 20. *Normativa guatemalteca aplicable y su atención en el proyecto*

Nota. Elaboración propia.

Como referencia de buenas prácticas, el proyecto adopta los principios de minimización, limitación de finalidad y seguridad del Reglamento General de Protección de Datos de la Unión Europea (Parlamento Europeo y Consejo de la Unión Europea, 2016) y los controles de acceso y

de gestión de contraseñas de la norma ISO/IEC 27001 (International Organization for Standardization, 2022a), en los términos que la propia guía metodológica recomienda para contextos en que la legislación local aún se desarrolla.

5.3.2 Datos personales tratados

El requerimiento no funcional RNF-04 establece excluir los datos personales innecesarios. La Tabla 21 inventaría los que el sistema efectivamente almacena.

Dato	Titular	Finalidad	Medida de protección
Nombre y correo electrónico	Empleados con cuenta de usuario	Identificación y control de acceso	Acceso restringido al rol de administrador; cifrado en tránsito (HTTPS)
Contraseña	Empleados con cuenta de usuario	Autenticación	Nunca se almacena en claro: hash bcrypt con factor de costo 12; política de longitud y composición; cambio exigiendo la contraseña actual
Identificador del cajero en cada venta	Empleados	Trazabilidad de la operación	Visible solo para usuarios autenticados
Datos de clientes finales	—	No se recolectan	No aplica

Tabla 21. *Inventario de datos personales tratados por el sistema y medidas de protección*

Nota. Elaboración propia.

El sistema no registra datos de clientes: el pronóstico se construye sobre transacciones agregadas, en línea con la sección 1.5.3. Las cuentas de demostración creadas durante el desarrollo generan contraseñas aleatorias que solo se muestran una vez y no se almacenan en el código fuente ni en la configuración.

5.3.3 Licenciamiento del software

Todos los componentes son de código abierto. La Tabla 22 detalla la licencia de cada uno y su implicación (Open Source Initiative, s. f.).

Componente	Función	Licencia	Implicación
Python	Lenguaje del backend	PSF License	Permisiva
FastAPI, Pydantic, Gunicorn, SQLAlchemy, python-jose	API, validación, servidor, acceso a datos, tokens	MIT	Permisiva; solo exige conservar el aviso de copyright

Componente	Función	Licencia	Implicación
Uvicorn, scikit-learn, statsmodels, pandas, NumPy, passlib	Servidor ASGI, aprendizaje automático, series temporales, datos, hash de contraseñas	BSD de 3 cláusulas	Permisiva
psycopg (driver de PostgreSQL)	Conexión a la base de datos	LGPL 3.0 (Free Software Foundation, 2007)	Copyleft débil: permite su uso como biblioteca sin afectar la licencia del sistema, siempre que no se modifique el driver
PostgreSQL	Base de datos	PostgreSQL License	Permisiva
Docker Engine	Contenedores	Apache 2.0 (Apache Software Foundation, 2004)	Permisiva; exige conservar avisos
Nginx	Proxy inverso	BSD de 2 cláusulas	Permisiva
Chart.js	Gráficas en el navegador	MIT	Permisiva
Let's Encrypt	Certificados TLS	Servicio gratuito	Sin costo de licencia

Tabla 22. *Licencias de los componentes del sistema*

Nota. Elaboración propia a partir de Open Source Initiative (s. f.).

Ningún componente tiene licencia comercial ni de copyleft fuerte que obligue a publicar el código del sistema. El único componente bajo LGPL se utiliza sin modificaciones, con lo que se cumplen sus condiciones. El costo de licenciamiento es cero.

5.3.4 Confidencialidad

La sección 3.3.6 prevé que la recolección de datos se realice con autorización de la empresa y en un entorno restringido. Se propone formalizar, antes de la carga de registros reales, un acuerdo de confidencialidad que cubra la información comercial de Zorros Revolution Biker, el acceso al servidor y las condiciones de uso del software, en concordancia con el Decreto 33-98.

5.4 Factibilidad ambiental

El impacto ambiental directo del sistema es bajo. No requiere hardware dedicado: se ejecuta en un servidor privado virtual compartido de un solo núcleo, con un consumo medido de alrededor de 400 MB de memoria entre la aplicación y la base de datos, y los usuarios lo utilizan

desde equipos con los que la empresa ya cuenta. No genera residuos electrónicos propios ni impresiones: toda la operación es en pantalla.

El impacto indirecto es potencialmente positivo aunque no se cuantifica en esta fase. Un pronóstico que reduzca el sobrepedido disminuye el inventario que termina obsoleto, y un reabastecimiento mejor planificado reduce la necesidad de envíos de emergencia desde el proveedor, que suelen realizarse por vía aérea con una huella de carbono muy superior a la del transporte marítimo habitual. Ambos efectos se alinean con el Objetivo de Desarrollo Sostenible 12, producción y consumo responsables (Organización de las Naciones Unidas, 2015). Como medida de mitigación del consumo energético se optó por un servidor compartido con recursos ajustados, en lugar de infraestructura dedicada, y por un modelo cuyo reentrenamiento completo tarda segundos, no horas.

5.5 Factibilidad operativa

Disposición de los usuarios. No fue posible medirla en esta fase con el cuestionario de la sección 3.3.2, que se aplicará durante la prueba piloto. Se anticipa una aceptación favorable con base en el Modelo de Aceptación de Tecnología de Davis (1989): la utilidad percibida es alta porque el sistema aborda una decisión que hoy consume tiempo y genera pérdidas, y la facilidad de uso percibida se cuidó en el diseño con flujos de pocos pasos y validación en la propia pantalla. La principal fuente de resistencia previsible es la disciplina de registro que el sistema exige.

Competencias y capacitación. El personal de ventas requiere las competencias de un punto de venta convencional: registrar una transacción y una recepción de mercadería. La gerencia requiere, además, interpretar el pronóstico y sus métricas. Se cuenta con un manual de usuario (versión 0.2) alineado con el sistema desplegado y se prevé una capacitación de dos sesiones: una para el personal de caja y otra para los administradores, centrada en la lectura del pronóstico y de las alertas de reabastecimiento.

Cambios en los procesos. Dos procesos cambian: el registro de ventas, que debe hacerse en el momento y con todos los productos del ticket, y la decisión de compra, que incorpora la recomendación del sistema como un insumo a contrastar. La sección 9 del manual de usuario propone un flujo diario, semanal y mensual.

Soporte y sostenibilidad. Durante el proyecto, el equipo de desarrollo atiende el soporte. Para la operación posterior se requiere designar en la empresa a un responsable de primer nivel y acordar quién administra el servidor. La solución está contenerizada y documentada para que su

despliegue sea reproducible por un tercero, lo que reduce la dependencia del equipo original. Con esas condiciones, el proyecto se considera operativamente factible; sin un responsable designado, la sostenibilidad quedaría comprometida.

5.6 Factibilidad técnica

5.6.1 Infraestructura

El sistema está desplegado y en operación en un servidor privado virtual con las características de la Tabla 23, lo que constituye evidencia directa de factibilidad: no se trata de una estimación sino de una medición.

Recurso	Disponible	Utilizado por el sistema	Observación
Procesador	1 núcleo	Compartido con otros servicios del servidor	El entrenamiento completo tarda entre 3 y 5 segundos
Memoria	3.8 GB (≈ 1.9 GB libres)	API: 331–355 MB; base de datos: 27–47 MB	Se fijaron dos procesos de trabajo para no exceder la memoria
Almacenamiento	48 GB	Del orden de 2 GB (imágenes de contenedores, base de datos, modelos)	Los modelos entrenados se conservan versionados
Red	Dominio con certificado TLS	HTTPS con renovación automática	Nginx del servidor como proxy inverso
Cliente	Navegador actual con conexión a internet	Sin instalación	Interfaz adaptable a pantalla de teléfono

Tabla 23. *Infraestructura del despliegue y mediciones obtenidas*

Nota. Elaboración propia a partir de las mediciones en el servidor.

5.6.2 Herramientas y madurez tecnológica

La plataforma se construyó con tecnologías maduras, con soporte activo y documentación abundante: FastAPI sobre Python para la API; PostgreSQL como base de datos, tal como especifica la Tabla 37 del diseño preliminar; scikit-learn y statsmodels para el motor de pronóstico; Docker Compose para el despliegue reproducible, en cumplimiento del RNF-12; y HTML, CSS y JavaScript sin dependencias de framework para la interfaz. La elección de PostgreSQL sobre MySQL, contemplado inicialmente por restricciones de hospedaje, fue posible al disponer de un

servidor propio y se realizó sin cambios en el código de aplicación gracias a la capa de abstracción de SQLAlchemy.

5.6.3 Competencias del equipo

El equipo domina Python, SQL y desarrollo web, y adquirió durante la fase las competencias específicas del motor de pronóstico: métricas de evaluación de series temporales, validación de origen móvil y métodos de referencia. La existencia de 128 pruebas automatizadas que verifican las fórmulas contra valores calculados a mano es evidencia de ese dominio y, a la vez, una salvaguarda frente a errores de implementación como el que se detectó y corrigió en el cálculo del MASE durante la fase.

5.6.4 Riesgos técnicos identificados

Tres riesgos permanecen abiertos y se documentan con su mitigación prevista: el entrenamiento se ejecuta dentro de la petición web, lo que con un histórico mayor podría exceder los tiempos de espera (mitigación: tarea asíncrona); el esquema de la base de datos no cuenta con migraciones versionadas (mitigación: incorporar Alembic); y el servidor es compartido con otros proyectos, lo que exige disciplina en los cambios de configuración. Ninguno impide la operación actual. El proyecto es técnicamente factible y, de hecho, está en operación.

5.7 Factibilidad económica

5.7.1 Costos

La Tabla 24 desglosa los costos del proyecto en su primer año y en los dos siguientes. Se distingue el desembolso efectivo del costo sombra del desarrollo, que corresponde al trabajo del equipo valorado a una tarifa de mercado aunque no represente un pago.

Concepto	Supuesto	Año 1 (Q)	Años 2 y 3 (Q por año)
Desarrollo (costo sombra)	3 integrantes × 10 h/semana × 16 semanas = 480 h, a Q 60/h	28,800	0
Servidor privado virtual	Q 80 mensuales	960	960
Dominio y certificado TLS	DuckDNS y Let's Encrypt, sin costo	0	0
Licencias de software	Componentes de código abierto (Tabla 22)	0	0
Capacitación	8 horas del equipo a Q 60/h	480	0
Mantenimiento y soporte	4 h mensuales a Q 60/h	2,880	2,880
Total con costo sombra		**33,120**	**3,840**

Concepto	Supuesto	Año 1 (Q)	Años 2 y 3 (Q por año)
Desembolso efectivo		**4,320**	**3,840**

Tabla 24. *Costos del proyecto*

Nota. Elaboración propia; las tarifas y horas son supuestos declarados.

5.7.2 Beneficios y supuestos

El beneficio principal identificado en el planteamiento del problema son las ventas que se pierden por falta de existencia en temporada alta y el capital que se inmoviliza por sobrepedido. Ninguno de los dos puede cuantificarse con datos de la empresa en esta fase. Se construye, en consecuencia, un modelo paramétrico con supuestos explícitos (Tabla 25) que la empresa podrá sustituir por sus cifras reales, tal como recomienda la guía metodológica y el PMBOK Guide para la documentación de estimaciones (Project Management Institute, 2021).

Parámetro	Valor supuesto	Origen
Proporción de la demanda no atendida por quiebre de existencia	14.5 %	Única cifra tomada de la validación técnica sobre datos simulados (Tabla 7); debe verificarse con registros reales
Fracción de esa demanda que el sistema permitiría recuperar	15 % (pesimista), 30 % (base), 50 % (optimista)	Supuesto conservador: el pronóstico reduce, no elimina, los faltantes
Margen bruto sobre ventas	35 %	Supuesto para comercio minorista de accesorios; sustituir por el dato de la empresa
Ventas anuales de la empresa	Q 600,000; Q 1,200,000; Q 2,400,000	Tres niveles ilustrativos; el nivel real es desconocido

Tabla 25. *Supuestos del análisis económico*

Nota. Elaboración propia.

Con estos parámetros, el beneficio anual se calcula como: ventas anuales × 14.5 % × fracción recuperada × 35 %. No se cuantifica el beneficio por menor capital inmovilizado, con lo que la estimación es conservadora.

5.7.3 Retorno de la inversión y relación beneficio-costo

La Tabla 26 presenta el beneficio anual, el retorno de la inversión (ROI) y la relación beneficio-costo (B/C) para cada combinación de supuestos, en dos horizontes: el primer año considerando solo el desembolso efectivo, y tres años considerando el costo total incluido el costo sombra del desarrollo. Las fórmulas son las estándar de evaluación de proyectos de tecnología (Schwalbe, 2019): ROI = (beneficios − costos) / costos × 100, y B/C = beneficios / costos.

Ventas anuales (Q)	Fracción recuperada	Beneficio anual (Q)	ROI año 1, desembolso Q 4,320	ROI a 3 años, costo total Q 40,800	B/C a 3 años
600,000	15 %	4,568	6 %	−66 %	0.34
600,000	30 %	9,135	111 %	−33 %	0.67
600,000	50 %	15,225	252 %	12 %	1.12
1,200,000	15 %	9,135	111 %	−33 %	0.67
1,200,000	30 %	18,270	323 %	34 %	1.34
1,200,000	50 %	30,450	605 %	124 %	2.24
2,400,000	15 %	18,270	323 %	34 %	1.34
2,400,000	30 %	36,540	746 %	169 %	2.69
2,400,000	50 %	60,900	1,310 %	348 %	4.48

Tabla 26. *Escenarios de retorno de la inversión según los supuestos de la Tabla 25*

Nota. Elaboración propia.

5.7.4 Interpretación y punto de equilibrio

La lectura de la Tabla 26 distingue dos situaciones. Considerando únicamente el desembolso efectivo —servidor, capacitación y mantenimiento—, el proyecto se recupera dentro del primer año en todos los escenarios salvo el más pesimista, y en el escenario base con ventas de Q 1,200,000 el periodo de recuperación es de aproximadamente tres meses (Q 4,320 / Q 18,270 × 12). Esta es la situación que enfrenta la empresa si adopta el sistema desarrollado en el marco del trabajo de graduación.

Considerando el costo total, es decir, valorando el desarrollo como si se hubiera contratado, el resultado depende de la escala del negocio. Con el escenario base de recuperación (30 %), el proyecto alcanza el punto de equilibrio a tres años cuando las ventas anuales superan aproximadamente Q 895,000, que es el nivel en que 3 × 0.0152 × ventas iguala Q 40,800. Por debajo de esa escala, el desarrollo a tarifa de mercado no se justificaría solo por las ventas recuperadas; por encima, la relación beneficio-costo crece con la escala y alcanza 2.69 con ventas de Q 2,400,000.

Tres precisiones son necesarias para no sobreinterpretar el análisis. Primero, el único parámetro con respaldo cuantitativo, la proporción de demanda no atendida, proviene de la simulación y debe medirse en la operación real antes de tomar cualquier decisión de inversión. Segundo, el beneficio por menor capital inmovilizado no se incluyó, por lo que los resultados son conservadores. Tercero, la conclusión que sí es robusta a los supuestos es que el costo recurrente del sistema —menos de Q 4,000 anuales— es una fracción pequeña de cualquier escenario de

beneficio razonable, de modo que la decisión económica relevante para la empresa no es si operar el sistema, sino si el volumen de faltantes justifica el esfuerzo de registro que exige. Con esa salvedad, el proyecto se considera económicamente factible.

Capítulo VI – Desarrollo de la Solución Tecnológica

Este capítulo documenta la construcción de la solución: el tipo de sistema, sus requerimientos, su diseño, la forma en que se implementó y cómo se probó. Incluye la documentación técnica preliminar, elaborada antes de construir el sistema —el backlog inicial (sección 6.2.2), el diseño arquitectónico preliminar (sección 6.3.1) y los prototipos de baja fidelidad (sección 6.3.6)—, y la actualiza con el diseño final. Donde el diseño final difiere del preliminar se indica la diferencia y su justificación, de modo que la documentación describa el sistema que existe y no el que se propuso.

6.1 Tipo de sistema propuesto

Siguiendo la taxonomía de Laudon y Laudon (2020), la solución combina cuatro tipos de sistema de información (Tabla 27). No se trata de una clasificación nominal: cada tipo justifica una decisión de arquitectura.

Tipo	Componente del sistema	Justificación
Transaccional (TPS)	Registro de ventas, recepción de mercadería, catálogo, movimientos de inventario	Procesa las operaciones diarias y mantiene la existencia de cada producto en la base de datos
De soporte a decisiones (DSS)	Pronóstico de ventas, señales por producto, punto de reorden y recomendaciones de reabastecimiento	Apoya la decisión de cuánto y cuándo pedir; no la ejecuta
Inteligente (con aprendizaje automático)	Motor de pronóstico con árboles potenciados por gradiente, comparado contra seis métodos de referencia y sujeto a un criterio de publicación	Aprende de los datos y su desempeño se mide y condiciona su uso; no es un conjunto de reglas fijas
Web en la nube	Aplicación accesible por navegador, desplegada en contenedores sobre un servidor privado virtual con HTTPS	Permite el acceso desde cualquier sucursal sin instalación local

Tabla 27. *Clasificación del sistema según su tipo*

Nota. Elaboración propia a partir de Laudon y Laudon (2020).

La combinación TPS-DSS explica la arquitectura en capas de la sección 6.3.2: la capa transaccional alimenta con datos al motor de pronóstico, y este devuelve información prospectiva a la misma interfaz. La calificación de sistema inteligente se sostiene en que el componente de

aprendizaje automático se evalúa contra líneas base y solo se publica si las supera (sección 6.3.5), en lugar de aplicarse de forma incondicional.

6.2 Análisis de requerimientos

6.2.1 Fuentes y método

Los requerimientos provienen de tres fuentes: el planteamiento del problema y los objetivos del Capítulo I; el backlog preliminar de la sección 6.2.2, elaborado con la escala MoSCoW; y la auditoría de alineación entre el documento y el sistema realizada al inicio de la fase, que contrastó cada requerimiento con el código. Se redactaron de forma numerada y verificable, conforme a la norma ISO/IEC/IEEE 29148 (International Organization for Standardization, 2018), y los no funcionales se asociaron a las características de calidad de la norma ISO/IEC 25010 (International Organization for Standardization, 2011). A cada requerimiento se le añade su estado en el MVP, lo que permite trazarlo hacia las pruebas de la sección 6.5.

6.2.2 Levantamiento Preliminar de Requerimientos

Los requerimientos siguientes constituyen un backlog inicial derivado del problema y del estado del arte. Deben validarse con usuarios de Zorros Revolution Biker antes de comprometer alcance. La prioridad utiliza la escala MoSCoW: Debe, Debería, Podría y No en esta fase.

6.2.2.1 Requerimientos Funcionales

RF	Requerimiento	Descripción	Prioridad
RF-01	Autenticación	Iniciar y cerrar sesión con roles de administrador, analista y consulta.	Debe
RF-02	Catálogo	Registrar o importar productos, categorías, sucursales y canales.	Debe
RF-03	Carga de ventas	Importar CSV/XLSX con fecha, SKU, cantidad y nivel comercial autorizado.	Debe
RF-04	Validación	Detectar esquema, nulos, duplicados, tipos y claves no reconocidas antes de confirmar.	Debe
RF-05	Trazabilidad de carga	Conservar archivo, usuario, fecha, resumen, filas aceptadas y rechazadas.	Debe
RF-06	Perfilamiento	Mostrar cobertura, volumen, ceros, faltantes, atípicos y densidad por serie.	Debe
RF-07	Entrenamiento	Ejecutar baselines y modelos candidatos con parámetros versionados.	Debe

RF	Requerimiento	Descripción	Prioridad
RF-08	Evaluación temporal	Calcular métricas en múltiples cortes y comparar contra baseline.	Debe
RF-09	Publicación	Publicar únicamente una versión aprobada y conservar la anterior.	Debe
RF-10	Pronóstico	Consultar horizontes de 7, 14 y 30 días por nivel autorizado.	Debe
RF-11	Intervalos	Mostrar rango o nivel de incertidumbre cuando el modelo lo soporte.	Debería
RF-12	Explicación	Presentar factores principales, limitaciones y versión del modelo.	Debería
RF-13	Alertas	Identificar demanda prevista alta, baja rotación y datos desactualizados.	Debería
RF-14	Escenarios	Permitir ajustar una promoción o precio planificado sin alterar el histórico.	Podría
RF-15	Exportación	Exportar pronósticos, métricas y alertas a CSV/XLSX/PDF.	Debe
RF-16	Monitoreo	Comparar pronóstico con venta real y detectar degradación del error.	Debe
RF-17	Bitácora	Registrar cargas, entrenamiento, aprobación, consulta administrativa y fallos.	Debe
RF-18	Integración	Exponer endpoints seguros para una futura conexión con POS o e-commerce.	Podría

Tabla 28. *Requerimientos funcionales preliminares*

Nota. Elaboración propia.

6.2.2.2 Requerimientos No Funcionales

RNF	Categoría	Requisito	Criterio de aceptación
RNF-01	Rendimiento	Consultas comunes del dashboard ágiles.	p95 menor de 3 s con la carga piloto.
RNF-02	Disponibilidad	Servicio disponible en horario operativo.	99 % mensual, excluyendo mantenimiento acordado.
RNF-03	Seguridad	TLS, control por rol y contraseñas con hash.	Pruebas de acceso no autorizado y configuración segura.
RNF-04	Privacidad	Excluir datos personales innecesarios.	Inventario de campos y revisión de minimización aprobada.

RNF	Categoría	Requisito	Criterio de aceptación
RNF-05	Usabilidad	Flujos principales comprensibles sin entrenamiento extenso.	80 % de tareas completadas por usuarios piloto.
RNF-06	Accesibilidad	Interfaz navegable con teclado y contraste adecuado.	Revisión WCAG 2.2 nivel AA en vistas principales.
RNF-07	Mantenibilidad	Componentes desacoplados y configuración externa.	Pruebas, documentación y análisis estático sin bloqueos.
RNF-08	Reproducibilidad	Cada pronóstico referencia datos y modelo.	Ejecución repetible con mismo artefacto y fecha de corte.
RNF-09	Respaldo	Copias automáticas de datos y modelos.	Restauración ensayada y RPO/RTO acordados.
RNF-10	Escalabilidad	Aumentar productos y sucursales sin rediseño total.	Prueba con al menos 2 veces el volumen piloto.
RNF-11	Observabilidad	Logs estructurados, métricas y alertas de fallos.	Correlación por id de carga y ejecución.
RNF-12	Portabilidad	Despliegue reproducible en contenedores.	Construcción y arranque documentados en entorno limpio.

Tabla 29. *Requerimientos no funcionales preliminares*

Nota. Elaboración propia.

6.2.2.3 Historias de Usuario – Backlog Inicial

ID	Historia de usuario	Criterio principal	Prioridad
HU-01	Como administrador, quiero gestionar usuarios y roles para controlar el acceso.	Solo roles autorizados acceden a datos y acciones.	Alta
HU-02	Como analista, quiero importar ventas para actualizar la base histórica.	La carga se previsualiza y valida antes de confirmar.	Alta
HU-03	Como analista, quiero corregir claves no reconocidas mediante un mapeo.	El mapeo queda registrado y reutilizable.	Alta
HU-04	Como analista, quiero perfilar series para decidir la granularidad del modelo.	Se muestran ceros, cobertura y frecuencia por nivel.	Alta
HU-05	Como responsable de ventas, quiero consultar el pronóstico de 30 días.	Puedo filtrar y comparar con el período anterior.	Alta

ID	Historia de usuario	Criterio principal	Prioridad
HU-06	Como responsable de inventario, quiero detectar demanda alta prevista.	La alerta identifica producto, horizonte y fundamento.	Alta
HU-07	Como gerente, quiero ver ventas reales frente al pronóstico.	El tablero muestra tendencia, error y sesgo.	Alta
HU-08	Como analista, quiero comparar modelos antes de publicar.	Se visualizan ventanas y métricas contra baseline.	Alta
HU-09	Como gerente, quiero conocer por qué cambia una predicción.	Se muestran factores y limitaciones comprensibles.	Media
HU-10	Como usuario, quiero exportar resultados para reuniones.	La exportación respeta filtros y fecha de corte.	Media
HU-11	Como administrador, quiero restaurar una versión previa del modelo.	La reversión conserva auditoría y no borra la versión fallida.	Media
HU-12	Como analista, quiero recibir alerta de deriva.	El sistema compara error reciente con umbral aprobado.	Media

Tabla 30. *Historias de usuario del backlog inicial*

Nota. Elaboración propia.

6.2.2.4 Casos de Uso Principales

Campo	Detalle
Caso	CU-01 – Importar histórico de ventas
Actor	Analista o administrador
Precondición	Sesión válida, catálogo básico y archivo autorizado
Flujo principal	Seleccionar archivo; detectar columnas; validar; revisar resumen; confirmar; registrar carga.
Flujo alternativo	Si existen claves desconocidas o errores críticos, se bloquea confirmación y se entrega reporte.
Postcondición	Datos normalizados disponibles con trazabilidad y reporte de calidad.

Tabla 31. *Caso de uso CU-01: importar histórico de ventas*

Nota. Elaboración propia.

Campo	Detalle
Caso	CU-02 – Entrenar y evaluar modelos
Actor	Analista
Precondición	Dataset aprobado, horizonte y baseline definidos
Flujo principal	Elegir alcance; generar variables; ejecutar candidatos; validar por origen móvil; comparar; registrar resultados.
Flujo alternativo	Si ningún candidato supera el baseline, se conserva la referencia y se registra el hallazgo.
Postcondición	Modelo candidato disponible para aprobación, con métricas y artefactos versionados.

Tabla 32. *Caso de uso CU-02: entrenar y evaluar modelos*

Nota. Elaboración propia.

Campo	Detalle
Caso	CU-03 – Consultar pronóstico
Actor	Gerencia, ventas o inventario
Precondición	Existe un modelo publicado y datos actualizados
Flujo principal	Abrir tablero; seleccionar nivel y horizonte; visualizar histórico, pronóstico, rango y explicación; exportar si se requiere.
Flujo alternativo	Si los datos están atrasados o la serie es insuficiente, se muestra advertencia y nivel agregado disponible.
Postcondición	Consulta registrada para auditoría sin modificar la predicción.

Tabla 33. *Caso de uso CU-03: consultar pronóstico*

Nota. Elaboración propia.

6.2.3 Requerimientos funcionales

ID	Requerimiento	Prioridad	Estado en el MVP
RF-01	Iniciar y cerrar sesión con control de acceso por rol	Debe	Implementado con dos roles (administrador y cajero); el rol de analista del diseño preliminar se incorporará junto con el importador de datos, que es la función que lo distingue
RF-02	Registrar y consultar el catálogo de productos, categorías, sucursales y canales	Debe	Parcial: productos y categorías; sucursales pendientes
RF-03	Importar ventas históricas desde archivos CSV o XLSX	Debe	Pendiente; prioridad para la fase de prueba piloto
RF-04	Validar esquema, nulos, duplicados y claves antes de confirmar una carga	Debe	Pendiente, depende de RF-03
RF-05	Conservar la trazabilidad de cada carga	Debe	Pendiente, depende de RF-03
RF-06	Perfilar cada serie: cobertura, proporción de ceros, intervalo entre demandas, variabilidad	Debe	Implementado (clasificación de Syntetos, Boylan y Croston)
RF-07	Entrenar líneas base y modelos candidatos con parámetros versionados	Debe	Implementado: seis referencias y un modelo de aprendizaje automático
RF-08	Evaluar con validación temporal de origen móvil y comparar contra la línea base	Debe	Implementado: cinco ventanas, seis métricas
RF-09	Publicar solo la versión aprobada y conservar la anterior	Debe	Implementado: criterio automático de aceptación y artefactos versionados

ID	Requerimiento	Prioridad	Estado en el MVP
RF-10	Consultar pronósticos a 7, 14 y 30 días	Debe	Parcial: horizontes de 7, 30, 90 y 180 días sobre el total diario; falta 14 y el nivel por producto
RF-11	Mostrar rango de incertidumbre	Debería	Parcial: intervalo fijo, no derivado del modelo
RF-12	Presentar factores principales y versión del modelo	Debería	Parcial: versión y métricas; sin factores explicativos
RF-13	Alertas de demanda alta, baja rotación y datos desactualizados	Debería	Parcial: alta y baja demanda; falta la alerta de datos desactualizados
RF-14	Simular escenarios de promoción o precio	Podría	Pendiente
RF-15	Exportar pronósticos, métricas y alertas	Debe	Pendiente
RF-16	Comparar pronóstico con venta real y detectar degradación	Debe	Pendiente
RF-17	Registrar en bitácora cargas, entrenamientos, aprobaciones y fallos	Debe	Parcial: los entrenamientos y sus decisiones se registran; la bitácora general está definida y sin uso
RF-18	Exponer endpoints seguros para integración futura con punto de venta	Podría	Parcial: API REST con autenticación por token
RF-19	Administrar cuentas: alta, cambio de rol, activación y restablecimiento de contraseña, con política de contraseñas	Debe	Implementado, con protección contra dejar el sistema sin administrador
RF-20	Registrar ventas con varios productos por ticket, descontando existencia, y registrar recepciones de mercadería	Debe	Implementado
RF-21	Calcular el punto de reorden por producto considerando el lead time de importación y los eventos de temporada	Debe	Implementado sobre la demanda reciente; su vínculo con el modelo de pronóstico es una mejora prevista

Tabla 34. *Requerimientos funcionales con su estado en el MVP*

Nota. Elaboración propia.

Los requerimientos RF-19 a RF-21 no figuraban en el backlog preliminar y surgieron durante la construcción: el primero, de la necesidad de eliminar toda credencial del código y la configuración; los otros dos, de que la empresa no dispone de un sistema transaccional del cual importar, lo que obligó a que el MVP capture las ventas por sí mismo.

6.2.4 Requerimientos no funcionales

ID	Característica (ISO/IEC 25010)	Requisito	Criterio de aceptación	Estado en el MVP
RNF-01	Eficiencia de desempeño	Consultas del tablero ágiles	p95 menor de 3 s con la carga piloto	Sin medir bajo carga; el reentrenamiento completo tarda de 3 a 5 s
RNF-02	Fiabilidad – disponibilidad	Servicio disponible en horario operativo	99 % mensual	Reinicio automático de contenedores y verificación de salud; sin monitoreo de disponibilidad
RNF-03	Seguridad	TLS, control por rol, contraseñas con hash	Pruebas de acceso no autorizado	Implementado: HTTPS, roles verificados en el servidor, bcrypt, política de contraseñas, secretos fuera del código
RNF-04	Seguridad – confidencialidad	Excluir datos personales innecesarios	Inventario de campos aprobado	Implementado: solo nombre y correo de empleados; sin datos de clientes
RNF-05	Usabilidad	Flujos comprensibles sin entrenamiento extenso	80 % de tareas completadas por usuarios piloto	Pendiente de medición con el cuestionario de la sección 3.3.2
RNF-06	Usabilidad – accesibilidad	Navegable con teclado y contraste adecuado	Revisión WCAG 2.2 nivel AA	Parcial: enlace de salto, etiquetas, cierre con Esc, regiones dinámicas anunciadas; revisión formal pendiente
RNF-07	Mantenibilidad	Componentes desacoplados y configuración externa	Pruebas, documentación y análisis estático	Implementado: 128 pruebas automatizadas, configuración por variables de entorno, documentación de despliegue

ID	Característica (ISO/IEC 25010)	Requisito	Criterio de aceptación	Estado en el MVP
RNF-08	Fiabilidad – reproducibilidad	Cada pronóstico referencia datos y modelo	Ejecución repetible con el mismo artefacto	Parcial: modelos versionados y semilla fija; falta persistir cada pronóstico emitido
RNF-09	Fiabilidad – recuperabilidad	Respaldos automáticos	Restauración ensayada	Parcial: procedimiento manual documentado y ensayado; sin automatizar
RNF-10	Eficiencia – capacidad	Aumentar productos y sucursales sin rediseño	Prueba con el doble del volumen piloto	Sin medir
RNF-11	Mantenibilidad – analizabilidad	Registros estructurados y métricas	Correlación por identificador de ejecución	Parcial: cada entrenamiento se registra con sus métricas; sin registros estructurados de la API
RNF-12	Portabilidad	Despliegue reproducible en contenedores	Arranque documentado en entorno limpio	Implementado: Docker Compose, verificado en local y en el servidor

Tabla 35. *Requerimientos no funcionales, característica de calidad asociada y estado en el MVP*

Nota. Elaboración propia a partir de ISO/IEC 25010.

6.2.5 Casos de uso

Dos actores humanos interactúan con el sistema —el cajero y el administrador— y un tercero, el administrador técnico, opera el servidor. La Tabla 36 lista los casos de uso y la Figura 5 los representa.

Caso de uso	Actor principal	Precondición	Postcondición	Estado
CU-01 Importar histórico de ventas	Administrador	Archivo autorizado y catálogo cargado	Datos normalizados con reporte de calidad	Pendiente (RF-03 a RF-05)
CU-02 Entrenar y evaluar modelos	Administrador	Al menos 60 días de historial	Modelo publicado si supera el criterio; intento registrado en cualquier caso	Implementado
CU-03 Consultar pronóstico	Administrador	Modelo publicado	Pronóstico, señales y recomendaciones en pantalla	Implementado
CU-04 Registrar venta	Cajero o administrador	Sesión activa y productos con existencia	Venta registrada, existencia descontada, indicadores actualizados	Implementado
CU-05 Recibir mercadería	Cajero o administrador	Producto registrado	Existencia incrementada y movimiento registrado	Implementado
CU-06 Administrar cuentas	Administrador	Sesión de administrador	Cuenta creada, rol cambiado, estado actualizado o contraseña restablecida	Implementado
CU-07 Recuperar acceso	Administrador técnico	Acceso al servidor	Contraseña restablecida desde la línea de comandos	Implementado

Tabla 36. *Casos de uso del sistema*

Nota. Elaboración propia.

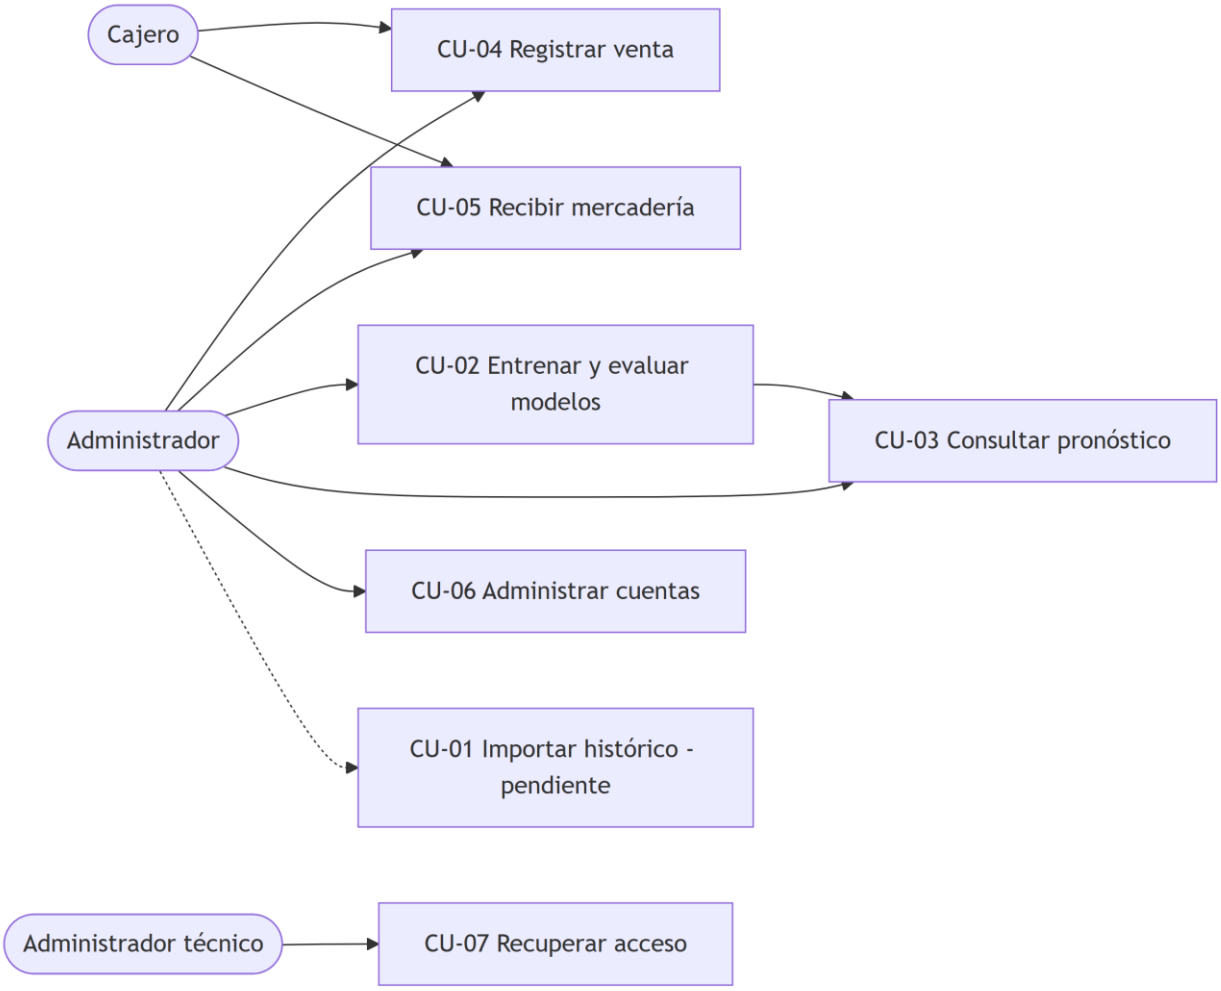


Figura 5. *Diagrama de casos de uso del sistema*

Nota. Elaboración propia.

El flujo principal de CU-02, que materializa la sección 2.2.5 del marco teórico, es el siguiente: el administrador solicita la recalibración; el sistema construye la serie diaria y sus características; entrena y evalúa los siete candidatos en cinco ventanas de origen móvil; calcula las métricas; aplica el criterio de aceptación al modelo de aprendizaje automático frente al naïve estacional; si lo supera, reentrena con todo el historial, guarda el artefacto versionado y lo publica; si no, conserva el modelo vigente. En ambos casos registra la ejecución con sus métricas y la decisión. El flujo alternativo —ningún candidato supera la referencia— es exactamente el previsto en la Tabla 32 del diseño preliminar.

6.3 Diseño de la solución

6.3.1 Diseño Arquitectónico Preliminar

La arquitectura sigue un modelo cliente-servidor con separación de responsabilidades. El navegador consume un frontend web; este se comunica con una API REST; la API coordina autenticación, datos y predicción; PostgreSQL almacena información transaccional normalizada y resultados; y un repositorio conserva artefactos del modelo.

El entrenamiento se ejecutará como tarea asíncrona para no bloquear consultas. Los procesos largos tendrán estado pendiente, en ejecución, completado o fallido. La publicación será una acción separada del entrenamiento y requerirá permiso, evitando que el último experimento reemplace automáticamente el modelo activo.

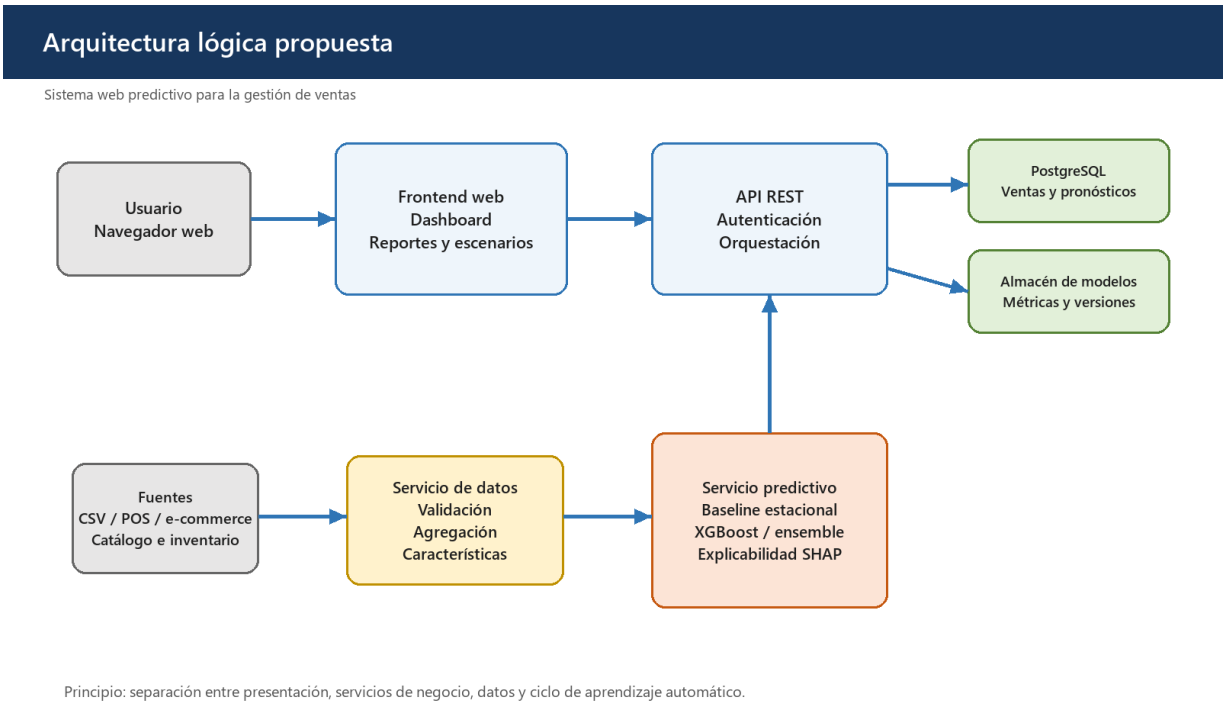


Figura 6. *Arquitectura lógica de la solución web predictiva*

Nota. Elaboración propia.

6.3.1.1 Componentes

Capa	Componente	Tecnología candidata	Responsabilidad
Presentación	Frontend web	React o Vue	Dashboard, filtros, cargas, métricas y administración.

Capa	Componente	Tecnología candidata	Responsabilidad
Aplicación	API REST	FastAPI	Autenticación, validación, orquestación y contratos.
Datos	Base relacional	PostgreSQL	Catálogo, ventas, cargas, pronósticos y auditoría.
Datos	Artefactos	Almacenamiento local/S3 compatible	Modelos, reportes y archivos fuente versionados.
Procesamiento	Servicio ETL	Python/pandas	Normalización, calidad, agregación y características.
IA	Servicio predictivo	scikit-learn/XGBoost/SHAP	Entrenamiento, evaluación, predicción y explicación.
Tareas	Cola y scheduler	Celery/RQ + Redis	Cargas, entrenamiento y monitoreo fuera de la petición web.
Infraestructura	Proxy y TLS	Nginx + certificados	HTTPS, límites, compresión y rutas.
Observabilidad	Logs y métricas	OpenTelemetry/Prometheus	Errores, latencia, estado y correlación.

Tabla 37. *Componentes propuestos para la arquitectura*

Nota. Elaboración propia.

6.3.1.2 Diseño de Datos

El diseño separa el evento de venta de su detalle para soportar múltiples productos por transacción, aunque una fuente inicial venga agregada. Los pronósticos almacenan valor, rango, nivel, fecha objetivo y ejecución del modelo. Las cargas conservan el archivo y el reporte de calidad.

El modelo entidad-relación es preliminar. Los nombres, claves y relaciones finales deberán ajustarse al sistema real y a las reglas de devolución, transferencia, promoción e inventario.

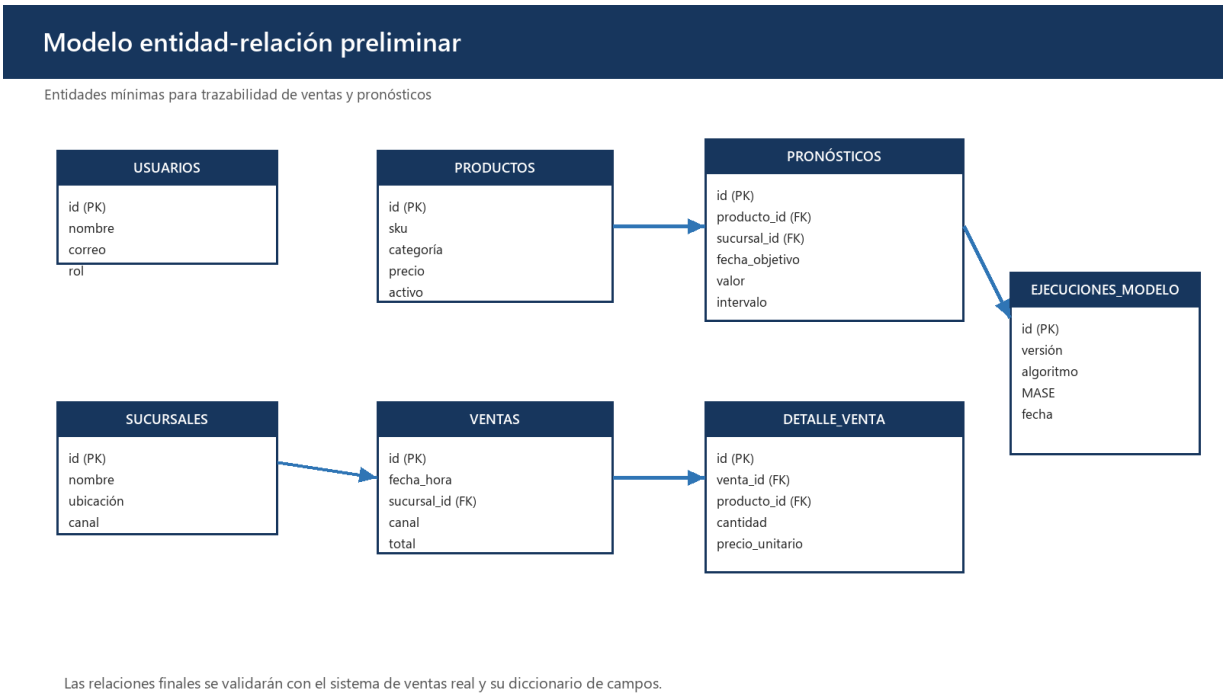


Figura 7. *Modelo entidad-relación preliminar*

Nota. Elaboración propia.

Entidad	Propósito	Campos principales
users	Usuarios y roles	id, nombre, correo, password_hash, rol, activo
stores	Sucursales y canales	id, nombre, ubicación, canal, activo
products	Catálogo normalizado	id, sku, nombre, categoría, marca, precio, activo
sales	Cabecera de venta	id, fecha_hora, store_id, canal, total, source_load_id
sale_items	Detalle vendido	id, sale_id, product_id, cantidad, precio, descuento
data_loads	Trazabilidad de carga	id, archivo, hash, usuario, estado, resumen, fecha
model_runs	Ejecuciones experimentales	id, fecha_corte, horizonte, algoritmo, métricas, estado
forecasts	Resultados publicados	id, run_id, nivel, clave, fecha_objetivo, valor, límites
actuals	Valores reales para monitoreo	nivel, clave, fecha, valor, fuente
audit_log	Auditoría	id, usuario, acción, entidad, fecha, metadatos

Tabla 38. *Entidades principales del sistema*

Nota. Elaboración propia.

6.3.1.3 Diseño de API REST

Método	Ruta	Propósito	Rol
POST	/api/v1/auth/login	Autenticar y emitir sesión segura.	Público
GET	/api/v1/catalog/products	Consultar productos y categorías.	Consulta
POST	/api/v1/data-loads	Crear carga y prevalidar archivo.	Analista
POST	/api/v1/data-loads/{id}/confirm	Confirmar importación validada.	Analista
GET	/api/v1/data-quality/summary	Consultar perfil de calidad y cobertura.	Analista
POST	/api/v1/model-runs	Iniciar experimento predictivo.	Analista
GET	/api/v1/model-runs/{id}	Consultar estado, parámetros y métricas.	Analista
POST	/api/v1/model-runs/{id}/publish	Publicar modelo aprobado.	Administrador
GET	/api/v1/forecasts	Consultar pronósticos filtrados.	Consulta
GET	/api/v1/forecasts/metrics	Consultar error y sesgo recientes.	Consulta
GET	/api/v1/alerts	Consultar alertas predictivas y de datos.	Consulta
GET	/api/v1/exports/forecasts	Exportar resultados con fecha de corte.	Consulta

Tabla 39. *Endpoints preliminares de la API*

Nota. Elaboración propia.

6.3.2 Arquitectura

El sistema adopta una arquitectura cliente-servidor en capas (Sommerville, 2016), desplegada en contenedores. La Figura 8 la representa y la Tabla 40 describe cada componente, señalando las diferencias respecto del diseño preliminar (Tabla 37).

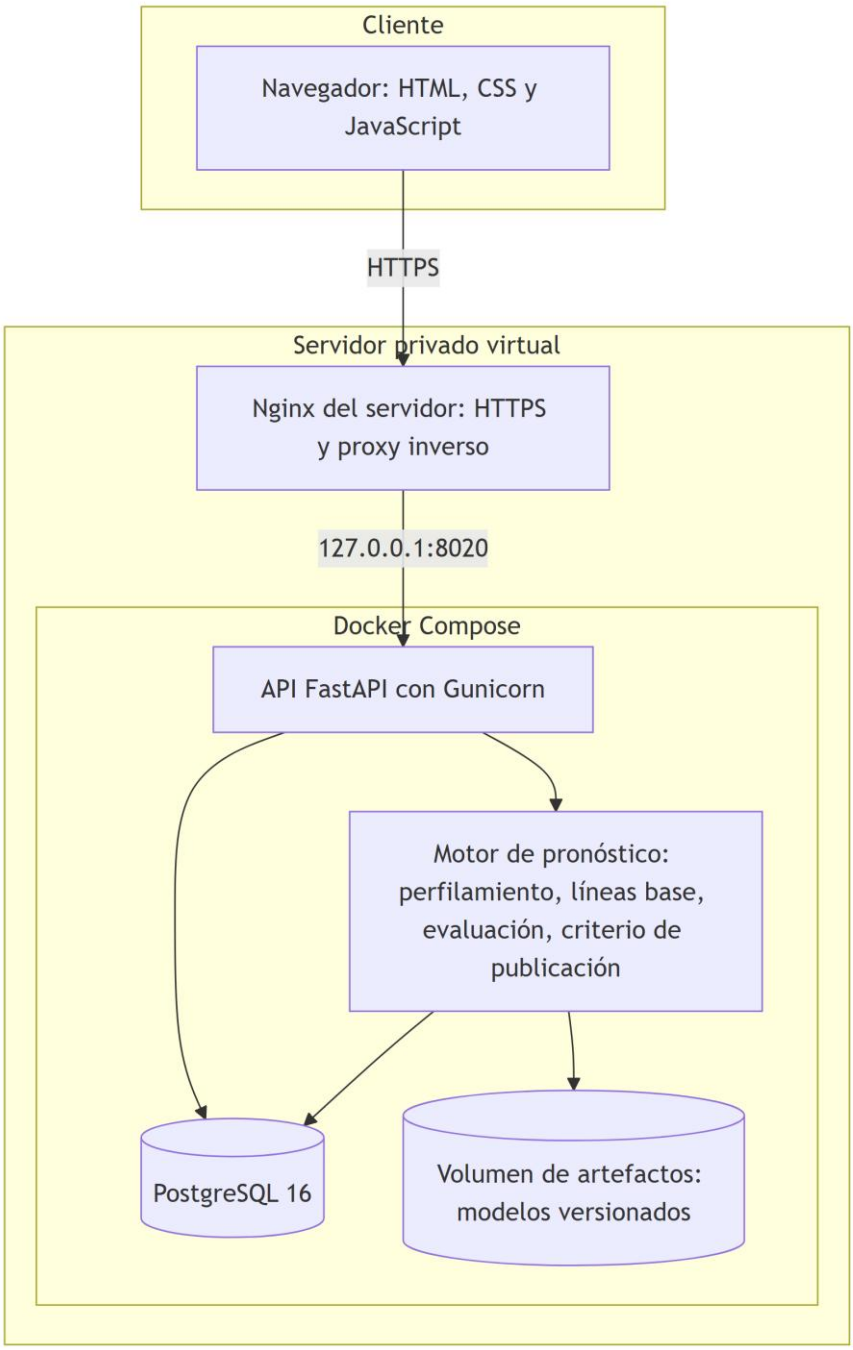


Figura 8. *Arquitectura desplegada de la solución*

Nota. Elaboración propia.

Capa	Componente	Tecnología	Diferencia respecto del diseño preliminar
Presentación	Interfaz web de seis módulos	HTML, CSS y JavaScript sin	El preliminar proponía React o

Capa	Componente	Tecnología	Diferencia respecto del diseño preliminar
		framework, servidos por la propia API	Vue; se optó por tecnología sin dependencias para reducir la complejidad de construcción y despliegue
Aplicación	API REST con autenticación por token y control de roles	FastAPI, Gunicorn con dos procesos de trabajo	Sin cambio
Datos	Base de datos relacional	PostgreSQL 16 en contenedor, con volumen persistente	Sin cambio respecto del preliminar; el prototipo intermedio usó MySQL por restricciones de hospedaje que desaparecieron al contar con servidor propio
Artefactos	Modelos entrenados	Archivos versionados por fecha en un volumen fuera de la imagen, con escritura atómica	Sin cambio conceptual; se añadió el versionado por nombre
Aprendizaje automático	Perfilamiento, seis líneas base, modelo de árboles potenciados, validación de origen móvil, métricas y criterio de publicación	scikit-learn, statsmodels, pandas, NumPy	El preliminar incluía XGBoost y SHAP; se usó el gradient boosting de scikit-learn y la explicabilidad queda pendiente
Tareas asíncronas	Cola y planificador	No implementado	El preliminar proponía Celery o RQ con Redis; el entrenamiento se ejecuta en la petición porque tarda segundos con el volumen actual
Infraestructura	Proxy inverso y TLS	Nginx del servidor y Let's Encrypt	Sin cambio

Capa	Componente	Tecnología	Diferencia respecto del diseño preliminar
Observabilidad	Registros y métricas	Verificación de salud y registro de entrenamientos	El preliminar proponía OpenTelemetry y Prometheus; pendiente

Tabla 40. *Componentes de la arquitectura y diferencias respecto del diseño preliminar*

Nota. Elaboración propia.

El servidor aloja otros proyectos, por lo que Nginx no forma parte del stack de contenedores del sistema: el servicio de la API se publica únicamente en la interfaz local del servidor y el Nginx existente lo expone al exterior. Esta decisión evita conflictos de puertos con los demás servicios y es la razón por la que el despliegue documenta reglas estrictas para la configuración compartida.

6.3.3 Modelo de datos

La base de datos sigue el diseño preliminar de separar la cabecera de la venta de su detalle, de modo que un ticket admita varios productos (Chen, 1976). La Figura 9 muestra el modelo entidad-relación implementado y la Tabla 41 el estado de cada entidad respecto de la Tabla 38 preliminar.

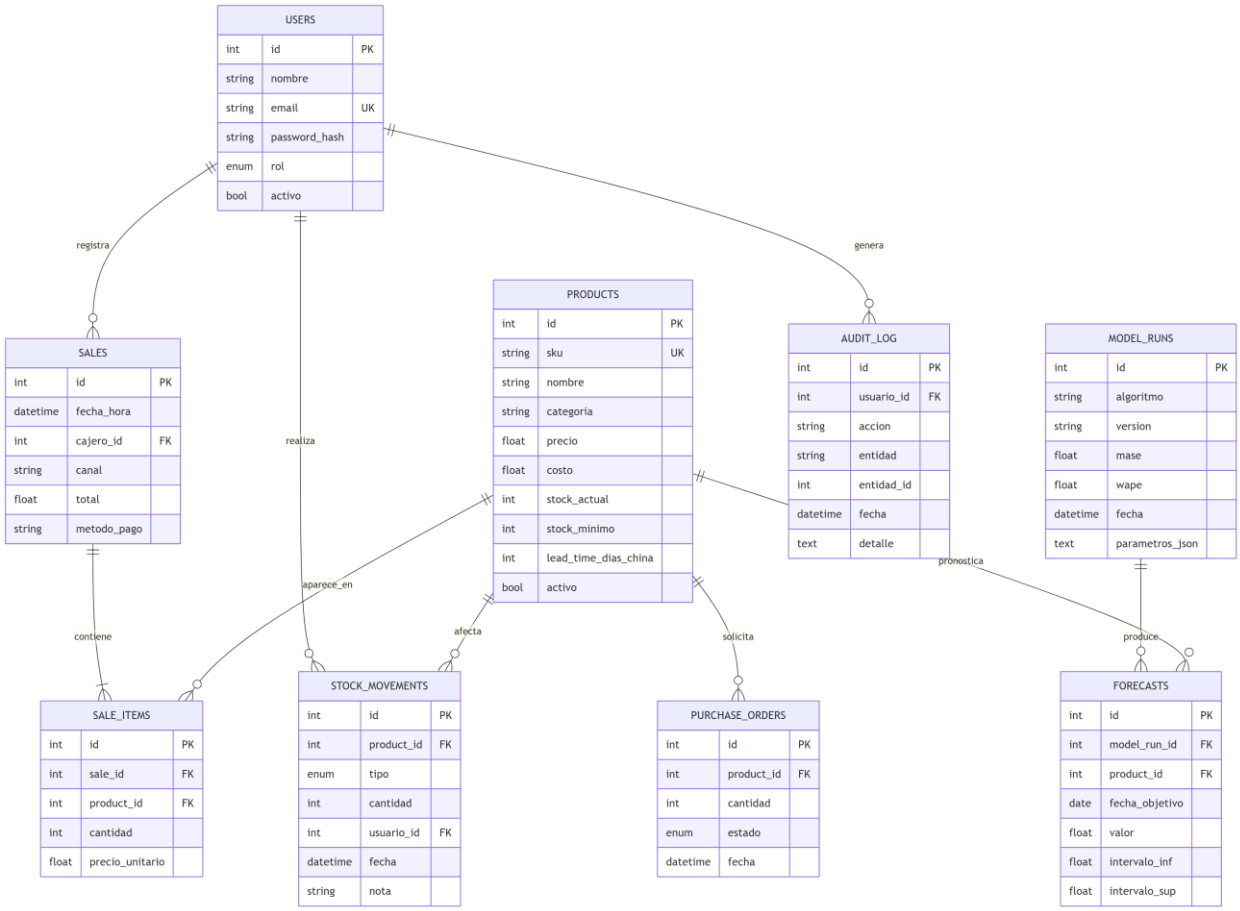


Figura 9. *Modelo entidad-relación implementado*

Nota. Elaboración propia.

Entidad (Tabla 38 preliminar)	Estado	Observación
users	Implementada	Roles administrador y cajero
products	Implementada	Se añadieron existencia, mínimo, costo y lead time; falta marca
sales y sale_items	Implementadas	Cabecera y detalle separados; falta el descuento por línea y la referencia a sucursal
stores	Pendiente	El canal se registra como texto en la venta; la entidad de sucursal es prerrequisito del pronóstico por ubicación
data_loads	Pendiente	Depende del importador (RF-03)
model_runs	Implementada	Registra algoritmo, versión, métricas, protocolo de evaluación, ranking de candidatos y decisión de publicación

Entidad (Tabla 38 preliminar)	Estado	Observación
forecasts	Definida, sin uso	Los pronósticos se calculan en cada consulta; su persistencia es prerrequisito del monitoreo (RF-16)
actuals	Pendiente	Depende de la persistencia de pronósticos
audit_log	Definida, sin uso	Prerrequisito de la bitácora general (RF-17)
stock_movements y purchase_orders	Añadidas	No figuraban en el preliminar; soportan la gestión de inventario y el lead time

Tabla 41. *Estado de las entidades del modelo de datos respecto del diseño preliminar*

Nota. Elaboración propia.

El esquema está normalizado hasta la tercera forma normal: las cantidades y precios de cada producto vendido residen en el detalle, el catálogo no repite datos de venta, y los movimientos de existencia son la única fuente de la cual se deriva el inventario. El esquema se crea automáticamente al arrancar, en un proceso previo al inicio de los servidores web para evitar que varios procesos intenten crearlo a la vez; la incorporación de migraciones versionadas es una mejora pendiente.

6.3.4 Diseño de la API

La API sigue el estilo REST (Fielding, 2000): recursos identificados por rutas, operaciones expresadas con los métodos HTTP y autenticación sin estado mediante tokens JWT. La Tabla 42 presenta los endpoints implementados y el rol que los autoriza; el control se verifica en el servidor en cada petición, no en la interfaz.

Método	Ruta	Propósito	Rol
POST	/auth/login	Autenticar y emitir token	Público
GET	/auth/me	Consultar la sesión actual	Autenticado
PUT	/auth/me/password	Cambiar la propia contraseña, exigiendo la actual	Autenticado
GET, POST, PUT, DELETE	/products	Catálogo	Consulta: autenticado; escritura: administrador

Método	Ruta	Propósito	Rol
GET	/products/stock-bajo	Productos bajo el mínimo	Autenticado
GET, POST	/sales	Historial y registro de ventas	Autenticado
POST	/inventory/receive	Recepción de mercadería	Autenticado
POST	/inventory/adjust	Ajuste de existencia	Administrador
GET, POST	/inventory/purchase-orders	Pedidos de compra	Administrador
GET	/dashboard/summary, /dashboard/trend	Indicadores y tendencia	Autenticado
GET	/predictions/forecast?horizonte	Histórico y pronóstico	Administrador
GET	/predictions/signals	Señales por producto	Administrador
GET	/predictions/recommendations	Recomendaciones de reabastecimiento	Administrador
GET	/predictions/series-profile	Perfil de intermitencia por producto	Administrador
POST	/predictions/retrain	Evaluar candidatos y publicar si procede	Administrador
GET	/predictions/model	Último entrenamiento registrado: algoritmo, métricas y si se publicó	Administrador
GET, POST	/users	Cuentas	Administrador
PUT	/users/{id}/rol, /users/{id}/estado, /users/{id}/password	Rol, activación y restablecimiento	Administrador
GET	/api/health	Verificación de salud	Público

Tabla 42. *Endpoints de la API implementados*

Nota. Elaboración propia.

Respecto de la Tabla 39 preliminar, las rutas no llevan aún el prefijo de versión /api/v1 y faltan los recursos de cargas de datos, calidad de datos, métricas de pronóstico y exportación, todos ellos dependientes del importador. Los recursos de perfilamiento y de cambio de contraseña no estaban previstos y se añadieron.

6.3.5 Diseño del motor de pronóstico

El motor materializa las secciones 2.2.2 a 2.2.6 del marco teórico. La Tabla 43 resume sus componentes y la Figura 10 el flujo de una recalibración.

Componente	Diseño	Sección del marco teórico
Variable objetivo	Total diario de ventas en quetzales (agregado del negocio)	2.2.1 y 3.1.1; el nivel por producto es la siguiente iteración por la intermitencia del catálogo
Características	Día de la semana, fin de semana, mes (codificado con seno y coseno), día del mes, indicadores de diciembre, Bono 14 y Caravana, rezagos de 1, 7, 14 y 30 días, medias móviles de 7 y 30 días calculadas solo con fechas anteriores	2.2.4, Tabla 2
Control de fuga	Todos los rezagos y ventanas se desplazan un periodo, de modo que ninguna característica del día t utiliza información de t o posterior	2.2.2 y 2.2.3 (Bergmeir y Benítez, 2012)
Líneas base	Naïve, naïve estacional de periodo 7, media móvil, suavizamiento exponencial simple con ajuste del parámetro, Holt-Winters aditivo y ARIMA(1,1,1)	2.2.2.2 (Hyndman y Athanasopoulos, 2021)
Modelo candidato	Árboles potenciados por gradiente de scikit-learn, con hiperparámetros fijos y registrados	2.2.3.1
Protocolo de evaluación	Origen móvil con cinco ventanas de 30 días; en cada ventana, todos los candidatos se reentrenan con el pasado disponible y predicen el horizonte completo de forma recursiva	2.2.5 (Tashman, 2000)
Métricas	MASE escalado con el error in-sample del naïve estacional (Hyndman y Koehler, 2006), WAPE, MAE, RMSE, sMAPE y sesgo; las indefinidas se reportan como tales y no como cero	2.2.5, Tabla 3
Criterio de publicación	Mejora de MASE de al menos 10 % sobre el naïve estacional, sesgo relativo no mayor de 20 % y victoria en más de la mitad de las ventanas; umbrales configurables sin tocar código	2.2.5.1

Componente	Diseño	Sección del marco teórico
Versionado	Cada ejecución registra algoritmo, hiperparámetros, protocolo, métricas de todos los candidatos y decisión; el artefacto se guarda con nombre versionado y escritura atómica	2.2.7
Perfilamiento previo	Proporción de ceros, ADI y CV^2 por producto, con clasificación de Syntetos, Boylan y Croston (2005)	2.2.2.3

Tabla 43. *Componentes del motor de pronóstico y su fundamento teórico*

Nota. Elaboración propia.

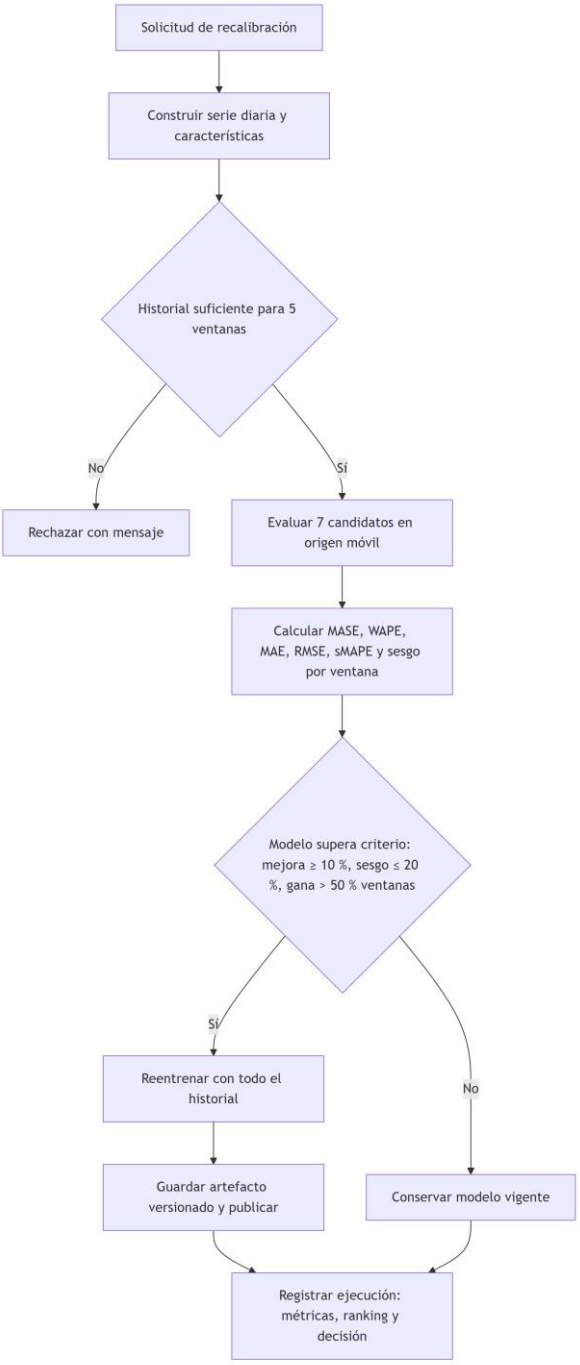


Figura 10. *Flujo de una recalibración del modelo*

Nota. Elaboración propia.

Dos decisiones de diseño merecen justificación explícita. La primera es evaluar con el horizonte de 30 días, que es el que consume el tablero, en lugar de uno más corto: evaluar a siete días y publicar para treinta mediría un problema distinto del que el sistema resuelve. La segunda es reentrenar cada candidato en cada ventana en lugar de entrenar una vez y desplazar el conjunto

de prueba; es más costoso, pero es lo que hace que la validación reproduzca el uso real, en el que el modelo se recalibra a medida que llegan datos (Tashman, 2000).

6.3.6 Prototipado de Baja Fidelidad

Los wireframes representan estructura y flujo, no diseño visual definitivo. La navegación lateral prioriza Resumen, Ventas, Pronósticos, Inventario y Configuración. El usuario de consulta no verá opciones de entrenamiento o administración.

El panel ejecutivo resume ventas, pronóstico, error y alertas. Los valores mostrados en los wireframes son deliberadamente neutros o ilustrativos; no corresponden a datos reales de la empresa.



Figura 11. *Wireframe del panel ejecutivo*

Nota. Elaboración propia.

6.3.6.1 Flujo de Importación

El flujo separa selección, detección de columnas, validación y confirmación. El archivo no se incorpora a las tablas productivas mientras existan errores críticos. Los problemas corregibles se presentan con fila, campo, valor y regla infringida.



Figura 12. *Wireframe de importación y validación de ventas*

Nota. Elaboración propia.

6.3.6.2 Flujo de Consulta de Pronósticos

La consulta permite cambiar sucursal, categoría y horizonte. El gráfico diferencia histórico y pronóstico; el panel lateral resume factores que contribuyen al resultado. Una vista técnica adicional mostrará versión, fecha de corte, métrica y límites.



Figura 13. *Wireframe del análisis de pronósticos*

Nota. Elaboración propia.

6.3.7 Diseño de la interfaz

La interfaz consta de seis módulos, cada uno en una pantalla: acceso, centro de control, ventas, productos e inventario, pronóstico y usuarios. Los wireframes de la sección 6.3.6 (Figuras 11 a 13) guiaron la estructura: navegación lateral con la opción activa resaltada, indicadores en tarjetas, gráfica que distingue histórico de pronóstico por color y por trazo, y panel lateral de señales y recomendaciones. Respecto de los wireframes, los módulos de importación y de configuración no se construyeron, y el módulo de usuarios, que el preliminar dejaba fuera, se incorporó por el requerimiento RF-19.

El diseño atiende los criterios del RNF-06: enlace para saltar al contenido, etiquetas asociadas a todos los campos, anuncio de los mensajes de estado a los lectores de pantalla, cierre de ventanas emergentes con la tecla Escape, tablas con encabezados declarados y contraste de la paleta revisado, con ajustes pendientes en los mensajes de error. La evaluación formal contra WCAG 2.2 (World Wide Web Consortium, 2023) queda pendiente. Las pantallas se documentan en el manual de usuario, versión 0.2, y se muestran como evidencia en la sección 6.4.4.

6.3.8 Diseño de seguridad

En cumplimiento del RNF-03, la autenticación emite tokens JWT firmados con una clave que solo existe en la configuración del servidor; en el despliegue en contenedores el sistema se niega a arrancar si no se define. Las contraseñas se almacenan con bcrypt, se exige una longitud mínima de diez caracteres con letras y números, y cambiar la propia contraseña requiere conocer la actual. La autorización se verifica en el servidor en cada endpoint; la ocultación de opciones en la interfaz es solo una comodidad. Toda salida de datos del servidor se escapa antes de insertarse en la página, lo que cierra la vía de inyección de código en el navegador. El sistema impide que el último administrador activo pierda su rol o se desactive, y ofrece una vía de recuperación por línea de comandos en el servidor. Las cuentas de demostración se crean con contraseñas aleatorias que se muestran una única vez.

6.4 Desarrollo o implementación

6.4.1 Tecnologías y justificación

Componente	Tecnología	Justificación
Lenguaje del servidor	Python 3.12	Ecosistema de aprendizaje automático y series temporales; competencia del equipo
Framework de API	FastAPI	Validación automática de entradas con Pydantic, documentación interactiva generada, rendimiento asíncrono
Acceso a datos	SQLAlchemy	Abstracción del motor de base de datos, que permitió pasar de SQLite en desarrollo a PostgreSQL en producción sin cambios de código
Base de datos	PostgreSQL 16	Motor especificado en el diseño preliminar; tipos enumerados, integridad referencial y madurez
Aprendizaje automático	scikit-learn, statsmodels	Implementaciones de referencia para árboles potenciados y para los métodos clásicos de series temporales, lo que evita errores en las líneas base
Interfaz	HTML, CSS y JavaScript, Chart.js	Sin proceso de compilación ni dependencias de framework; se sirve desde la misma API
Contenedores	Docker Compose	Reproducibilidad del despliegue (RNF-12) y paridad entre desarrollo y producción (Merkel, 2014)

Componente	Tecnología	Justificación
Servidor web	Gunicorn con Uvicorn, Nginx	Procesos de trabajo controlados y proxy inverso con TLS
Pruebas	pytest	Suite de 128 pruebas ejecutable en segundos
Control de versiones	Git y GitHub	Historial verificable, ramas por cambio y revisión mediante pull requests

Tabla 44. *Tecnologías utilizadas y su justificación*

Nota. Elaboración propia.

6.4.2 Proceso de construcción

El desarrollo siguió un proceso iterativo en el que cada cambio lógico se construyó en una rama, se acompañó de sus pruebas, se documentó en un pull request y se integró tras revisión, para desplegarse después con un comando reproducible. La Tabla 45 resume las iteraciones de la fase, cada una verificable en el historial del repositorio.

Iteración	Contenido	Resultado verificable
1	Auditoría de alineación entre el documento y el código	Informe con el estado de cada requerimiento y defectos detectados
2	Corrección de cuatro defectos críticos: ventanas modales visibles de forma permanente, inyección de código en la interfaz, cálculo erróneo de días hasta el próximo evento y horizonte sin validar	Defectos cerrados con verificación reproducible
3	Contenerización con Docker Compose y migración a PostgreSQL; corrección de una condición de carrera en la creación del esquema	Despliegue reproducido en local y en el servidor
4	Documentación de estado y despliegue para el equipo	Guía de despliegue y estado del proyecto
5	Perfilamiento de series con clasificación de intermitencia	Endpoint y 20 pruebas
6	Marco de evaluación honesto: seis líneas base, validación de origen móvil, métricas corregidas y criterio de publicación	51 pruebas; ranking de candidatos registrado en cada ejecución
7	Administración de usuarios, roles y contraseñas; eliminación de credenciales del código y de la pantalla de acceso	27 pruebas; cuentas gestionadas desde la base de datos

Iteración	Contenido	Resultado verificable
8	Rediseño de la interfaz y mejoras de accesibilidad	Seis módulos con navegación, tema y registro de ventas renovados
9	Simulador de ventas sin funciones compartidas con el modelo	30 pruebas; validación técnica con demanda censurada
10	Manual de usuario y guía de demostración	Documentos versionados en el repositorio

Tabla 45. *Iteraciones del desarrollo durante la fase*

Nota. Elaboración propia a partir del historial del repositorio.

6.4.3 Entorno de desarrollo y despliegue

El entorno de desarrollo utiliza un entorno virtual de Python con las mismas versiones fijadas que la imagen de producción, una base SQLite para iteración rápida y Docker Compose con PostgreSQL para reproducir exactamente el entorno del servidor. El despliegue en producción consiste en actualizar el repositorio en el servidor y reconstruir los contenedores; la base de datos y los modelos entrenados residen en volúmenes que sobreviven a cada reconstrucción, lo que se verificó destruyendo y recreando el contenedor de la aplicación y comprobando que el modelo publicado conservaba su suma de verificación. La configuración sensible —clave de firma de tokens, credenciales de la base de datos— se inyecta por variables de entorno y nunca forma parte de la imagen ni del repositorio.

6.4.4 Evidencia del sistema en funcionamiento

El sistema se encuentra desplegado y accesible con certificado TLS válido. Las Figuras 14 a 19 muestran los seis módulos en operación.

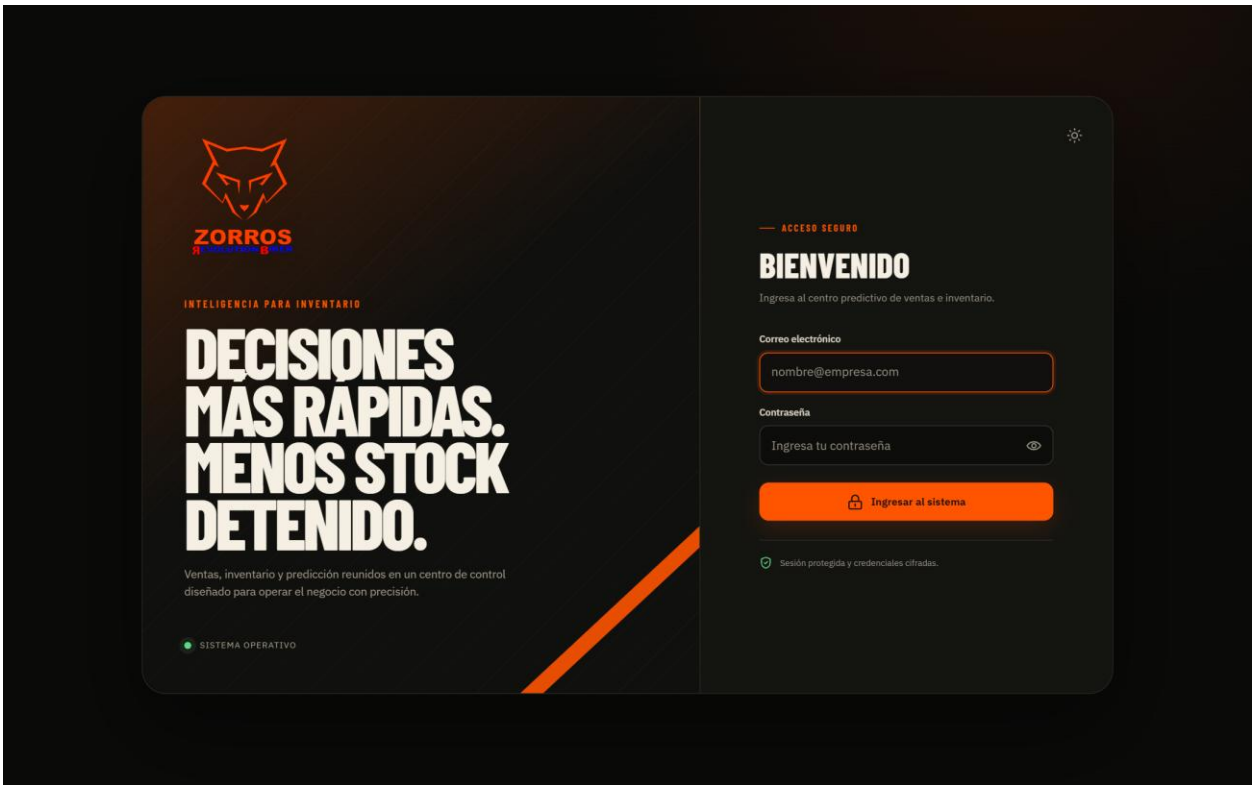


Figura 14. *Pantalla de acceso*

Nota. Captura del sistema en producción.



Figura 15. *Centro de control con indicadores, proyección del próximo mes y ventas reales frente a proyectadas*

Nota. Captura del sistema en producción.

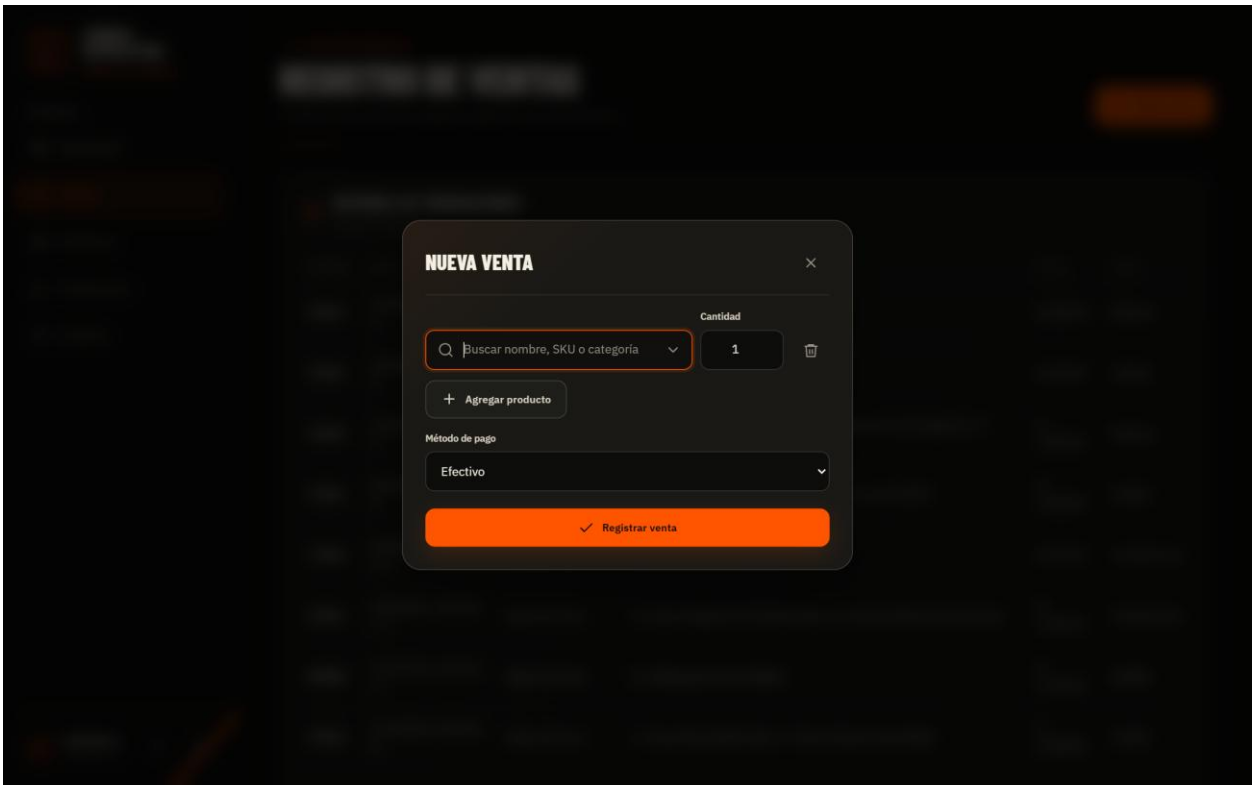


Figura 16. *Registro de ventas con el formulario de nueva venta*

Nota. Captura del sistema en producción.

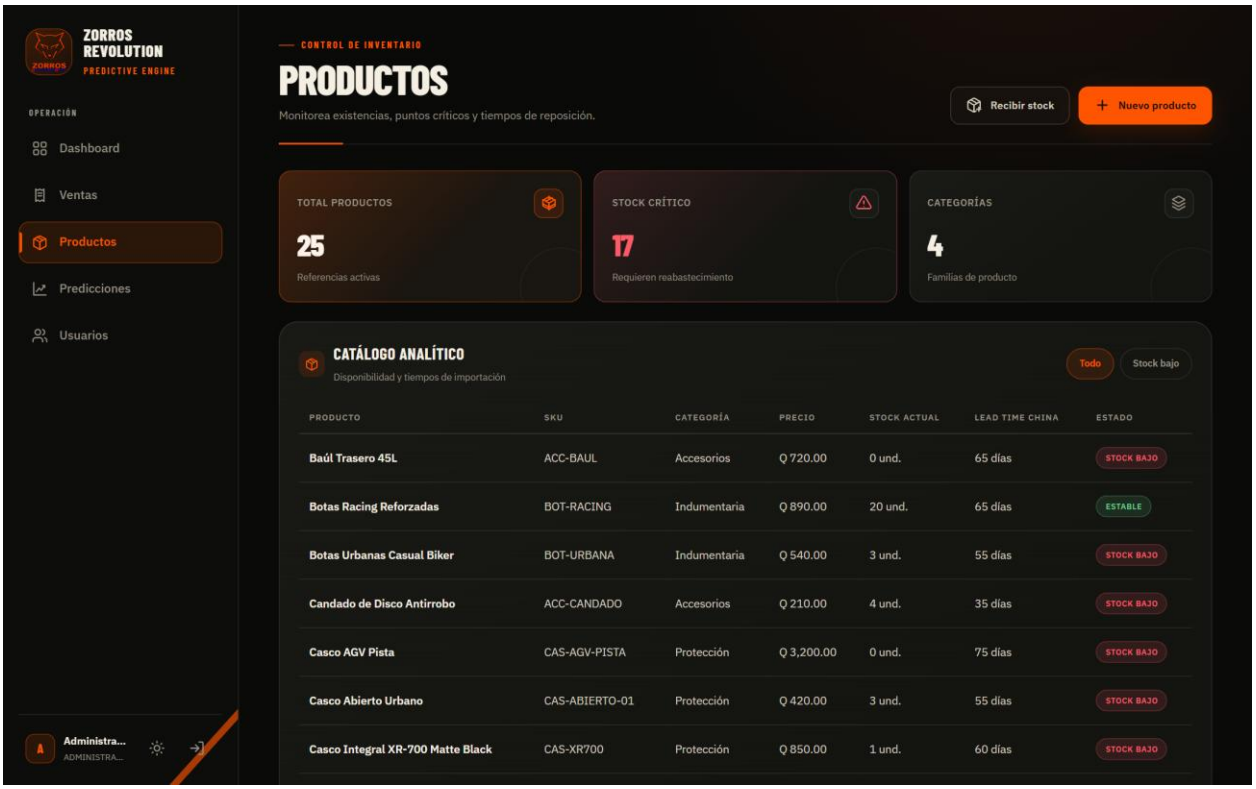


Figura 17. *Productos e inventario con el filtro de existencia baja*

Nota. Captura del sistema en producción.



Figura 18. *Pronóstico de ventas con señales por producto, recomendaciones de reabastecimiento y resultado de la recalibración*

Nota. Captura del sistema en producción.

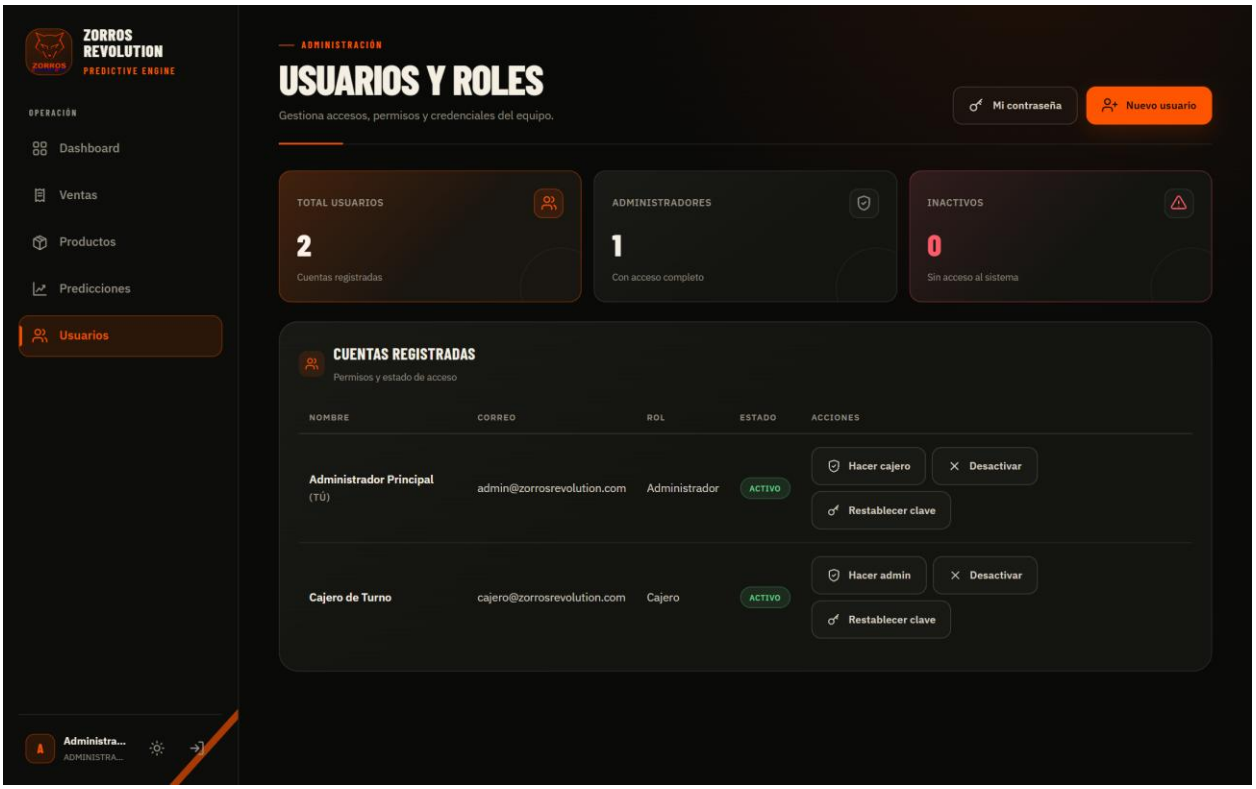


Figura 19. *Administración de usuarios y roles*

Nota. Captura del sistema en producción.

6.5 Plan de pruebas

6.5.1 Estrategia

La estrategia combina cuatro niveles, conforme a la norma ISO/IEC/IEEE 29119 (International Organization for Standardization, 2022b): pruebas unitarias automatizadas de la lógica de negocio y del motor de pronóstico; pruebas de integración automatizadas de la API sobre una base de datos aislada; pruebas funcionales del sistema completo en el entorno de producción; y pruebas no funcionales de seguridad, rendimiento y persistencia. Todas las pruebas automatizadas se ejecutan antes de integrar cualquier cambio. Un principio guió la suite del motor de pronóstico: los valores esperados de cada métrica se calcularon a mano en la propia prueba, no a partir del código que se está probando, porque una fórmula comparada consigo misma pasa la prueba aunque esté equivocada. Ese principio permitió detectar que el cálculo original del MASE no correspondía a la definición de Hyndman y Koehler (2006).

6.5.2 Matriz de casos de prueba

ID	Requerimiento	Resultado esperado	Tipo	Estado
CP-01	RF-01	Sin token la API responde 401; con rol de cajero, los recursos de administrador responden 403	Integración	Aprobado
CP-02	RF-19	Una contraseña de menos de diez caracteres, sin letras o sin números, se rechaza con el motivo	Integración	Aprobado
CP-03	RF-19	La contraseña se almacena como hash bcrypt y nunca aparece en una respuesta	Integración	Aprobado
CP-04	RF-19	No es posible desactivar la propia cuenta, quitarse el rol de administrador ni degradar al último administrador activo	Integración	Aprobado
CP-05	RF-19	Un usuario desactivado no puede iniciar sesión; tras restablecer una contraseña, la anterior deja de funcionar	Integración	Aprobado
CP-06	RF-20	Registrar una venta descuenta la existencia y rechaza vender más unidades de las disponibles	Funcional en producción	Aprobado
CP-07	RF-06	Los estadísticos de intermitencia coinciden con valores calculados a mano y la clasificación respeta los cortes de Syntetos, Boylan y Croston	Unitaria	Aprobado
CP-08	RF-06	El relleno de días sin venta arranca en la primera venta de cada producto, no en el inicio del catálogo	Unitaria	Aprobado
CP-09	RF-08	MASE, WAPE, MAE, RMSE, sMAPE y sesgo coinciden con valores calculados a mano; las métricas indefinidas	Unitaria	Aprobado

ID	Requerimiento	Resultado esperado	Tipo	Estado
		devuelven "indefinido", no cero		
CP-10	RF-08	El MASE se escala con el error del conjunto de entrenamiento y no cambia al cambiar el conjunto de prueba	Unitaria	Aprobado
CP-11	RF-08	En la validación de origen móvil el pronosticador nunca recibe datos posteriores al corte	Unitaria	Aprobado
CP-12	RF-07	Cada línea base devuelve el horizonte solicitado y valores coherentes en casos calculados a mano	Unitaria	Aprobado
CP-13	RF-09	Con un umbral imposible el modelo no se publica, el artefacto vigente conserva su suma de verificación y el intento queda registrado	Funcional	Aprobado
CP-14	RF-09	Los umbrales del criterio se leen de la configuración en tiempo de ejecución	Unitaria	Aprobado
CP-15	RF-10	Un horizonte fuera del rango permitido responde 422	Integración	Aprobado
CP-16	RF-21	Durante un evento de temporada, los días hasta el evento son cero y el refuerzo de reabastecimiento se aplica	Unitaria	Aprobado
CP-17	RNF-03	La interfaz escapa los datos del servidor; un nombre de producto con etiquetas HTML no ejecuta código	Funcional	Aprobado
CP-18	RNF-12	El sistema arranca desde cero en contenedores con base de datos vacía sin errores	Funcional	Aprobado
CP-19	RNF-08	Tras recrear el contenedor, el modelo publicado y los datos se conservan	No funcional	Aprobado

ID	Requerimiento	Resultado esperado	Tipo	Estado
CP-20	RNF-01	Reentrenamiento completo de siete candidatos en cinco ventanas	No funcional	Aprobado: 3 a 5 s en el servidor
CP-21	RNF-05	80 % de tareas completadas por usuarios piloto	Aceptación	Pendiente de la prueba piloto
CP-22	RNF-06	Revisión WCAG 2.2 nivel AA	No funcional	Pendiente

Tabla 46. *Matriz de casos de prueba trazada a los requerimientos*

Nota. Elaboración propia.

6.5.3 Defectos detectados y corregidos

La ejecución del plan detectó defectos que se corrigieron con su prueba de regresión correspondiente (Tabla 47). Se documentan porque evidencian que las pruebas cumplieron su función y porque varios de ellos habrían sido invisibles en el uso normal.

Defecto	Cómo se detectó	Corrección
Las ventanas modales eran visibles de forma permanente por una regla de estilo que anulaba el atributo de ocultación	Auditoría de la interfaz	Regla de estilo con prioridad y prueba visual
Datos del servidor insertados en la página sin escapar, con posibilidad de robo de sesión	Auditoría de seguridad	Función de escape aplicada en todas las inserciones (CP-17)
El cálculo de días hasta el próximo evento devolvía 351 durante el propio evento	Prueba unitaria con nueve casos calculados a mano	Ventanas de evento con valor cero durante el evento (CP-16)
El horizonte del pronóstico no tenía límite y permitía bloquear el servidor	Auditoría de la API	Validación del rango (CP-15)
Dos procesos creaban el esquema simultáneamente sobre PostgreSQL y uno fallaba	Primer arranque en contenedores con base vacía	Creación del esquema en un proceso previo (CP-18)
El MASE se escalaba con el conjunto de prueba en lugar del de entrenamiento	Prueba unitaria contra la definición de Hyndman y Koehler	Escalado in-sample (CP-10)
Las métricas indefinidas devolvían cero, lo que se presentaba como error perfecto	Prueba unitaria de casos límite	Valor indefinido explícito (CP-09)
Los umbrales de publicación no eran configurables por estar fijados al definir la función	Prueba de la vía de rechazo	Lectura de la configuración en tiempo de llamada (CP-14)

Defecto	Cómo se detectó	Corrección
La pantalla de acceso mostraba las credenciales de administrador	Búsqueda de credenciales en el repositorio	Eliminadas; contraseñas generadas al azar
La pantalla de pronóstico indicaba "Sin entrenar" al abrirse aunque existiera un modelo publicado	Revisión de las capturas para este documento	Consulta del último entrenamiento al cargar la pantalla, con cinco pruebas de la vía

Tabla 47. *Defectos detectados durante las pruebas y su corrección*

Nota. Elaboración propia.

6.5.4 Pruebas pendientes

Tres pruebas quedan para la fase de prueba piloto por requerir a la empresa o su volumen real: la prueba de aceptación de usuario con el cuestionario de la sección 3.3.2 (CP-21), la revisión formal de accesibilidad (CP-22) y la medición del percentil 95 de tiempo de respuesta con la carga piloto (RNF-01). Se añadirá, además, la prueba de aceptación del importador de históricos en cuanto se implemente el RF-03, con un archivo real de la empresa como caso de prueba.

Referencias

Aiken, L. R. (1985). Three coefficients for analyzing the reliability and validity of ratings. *Educational and Psychological Measurement, 45*(1), 131–142. https://doi.org/10.1177/0013164485451012

Apache Software Foundation. (2004). *Apache License, version 2.0*. https://www.apache.org/licenses/LICENSE-2.0

Asamblea Nacional Constituyente. (1985). *Constitución Política de la República de Guatemala*. Diario de Centro América.

Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences, 191*, 192–213. https://doi.org/10.1016/j.ins.2011.12.028

Chen, P. P.-S. (1976). The entity-relationship model—Toward a unified view of data. *ACM Transactions on Database Systems, 1*(1), 9–36. https://doi.org/10.1145/320434.320440

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. https://doi.org/10.1145/2939672.2939785

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.ª ed.). Lawrence Erlbaum Associates.

Congreso de la República de Guatemala. (1970). *Decreto 2-70, Código de Comercio de Guatemala*. Diario de Centro América.

Congreso de la República de Guatemala. (1996). *Decreto 33-96, Reformas al Código Penal, Decreto 17-73* (delitos informáticos, artículos 274 "A" a 274 "G"). Diario de Centro América.

Congreso de la República de Guatemala. (1998). *Decreto 33-98, Ley de Derecho de Autor y Derechos Conexos*. Diario de Centro América.

Congreso de la República de Guatemala. (2008). *Decreto 57-2008, Ley de Acceso a la Información Pública*. Diario de Centro América.

Cronbach, L. J. (1951). Coefficient alpha and the internal structure of tests. *Psychometrika, 16*(3), 297–334. https://doi.org/10.1007/BF02310555

Croston, J. D. (1972). Forecasting and stock control for intermittent demands. *Operational Research Quarterly, 23*(3), 289–303. https://doi.org/10.1057/jors.1972.50

Davis, F. D. (1989). Perceived usefulness, perceived ease of use, and user acceptance of information technology. *MIS Quarterly, 13*(3), 319–340. https://doi.org/10.2307/249008

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics, 13*(3), 253–263. https://doi.org/10.1080/07350015.1995.10524599

Fielding, R. T. (2000). *Architectural styles and the design of network-based software architectures* [Tesis doctoral, University of California, Irvine]. https://ics.uci.edu/~fielding/pubs/dissertation/top.htm

Fildes, R., Ma, S., & Kolassa, S. (2022). Retail forecasting: Research and practice. International Journal of Forecasting, 38(4), 1283–1318. https://doi.org/10.1016/j.ijforecast.2019.06.004

Free Software Foundation. (2007). *GNU Lesser General Public License, version 3*. https://www.gnu.org/licenses/lgpl-3.0.html

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Ganguly, P., & Mukherjee, I. (2024). Enhancing retail sales forecasting with optimized machine learning models. arXiv. https://doi.org/10.48550/arXiv.2410.13773

Ganzevoort, R. C., & van Vuuren, J. H. (2023). A two-phased cluster-based approach towards ranked forecast-model selection. Machine Learning with Applications, 13, 100482. https://doi.org/10.1016/j.mlwa.2023.100482

Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, P. (2014). *Metodología de la investigación* (6.ª ed.). McGraw-Hill.

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. International Journal of Forecasting, 22(4), 679–688. https://doi.org/10.1016/j.ijforecast.2006.03.001

Instituto Nacional de Estadística. (2023). Informe del empleador: Primer trimestre 2022. https://sen.ine.gob.gt/wp-content/uploads/2023/09/Reporte-Informe-del-Empleador-T1_2022.pdf

International Organization for Standardization. (2011). *ISO/IEC 25010:2011. Systems and software engineering — Systems and software Quality Requirements and Evaluation (SQuaRE) — System and software quality models*. ISO.

International Organization for Standardization. (2018). *ISO/IEC/IEEE 29148:2018. Systems and software engineering — Life cycle processes — Requirements engineering*. ISO.

International Organization for Standardization. (2022a). *ISO/IEC 27001:2022. Information security, cybersecurity and privacy protection — Information security management systems — Requirements*. ISO.

International Organization for Standardization. (2022b). *ISO/IEC/IEEE 29119-1:2022. Software and systems engineering — Software testing — Part 1: General concepts*. ISO.

Laudon, K. C., & Laudon, J. P. (2020). *Management information systems: Managing the digital firm* (16.ª ed.). Pearson.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems, 30. https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. International Journal of Forecasting, 38(4), 1346–1364. https://doi.org/10.1016/j.ijforecast.2021.11.013

Mejía, S., & Aguilar, J. (2024). A demand forecasting system of product categories defined by their time series using a hybrid approach of ensemble learning with feature engineering. Computing, 106(12), 3945–3965. https://doi.org/10.1007/s00607-024-01320-y

Merkel, D. (2014). Docker: Lightweight Linux containers for consistent development and deployment. *Linux Journal, 2014*(239), artículo 2.

Open Source Initiative. (s. f.). *Licenses*. Recuperado el 19 de septiembre de 2026, de https://opensource.org/licenses

Organización de las Naciones Unidas. (2015). *Transformar nuestro mundo: la Agenda 2030 para el Desarrollo Sostenible* (Resolución A/RES/70/1). ONU.

Osterwalder, A., & Pigneur, Y. (2010). *Business model generation: A handbook for visionaries, game changers, and challengers*. Wiley.

Parlamento Europeo y Consejo de la Unión Europea. (2016). Reglamento (UE) 2016/679, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos

personales y a la libre circulación de estos datos (Reglamento General de Protección de Datos). *Diario Oficial de la Unión Europea, L 119*, 1–88.

Project Management Institute. (2021). *A guide to the project management body of knowledge (PMBOK guide)* (7.ª ed.). PMI.

Schwaber, K., & Sutherland, J. (2020). *The Scrum guide: The definitive guide to Scrum: The rules of the game*. Scrum.org. https://scrumguides.org/scrum-guide.html

Schwalbe, K. (2019). *Information technology project management* (9.ª ed.). Cengage Learning.

Sommerville, I. (2016). *Software engineering* (10.ª ed.). Pearson.

Superintendencia de Administración Tributaria. (2018). *Acuerdo de Directorio Número 13-2018, Régimen de Factura Electrónica en Línea (FEL)*. Diario de Centro América.

Suresh, B. S., Suresh, M., & Kang, D.-K. (2026). Meta-LLSTM: Meta-learning enhanced learnable LSTM for retail sales forecasting. Scientific Reports, 16, 23928. https://doi.org/10.1038/s41598-026-54836-y

Swami, A., Shah, N., & Ray, P. (2020). Predicting future sales of retail products using machine learning. arXiv. https://doi.org/10.48550/arXiv.2008.07779

Syntetos, A. A., & Boylan, J. E. (2005). The accuracy of intermittent demand estimates. *International Journal of Forecasting, 21*(2), 303–314. https://doi.org/10.1016/j.ijforecast.2004.10.001

Syntetos, A. A., Boylan, J. E., & Croston, J. D. (2005). On the categorization of demand patterns. *Journal of the Operational Research Society, 56*(5), 495–503. https://doi.org/10.1057/palgrave.jors.2601841

Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting, 16*(4), 437–450. https://doi.org/10.1016/S0169-2070(00)00065-0

Taylor, S. J., & Letham, B. (2018). Forecasting at scale. The American Statistician, 72(1), 37–45. https://doi.org/10.1080/00031305.2017.1380080

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin, 1*(6), 80–83. https://doi.org/10.2307/3001968

World Wide Web Consortium. (2023). *Web Content Accessibility Guidelines (WCAG) 2.2*. W3C. https://www.w3.org/TR/WCAG22/

Zhang, G. P., Xia, Y., & Xie, M. (2024). Intermittent demand forecasting with transformer neural networks. Annals of Operations Research, 339, 1051–1072. https://doi.org/10.1007/s10479-023-05447-7

Zorros Revolution Biker. (s. f.). Inicio. Recuperado el 22 de agosto de 2026, de https://zorrosrevolutionbikergt.com/